

SISTEMA INTEL·LIGENT DE SUPORT A LA DECISIÓ (IDSS)

ANÀLISI DEL RENDIMENT ACADÈMIC - DETECCIÓ
D'ESTUDIANTS EN RISC D'ABANDONAMENT ESCOLAR



Albert Campos, Adrià Hernandez,
Oriol Martí, Júlia Pedrol, Albert
Roca, i Jana Roman

3r GIA - PAID

ÍNDEX

1. INTRODUCCIÓ	5
1.1. PROBLEMA	5
1.2. DADES	5
1.2.1. <i>Obtenció de les dades</i>	5
1.2.2. <i>Descripció de les dades</i>	5
1.2.3. <i>Metadata</i>	6
1.3. OBJECTIUS	7
1.4. PLANIFICACIÓ DEL TREBALL	8
1.4.1. <i>Divisió de tasques</i>	8
1.4.2. <i>Pla de contingència</i>	8
2. CANVAS	10
2.1. DEFINICIÓ DEL SISTEMA I ENFOCAMENT	10
2.1.1. <i>Tasca i decisió</i>	10
2.1.2. <i>Proposta de valor</i>	10
2.1.3. <i>Criteri de decisió</i>	10
2.1.4. <i>Dades utilitzades</i>	11
2.1.5. <i>Resultats esperats</i>	11
2.1.6. <i>Desplegament del sistema</i>	11
2.1.7. <i>Tecnologies utilitzades</i>	12
2.1.8. <i>Riscos i limitacions</i>	12
2.1.9. <i>Barreres</i>	12
2.1.10. <i>Viabilitat i fonamentació</i>	12
3. IDSS PROPOSAT	13
3.1. DEFINICIÓ DEL IDSS	13
3.2. MODEL DE DECISIÓ	13
3.3. TIPUS D'USUARIS	15
3.4. ARQUITECTURA DE L'IDSS	16
3.4.1. <i>Monitorització, feedback i política de reentrenament</i>	16
3.4.2. <i>Components addicionals del sistema i ampliació temporal</i>	17
3.4.3. <i>Esquema arquitectura i explicació</i>	19
3.5. DESCRIPCIÓ DE LES FONTS D'INFORMACIÓ	31
3.6. DESCRIPCIÓ DE LES EINES DE PROGRAMARI	32
3.7. DISSENY DEL PREPROCESSAMENT	32
3.7.1. <i>Naturalesa del model predictiu</i>	32
3.7.2. <i>Ús del model en producció</i>	33

3.7.3. Filtratge i generació DB	34
3.7.4. Detecció de missings i tractament	34
3.7.5. Detecció outliers i tractament	35
3.7.6. Filter selection	36
3.7.7. Transformació i creació de noves variables	37
3.8. ANÁLISIS DEL CONJUNT DE DADES (EDA)	37
3.8.1. Dimensions i estructura del dataset	37
3.8.2. Descripció detallada de les variables	38
3.8.3. Estadístics descriptius de variables numèriques	40
3.8.4. Anàlisi de la Variable Objectiu: dropout	41
3.8.5 Anàlisi Univariant	42
3.8.5.1. Variables numèriques	42
3.8.5.2. Variables categòriques	43
3.8.6. Anàlisi Bivariant (relació amb dropout)	44
3.8.6.1. Variables numèriques vs. dropout	44
3.8.6.2. Motivation_Level: El predictor dominant	46
3.8.6.3. Resta de variables categòriques vs. dropout	47
3.8.6.4. Variables binàries vs. dropout	48
3.8.7. Anàlisi de Correlacions	49
3.8.8. Anàlisi de Components Principals (PCA)	50
3.8.9. Perfils d'Estudiants en Risc vs. Sense Risc	51
3.8.10. Interacció Motivació × Assistència	53
3.8.11. Conclusions i Recomanacions	54
4. MODELS DEL SISTEMA	56
4.1. CLUSTERING JERÀRQUIC	56
4.1.1. Descripció	56
4.1.2. Implementació	56
4.1.3. Resultats	58
4.2. MODEL DE PROFILING	59
4.2.1. Descripció	59
4.2.2. Implementació	59
4.2.3. Resultats	64
4.3. MODEL DE CLASSIFICACIÓ SUPERVISADA	66
4.3.1. Descripció	66
4.3.2. Implementació	66
4.3.3. Resultats	67

4.3.4 Anàlisi de variables	67
4.3.5 Conclusions classificació supervisada	68
4.4. MOTOR D'EXPLICABILITAT	68
4.4.1. Descripció	68
4.4.2. Implementació	68
4.4.3. Resultats	69
4.4.4. Conclusions	70
4.5. INTERVENTION IMPACT ANALYSIS	71
4.5.1. Plantejament Inicial i Evolució del Disseny de Recerca	71
4.5.3. Conclusions	72
5. REPRESENTACIÓ DEL CONEIXEMENT	73
5.1. FORMALISME UTILITZAT	73
5.2. ESTRUCTURA PRINCIPAL	74
5.3. FONTS DE CONEIXEMENT	75
5.4. ROL DINS DEL SISTEMA	76
5.5. SORTIDES I VALIDACIÓ	77
5.6. INTEGRACIÓ EN L'ARQUITECTURA	78
6. COMPONENTS DE RAONAMENT	79
7. VALIDACIÓ	81
7.1. ENQUESTA REALITZADA	81
7.2. PREPROCESSAMENT DELS RESULTATS	81
7.3. APLICACIÓ AL IDSS - VALIDACIÓ	82
7.3.1. Clustering i Profiling	83
7.3.2. Model de classificació supervisada	84
7.3.3. Model d'explicabilitat	86
7.3.4. Intervention Impact Analysis	87
7.4. ÈTICA I IMPACTE	87
7.6.1. Validació general del sistema IDSS	89
7.6.2. Validació dels components del sistema	89
7.6.3. Validació de les interaccions entre components	91
7.6.4. Validació dels inputs i outputs	91
7.6.5. Validació del rendiment global del sistema	92
7.6.6. Casos d'ús per a la validació	95
7.6.7. Conclusió	97
8. INTERFÍCIE	98
8.1. ESTRUCTURA GENERAL DEL DASHBOARD	99

8.2. VISITA GLOBAL	99
8.3. VISITA D'ESTUDIANTS I FITXA INDIVIDUAL	100
8.4. PLA D'INTERVENCIÓ I REGISTRE DE SEGUIMENT	103
8.5. VALIDACIÓ, SIMULACIÓ D'INTERVENCIONS I AVALUACIÓ D'ALUMNES NOUS	103
8.6. IMPLEMENTACIÓ TÈCNICA	107
8.7. DECISIONS DE DISSENY I LIMITACIONS	107
8.8. VALOR APORTAT PER LA INTERFÍCIE	108
9. GESTIÓ GENERAL DEL PROJECTE	109
10. MILLORES I FUTURES IMPLEMENTACIONS	110
11. CONCLUSIONS	113

1. INTRODUCCIÓ

1.1. PROBLEMA

El treball es centra en l'anàlisi del rendiment acadèmic dels estudiants i en la identificació de factors que poden influir en un baix rendiment o en un possible risc d'abandonament escolar.

L'objectiu principal és desenvolupar un Sistema Intel·ligent de Suport a la Decisió (IDSS) capaç de detectar patrons rellevants a partir de dades acadèmiques i socioeducatives. Aquest sistema permetrà classificar els estudiants segons el seu nivell de risc (alt risc o baix risc) i donar suport a docents i centres educatius en la presa de decisions. Concretament, el sistema ajudarà a:

- Identificar estudiants que poden necessitar suport acadèmic.
- Detectar factors que influeixen en el rendiment.
- Facilitar la presa de decisions sobre mesures com reforç, tutories o intervencions educatives.

1.2. DADES

1.2.1. *Obtenció de les dades*

Les dades utilitzades en aquest projecte s'han obtingut a través de la plataforma Kaggle, una font àmpliament utilitzada per a projectes d'anàlisi de dades.

Inicialment, es van explorar diverses bases de dades relacionades amb l'àmbit educatiu. Una primera opció va ser descartada perquè ja estava sent utilitzada per un altre grup. Posteriorment, es va trobar una altra base de dades amb una bona estructura, però amb un nombre insuficient de registres, fet que podia comprometre la fiabilitat dels resultats.

Finalment, es va seleccionar el conjunt de dades **Student Exam Performance Dataset**, ja que complia els requisits tant pel que fa a les variables disponibles com al volum de dades. La seva obtenció es va realitzar mitjançant una descàrrega directa des de Kaggle.

Base de dades sobre el rendiment acadèmic dels estudiants i factors socioeducatius associats:

[Student Exam Performance Dataset](#)

1.2.2. *Descripció de les dades*

El conjunt de dades analitza el rendiment acadèmic dels estudiants i inclou informació sobre les seves qualificacions en diferents àrees, com matemàtiques, lectura i escriptura, així com múltiples factors socioeducatius.

Entre les variables incloses destaquen:

- **Variables numèriques:** hores d'estudi, assistència, hores de son, puntuacions prèvies, etc.
- **Variables categòriques:** nivell educatiu dels pares, tipus d'escola, nivell de motivació, etc.
- **Variables binàries:** accés a internet, activitats extraescolars, dificultats d'aprenentatge, etc.

Aquestes dades permeten estudiar la relació entre factors personals, familiars i educatius amb el rendiment acadèmic.

Característiques principals del dataset:

- Nombre de registres: 6607
- Nombre de variables: 21
- Variables numèriques: 7 (*Hours_Studied*, *Attendance*, *Sleep_Hours*, *Previous_Scores*, *Tutoring_Sessions*, *Physical_Activity*, *Exam_Score*)
- Variables binàries: 5 (*Extracurricular_Activities*, *Internet_Access*, *Gender*, *Dropout*, *Learning_Disabilities*)
- Variables qualitatives: 9 (*Parental_Involvement*, *Access_to_Resources*, *Motivation_Level*, *Family_Income*, *Teacher_Quality*, *School_Type*, *Peer_Influence*, *Parental_Education_Level*, *Distance_from_Home*)
- Percentatge de valors perduts: 1% (en tres variables)

1.2.3. Metadata

En aquesta fase s'ha generat la metadata del dataset amb l'objectiu de descriure de manera estructurada totes les variables utilitzades en el projecte.

La metadata consisteix en un conjunt d'informació associada a cada variable del dataset que permet entendre la seva naturalesa, tipus i comportament estadístic. Aquesta informació és fonamental per facilitar les fases posteriors de preprocessament, anàlisi i modelatge.  Metadata

Per a la seva construcció, s'ha desenvolupat un script en Python utilitzant la llibreria *pandas*, que recorre totes les columnes del dataset i calcula automàticament diferents característiques per a cada variable. En concret, per a cada variable s'han obtingut els següents atributs:

- *variable_id*: nom de la variable dins del dataset.
- *variable_type*: tipus de variable (numèrica o categòrica).
- *n*: nombre total d'observacions.
- *min* i *max*: valors mínim i màxim (només per variables numèriques).
- *mean*: valor mitjà (només per variables numèriques).
- *item_text*: distribució de valors en el cas de variables categòriques.

El resultat d'aquest procés és un fitxer estructurat (*Metadata.csv*) que conté la descripció completa de totes les variables del dataset. Aquesta metadata permet:

- Comprendre millor el significat i la distribució de les variables.
- Detectar possibles inconsistències o anomalies en les dades.
- Facilitar la selecció de variables en fases posteriors (feature selection).
- Millorar la interpretabilitat dels models utilitzats en l'IDSS.

En resum, la generació de metadata constitueix un pas clau dins del procés de preparació de dades, ja que proporciona una visió global i estructurada del dataset abans d'aplicar tècniques d'anàlisi avançades.

1.3. OBJECTIUS

L'objectiu principal d'aquest projecte és desenvolupar un Sistema Intel·ligent de Suport a la Decisió (IDSS) capaç d'analitzar el rendiment acadèmic dels estudiants i identificar aquells que presenten risc de baix rendiment o abandonament escolar.

Els nostres objectius específics referents a la realització del treball són els següents:

- **Comprensió i anàlisi inicial de les dades:** Entendre l'estructura del dataset, identificar els diferents tipus de variables (numèriques, binàries i qualitatives) i analitzar la presència de possibles valors nuls o inconsistències.
- **Processament de dades:** Aplicar tècniques de preprocessament com la neteja de dades, la codificació de variables categòriques i la preparació del dataset per al modelatge.
- **Anàlisi i modelatge de dades:** Aplicar tècniques de machine learning, tant supervisades com no supervisades, per identificar patrons i construir models predictius de classificació del risc acadèmic.
- **Validació i interpretació dels resultats:** Avaluar el rendiment dels models i interpretar els resultats per extreure conclusions significatives.
- **Treball en equip i organització del projecte:** Desenvolupar habilitats de coordinació, repartiment de tasques i comunicació entre els membres del grup.

Per altra banda, els nostres objectius basats en l'anàlisi de la base de dades són:

- **Identificar els factors principals associats al rendiment acadèmic:** Analitzar quines variables tenen més impacte en les qualificacions dels estudiants.
- **Detectar estudiants en risc:** Classificar els estudiants en funció del seu nivell de risc (alt o baix) per facilitar intervencions educatives.
- **Analitzar la influència dels factors socioeducatius:** Estudar com el context familiar, econòmic i educatiu influeix en el rendiment.
- **Identificar perfils d'estudiants:** Agrupar estudiants amb característiques similars mitjançant tècniques de clustering.
- **Donar suport a la presa de decisions educatives:** Proporcionar informació útil per ajudar docents i centres a aplicar mesures de suport adequades.

En general, orientem els nostres objectius a extreure conclusions útils de la base de dades per comprendre millor els factors que influeixen en el rendiment acadèmic i contribuir a la millora dels resultats educatius mitjançant l'ús de tècniques d'anàlisi de dades.

1.4. PLANIFICACIÓ DEL TREBALL

1.4.1. Divisió de tasques

Per organitzar el desenvolupament del projecte, s'ha elaborat un diagrama de Gantt dividit per setmanes, des de finals de febrer fins a mitjans de maig. Aquesta planificació permet visualitzar de manera clara quines tasques s'han realitzat en cada fase del projecte i quantes persones han participat aproximadament en cadascuna.

Després del parcial, el grup va estructurar millor la divisió de tasques, especialment en les fases més avançades del projecte. A partir d'aquest moment, el treball es va concentrar principalment en el desenvolupament dels models, la representació del coneixement, la validació del sistema, el disseny del dashboard i la redacció final de l'informe.

La planificació mostra que les primeres setmanes es van dedicar a la definició del problema, la descripció de les dades, la planificació inicial i el disseny de l'arquitectura del sistema. Posteriorment, es va avançar en la part més tècnica, amb el preprocessing, l'anàlisi exploratòria de dades, el PCA, el clustering jeràrquic, el profiling, el model de classificació supervisada i el motor d'explicabilitat.

En les últimes setmanes, el treball es va centrar en la integració dels components finals de l'IDSS, com el Dynamic Supervised Learning, la representació del coneixement, la validació dels models, el dashboard, la gestió del projecte, les conclusions i les possibles millores futures.

Aquest Gantt també reflecteix que algunes tasques han estat realitzades per un nombre reduït de persones, sobretot aquelles més tècniques o específiques, mentre que altres han requerit una participació més àmplia del grup. Aquesta divisió ha permès avançar de manera més eficient, adaptant la càrrega de treball segons la complexitat de cada activitat.

En conjunt, el diagrama de Gantt mostra una evolució progressiva del projecte i evidencia que, després del parcial, el grup va aconseguir organitzar-se millor, portar l'informe més al dia i evitar acumulacions importants de feina al final. Per observar el Gantt: [Diagrama de Gantt](#)

1.4.2. Pla de contingència

Per tal de garantir el bon desenvolupament del projecte, s'ha establert un pla de contingència davant possibles imprevistos.

En cas de dificultats tècniques, manca de temps o problemes en el desenvolupament d'alguna part del projecte, el grup es reorganitza redistribuint les tasques entre els membres disponibles per assegurar el compliment dels terminis.

A més, en cas que algun membre no pugui completar una tasca assignada, la resta del grup assumeix la seva finalització per evitar bloquejos en el progrés del projecte.

Finalment, es prioritzen sempre les parts essencials del treball (anàlisi de dades, modelatge i interpretació de resultats), assegurant així que els objectius principals es compleixin encara que s'hagin d'ajustar aspectes secundaris.

2. CANVAS

2.1. DEFINICIÓ DEL SISTEMA I ENFOCAMENT

Tal i com hem comentat en el primer apartat de l'informe, el projecte proposa el desenvolupament d'un sistema d'anàlisi del rendiment acadèmic orientat a la detecció precoç d'estudiants amb risc de baix rendiment o abandonament escolar. El sistema combina tècniques de machine learning per tal d'obtenir una visió completa dels perfils d'estudiants i poder fer prediccions útils per a la presa de decisions educatives.

El canvas complet del projecte es pot consultar a l'enllaç corresponent: [P Canvas.pptx](#)

En aquest document es presenta una visió global del sistema, incloent-hi la tasca, la proposta de valor, els criteris de decisió, les dades, el desplegament i els principals riscos i barreres.

A continuació, es desglossen els diferents apartats del canvas, replicant i detallant la informació més rellevant per tal d'explicar amb més profunditat cadascun dels components del sistema.

2.1.1. Tasca i decisió

La tasca principal del sistema consisteix en segmentar els estudiants segons els seus perfils acadèmics mitjançant tècniques de clustering. Posteriorment, s'aplica un model supervisat per predir el risc de baix rendiment o abandonament per a cada perfil.

La decisió que es vol recolzar és determinar quin tipus d'intervenció educativa necessita cada estudiant segons el seu nivell de risc. Això permet decidir si cal aplicar mesures com suport acadèmic, seguiment personalitzat o altres accions específiques.

2.1.2. Proposta de valor

El sistema aporta valor permetent detectar patrons en les dades acadèmiques i socioeducatives dels estudiants. Això facilita la identificació d'alumnes amb risc abans que els seus resultats empitjorin.

D'aquesta manera, es millora la presa de decisions educatives, ja que es basen en dades objectives i no només en la percepció del professorat.

2.1.3. Criteri de decisió

El model està dissenyat amb un criteri clar: **prioritzar la detecció d'estudiants en risc.**

Per aquest motiu:

- Es dona més importància a evitar falsos negatius (no detectar un estudiant amb risc).
- S'accepta la presència d'alguns falsos positius.
- El sistema classifica els estudiants en dues categories: **alt risc** i **baix risc**.

La decisió final sempre serà revisada pel professorat.

2.1.4. Dades utilitzades

El sistema utilitza dades demogràfiques, socioeconòmiques i acadèmiques dels estudiants, com:

- Qualificacions d'exàmens
- Hores d'estudi i assistència
- Nivell educatiu dels pares
- Tipus de centre educatiu
- Accés a recursos i suport acadèmic

Aquestes dades permeten analitzar els factors que influeixen en el rendiment i construir models predictius fiables.

2.1.5. Resultats esperats

L'èxit del projecte es mesurarà a través d'indicadors quantificables com:

- Reducció del percentatge d'estudiants amb baix rendiment.
- Increment del nombre d'estudiants que milloren després de rebre suport.
- Augment de la taxa d'aprovat després de les intervencions.

2.1.6. Desplegament del sistema

El sistema seguirà diverses fases:

- El desplegament de l'IDSS en un entorn real requereix diverses fases que van més enllà del desenvolupament tècnic del model, i que impliquen la seva integració efectiva dins d'un centre educatiu.
- **Preparació:** En primer lloc, és necessari establir un contacte inicial amb el centre educatiu per definir els objectius del projecte i les necessitats específiques. En aquesta fase també es formalitzen els acords de privacitat i ús de dades, garantint el compliment de la normativa vigent, com el RGPD.
- **Dades:** Posteriorment, es duu a terme la recollida de dades acadèmiques, socials i demogràfiques dels estudiants. Aquestes dades s'han d'integrar amb els sistemes existents del centre i sotmetre a processos de neteja i validació per assegurar la seva qualitat i consistència.
- **Adaptació del model:** Un cop disponibles les dades, el model s'ha d'ajustar al context específic del centre educatiu. Això inclou la seva validació amb dades reals i la revisió dels resultats conjuntament amb el professorat i els orientadors, per assegurar que les prediccions són coherents i útils.
- **Implementació:** En aquesta fase, el sistema s'integra dins d'una eina accessible, com un dashboard, que permeti als usuaris consultar els resultats de manera intuïtiva. També es realitza la formació dels usuaris i es defineixen protocols clars d'ús per garantir una correcta aplicació del sistema.

2.1.7. *Tecnologies utilitzades*

El projecte combina diferents tècniques de data science:

- **Clustering no supervisat** (K-means o jeràrquic) per segmentar estudiants.
- **Models supervisats** (Logistic Regression, Random Forest, XGBoost) per classificar el risc.
- **Tècniques per dades desbalancejades** (SMOTE o pesos de classe).
- **Eines d'explicabilitat** (feature importance, SHAP) per interpretar els resultats.

2.1.8. *Riscos i limitacions*

El projecte presenta alguns riscos:

- Desbalanceig entre estudiants amb i sense risc.
- Presència de biaixos socioeconòmics en les dades.
- Possibilitat de sobreajustament del model.
- Dificultat d'interpretació dels resultats en context real.
- Risc d'estigmatització dels estudiants classificats com a "alt risc".

2.1.9. *Barreres*

Les principals barreres per a la implementació del sistema són:

- Resistència al canvi per part del professorat.
- Falta de cultura de dades en centres educatius.
- Limitacions tècniques.
- Problemes de privacitat i protecció de dades.

2.1.10. *Viabilitat i fonamentació*

El projecte presenta una viabilitat alta, ja que es disposa d'un dataset estructurat que inclou dades demogràfiques, socioeconòmiques i acadèmiques dels estudiants, amb informació rellevant com l'historial acadèmic i l'estat final (Dropout, Graduate, Enrolled). A més, el problema està clarament definit com una tasca de classificació, fet que facilita l'aplicació de tècniques de machine learning i la seva implementació en un context real.

El sistema té una aplicació directa en la presa de decisions educatives, sempre amb supervisió humana, la qual cosa reforça la seva utilitat i aplicabilitat pràctica.

Pel que fa a la fonamentació, el projecte es basa en estudis previs d'Educational Data Mining i Learning Analytics, que analitzen l'ús de dades educatives per predir el rendiment acadèmic i el risc d'abandonament. Aquests estudis demostren que les tècniques de machine learning són eficaces per identificar patrons rellevants i donar suport a la presa de decisions en l'àmbit educatiu.

3. IDSS PROPOSAT

3.1. DEFINICIÓ DEL IDSS

Un Intelligent Decision Support System (IDSS) és un sistema de suport a la decisió que combina dades, models analítics/IA i una interfície orientada a l'usuari per ajudar persones i organitzacions a prendre decisions més informades, coherents i oportunes. A diferència d'un DSS tradicional (que sovint es limita a reports o consultes), un IDSS incorpora capacitats intel·ligents com la predicció, la detecció de patrons, l'explicabilitat de resultats i la recomanació d'accions.

En el nostre projecte, l'IDSS utilitza dades acadèmiques i socioeducatives (notes, GPA, assistència, crèdits, informació demogràfica i socioeconòmica, etc.) per:

- Predir el risc d'abandonament (sense risc / risc futur / risc imminent),
- Prioritzar estudiants per intervenció,
- Recomanar plans d'actuació (tutoria, reforç, suport econòmic, orientació), i monitoritzar l'evolució del risc al llarg del temps.

Així, el sistema no només informa, sinó que ajuda a decidir què fer, a qui, quan, i amb quins recursos, contribuint a reduir el fracàs o l'abandonament escolar amb actuacions precoces i basades en evidència.

3.2. MODEL DE DECISIÓ

L'IDSS dona suport a diferents decisions dins del procés de prevenció de l'abandonament acadèmic. Aquestes decisions s'han definit a partir del canvas inicial i s'han transformat en decisions operatives, tàctiques i estratègiques que el sistema ha de suportar.

Tipus de decisions:

1. Predir el nivell de risc d'abandonament (Sense risc / Risc futur / Risc imminent)

- Tipus: Operativa (automatitzada)
- Responsable de la decisió: Sistema analític predictiu
- Dades d'entrada: Notes, GPA, assistència, crèdits matriculats, estat de matrícula, pagament de matrícula, variables demogràfiques i socioeconòmiques
- Resultat (output): Classificació de risc per a cada estudiant

2. Ordenar els estudiants segons intervenció

- Tipus: Tàctica
- Responsable de la decisió: Coordinador acadèmic / Servei d'orientació
- Dades d'entrada: Classificació de risc, evolució recent del rendiment, indicadors de desconexió
- Resultat (output): Llista prioritzada d'estudiants en risc imminent

3. Assignar tipus d'intervenció segons el nivell de risc

- Tipus: Operativa
- Responsable de la decisió: Tutor acadèmic / Coordinador
- Dades d'entrada: Nivell de risc, historial acadèmic, situació econòmica, recursos disponibles
- Resultat (output): Pla d'intervenció personalitzat (tutoria, suport econòmic, reforç acadèmic, orientació)

4. Monitoritzar i actualitzar el nivell de risc al llarg del temps

- Tipus: Operativa
- Responsable de la decisió: Sistema analític
- Dades d'entrada: Dades acadèmiques actualitzades, assistència, evolució després de la intervenció
- Resultat (output): Actualització de la probabilitat i del grup de risc

5. Avaluar tendències globals d'abandonament i optimitzar recursos

- Tipus: Estratègica
- Responsable de la decisió: Direcció acadèmica
- Dades d'entrada: Distribució agregada de riscos, taxes històriques d'abandonament, efectivitat de les intervencions
- Resultat (output): Informe institucional i recomanacions de política acadèmica

El resultat principal del sistema serà **una predicció binària**, és a dir, una classificació directa que indicarà si un estudiant està en **risc d'abandonament (Sí)** o **no està en risc (No)**. El model, entrenat amb dades històriques, analitzarà les variables acadèmiques i socioeconòmiques i assignarà automàticament cada estudiant a una d'aquestes dues categories.

A partir d'aquesta classificació binària, el sistema generarà també una **llista d'estudiants identificats com a "En risc"**, que servirà per activar els protocols d'intervenció. Aquesta llista podrà ordenar-se segons criteris complementaris, com ara l'evolució recent del rendiment o el nivell d'urgència detectat per altres indicadors.

El resultat del model (la probabilitat d'abandonament) transforma un problema d'anàlisi manual inabastable en un procés de triatge automatitzat. Ajuda a la presa de decisions de les següents maneres:

- **Reducció de la càrrega cognitiva (Filtratge)**: Un coordinador no pot revisar l'expedient, assistència i situació econòmica de 6.000 estudiants diàriament. L'IDSS actua com un filtre, reduint l'univers d'estudiants a només aquells que superen un llindar de risc (per exemple, el top 5%).

- **Proactivitat vs. Reactivitat:** Les decisions acadèmiques tradicionals es prenen quan l'alumne ja ha suspès o ha deixat de venir. L'IDSS troba patrons subtils (ex. lleugera baixada d'assistència combinada amb cert entorn socioeconòmic) i permet assignar recursos (tutories, beques) *abans* que el problema sigui irreversible.
- **Optimització de recursos limitats:** Les hores de tutoria i les ajudes econòmiques són finites. L'IDSS permet al departament d'orientació ordenar els alumnes i fer una assignació eficient dels recursos cap a on tindran més impacte.

El resultat es comunicarà al stakeholder mitjançant una llista estructurada d'estudiants, on cada alumne apareixerà classificat com a “En risc” o “Sense risc” segons la predicció binària del model.

No es proporcionarà un únic número aïllat, sinó una relació d'estudiants ordenada de manera prioritzada, amb l'objectiu de facilitar la presa de decisions. El criteri principal d'ordenació serà:

- En primer lloc, els estudiants classificats com a “En risc”.
- En segon lloc, els estudiants “Sense risc”.

Dins del grup “En risc”, la llista es podrà ordenar segons criteris complementaris operatius, com ara:

- Empitjorament recent del rendiment acadèmic.
- Descens significatiu d'assistència.
- Major nombre d'indicadors de vulnerabilitat acumulats.

La comunicació es farà mitjançant un quadre de comandament (dashboard) o informe digital, que permetrà al coordinador acadèmic visualitzar ràpidament quins estudiants requereixen intervenció prioritària. D'aquesta manera, el resultat no només informa, sinó que estructura l'acció i facilita una resposta ràpida i eficient.

3.3. TIPUS D'USUARIS

En aquest IDSS es poden diferenciar diversos tipus d'usuaris segons el nivell de decisió (operatiu, tàctic o estratègic), el seu rol dins la institució i el tipus d'informació que necessiten.

a) Usuaris operatius (intervenció directa)

Inclouen tutors/es acadèmics, professorat i orientadors/es que treballen directament amb l'estudiantat. Per a aquests usuaris, el sistema ha de permetre identificar ràpidament el nivell de risc de cada estudiant, entendre quins factors hi contribueixen i oferir recomanacions clares d'intervenció. També és important que puguin fer un seguiment de l'evolució després d'aplicar aquestes accions. En aquest sentit, l'IDSS aporta valor facilitant la detecció precoç i ajudant a actuar de manera immediata i coherent.

b) Usuaris tàctics (priorització i coordinació de recursos)

En aquest grup s'hi troben figures com coordinadors/es acadèmics, caps d'estudis o serveis d'orientació. El seu interès se centra en la gestió global dels casos i dels recursos disponibles. Necessiten disposar de llistes d'estudiants ordenades segons el nivell de risc i la urgència, així com una visió agregada per grups, cursos o programes. Això els permet assignar millor recursos com tutories, reforç acadèmic o ajuts. El sistema, per tant, els ajuda a prioritzar i a assegurar que els casos més crítics reben atenció en primer lloc.

c) Usuaris estratègics (polítiques i planificació institucional)

Aquest perfil inclou equips directius, direcció acadèmica i responsables de qualitat. Utilitzen el sistema com a eina de suport per a la presa de decisions a nivell institucional. Necessiten accedir a indicadors agregats, com la taxa de risc, la seva evolució al llarg del temps o l'efectivitat de les intervencions, així com informes que els ajudin a definir polítiques, planificar programes i ajustar recursos. També és rellevant la possibilitat de comparar resultats entre cohorts o programes. El valor de l'IDSS en aquest cas és orientar les estratègies a mitjà i llarg termini.

d) Usuari "tècnic" (manteniment del sistema)

Inclou analistes de dades, equips IT i data scientists del centre. Tot i no intervenir directament en la presa de decisions educatives, són responsables de garantir el bon funcionament del sistema. Necessiten monitoritzar la qualitat de les dades, reentrenar els models de manera periòdica i detectar possibles canvis en els patrons que puguin afectar el rendiment. També gestionen el manteniment tècnic i les APIs. La seva funció és clau per assegurar la fiabilitat i sostenibilitat del sistema en producció.

3.4. ARQUITECTURA DE L'IDSS**3.4.1. Monitorització, feedback i política de reentrenament**

Mentre el sistema està en funcionament, l'ús dels seus components s'adapta mitjançant una política d'entrenament híbrida, basada principalment en entrenament **fora de línia (off-line)** i monitorització contínua en producció. El model no s'entrena en temps real, ja que en un entorn acadèmic és important garantir estabilitat, traçabilitat i control sobre les versions del model. Per tant, el reentrenament es realitza de manera periòdica cada 6 mesos, incorporant les noves dades acumulades i els resultats reals d'abandonament. Aquest procés és dut a terme per l'equip analític o tècnic responsable del sistema, que valida el nou model amb mètriques de rendiment abans de desplegar-lo. Durant el funcionament ordinari, el sistema monitoritza el comportament del model per detectar possibles desviacions en les dades o en les prediccions. Si es detecta una degradació significativa del rendiment, es pot activar un reentrenament extraordinari.

El mecanisme de retorn (feedback loop) s'implementa registrant totes les prediccions i recomanacions generades pel sistema. Cada vegada que l'IDSS classifica un estudiant en un nivell de risc i suggereix una intervenció, aquesta informació queda emmagatzemada. Posteriorment, els tutors o coordinadors acadèmics indiquen si la intervenció recomanada s'ha dut a terme i quin tipus d'acció s'ha aplicat. A final de semestre o de curs, s'incorpora el resultat real (abandona o no abandona), que es converteix en nova informació etiquetada per millorar el model en futurs entrenaments.

L'IDSS utilitza aquests resultats amb una doble finalitat. D'una banda, per millorar la capacitat predictiva del model en els següents cicles d'entrenament, incorporant nous casos reals. De l'altra, per avaluar l'efectivitat de les decisions recomanades, analitzant si els estudiants que han rebut intervenció han reduït la probabilitat d'abandonament respecte a cohorts anteriors o respecte a estudiants similars.

Per mesurar si les decisions recomanades s'han seguit, el sistema registra el percentatge d'intervencions executades, el temps de resposta i el tipus d'acció aplicada. Per determinar si aquestes decisions han estat adequades, es comparen els resultats finals amb les prediccions inicials, utilitzant mètriques com la precisió del model, la capacitat de detectar casos de risc imminent i, especialment, la reducció real de la taxa d'abandonament en els grups intervinguts.

D'aquesta manera, el sistema funciona com un cicle de millora contínua: prediu, recomana, registra l'acció, observa el resultat real i aprèn de l'experiència acumulada, mantenint alhora estabilitat i control institucional.

3.4.2. Components addicionals del sistema i ampliació temporal

A partir de l'arquitectura actual de l'IDSS, es detecta que, tot i que el sistema ja incorpora els principals mòduls de preprocessament, modelització, explicabilitat i recomanació, es poden afegir alguns components addicionals per millorar la rapidesa de resposta, especialment en situacions com la gestió de correus o notificacions, així com per augmentar l'eficiència global del sistema.

En primer lloc, seria útil incorporar **un mòdul de gestió d'alertes i notificacions en temps quasi real**. Actualment, el sistema genera classificacions de risc i recomanacions, però no queda del tot explícit com es comuniquen aquestes als usuaris operatius. Aquest mòdul permetria generar alertes automàtiques (per exemple, via correu electrònic o dins la pròpia plataforma) quan es detecti un cas de risc immediat. Això reduiria el temps de reacció dels tutors i orientadors, facilitant una intervenció més ràpida.

Relacionat amb això, es pot afegir **un component de priorització dinàmica de tasques**, que, a partir de la llista d'estudiants ordenada per risc que ja genera el sistema, assigni automàticament casos als professionals disponibles. Aquest component podria incorporar un petit model d'optimització que tingui en compte la càrrega de treball, la urgència dels casos i el tipus d'intervenció requerida.

Un altre element clau és **la incorporació d'un mòdul de processament de comunicacions (correus i registres d'interacció)**. Aquest component podria utilitzar tècniques bàsiques de processament de llenguatge natural per analitzar correus dels estudiants o anotacions dels tutors, amb l'objectiu de detectar indicadors de risc no presents en les variables estructurades del dataset. Això enriqueiria la base de dades actual, que ja inclou variables acadèmiques, socioeconòmiques i d'entorn.

També es pot ampliar el sistema amb **un model d'avaluació de l'efectivitat de les intervencions més formalitzat**. Tot i que ja existeix una Knowledge Base amb informació sobre les accions aplicades i els seus resultats, es podria afegir un model estadístic que permeti quantificar quines intervencions funcionen millor segons el perfil d'estudiant. Això ajudaria a fer recomanacions cada cop més personalitzades i basades en evidència.

En la mateixa línia, es pot incorporar **un model de costos i impacte**, especialment útil per als usuaris tàctics i estratègics. Aquest model permetria estimar el cost de cada tipus d'intervenció (tutories, reforç, ajuts, etc.) i relacionar-lo amb els resultats obtinguts (reducció del risc o abandonament evitat). Això facilitaria una assignació de recursos encara més eficient.

Pel que fa a la capa de dades, es podria afegir **un sistema de monitorització en temps real de la qualitat de les dades** i deriva del model, ampliant el que ja es contempla en el procés de reentrenament. Aquest component permetria detectar de manera automàtica canvis en els patrons (per exemple, noves tendències en el comportament dels estudiants) i activar alertes per reentrenar el model.

Finalment, seria interessant incorporar **un mòdul d'informes automatitzats i dashboards interactius**, que generi informes periòdics (setmanals o mensuals) per als diferents tipus d'usuaris. Això complementaria els indicadors agregats ja existents i facilitaria la presa de decisions sense necessitat d'anàlisi manual.

En conjunt, aquests components no substitueixen l'arquitectura actual, sinó que la reforcen, especialment en termes de rapidesa de resposta, integració de nova informació i suport a la presa de decisions en tots els nivells (operatiu, tàctic i estratègic).

3.4.3. Esquema arquitectura i explicació

L'arquitectura del sistema IDSS es divideix en dues capes principals: la capa de dades i analítica, encarregada del processament i modelització, i la capa d'interacció amb usuaris, orientada a la presa de decisions i aplicació d'intervencions. Per poder observar tota l'arquitectura completa es pot accedir en el següent enllaç: [Arquitectura IDSS](#)




Figura1: Arquitectura IDSS

Per poder entrar més en detall, analitzem els apartats de cadascuna de les capes:

1. CAPA DE DADES I ANALÍTICA

- *Anàlisi del domini i dades*

La primera etapa dins de l'arquitectura del Sistema Intel·ligent de Suport a la Decisió (IDSS) correspon a la fase d'anàlisi del domini i recollida de dades, la qual constitueix el punt de partida per al desenvolupament de tot el sistema analític. Aquesta fase té com a objectiu principal identificar, recopilar i estructurar la informació rellevant necessària per construir models capaços d'analitzar el comportament dels estudiants i predir situacions de risc acadèmic.

Per al desenvolupament del sistema s'ha utilitzat un conjunt de dades format per **6.607 registres corresponents a estudiants**, que representen la mostra poblacional sobre la qual es realitza l'estudi. Aquest dataset integra informació procedent de diferents dimensions que poden influir directament o indirectament en el rendiment i permanència acadèmica dels estudiants.

Concretament, les dades recollides es divideixen en tres grans blocs principals:

- **Variables acadèmiques**, relacionades amb el rendiment, progrés i historial formatiu de l'estudiant.
- **Variables socioeconòmiques**, vinculades al context social i econòmic personal o familiar.
- **Variables d'entorn educatiu**, associades a factors contextuais i institucionals del procés educatiu.

El conjunt de dades està compost per un total de **21 variables descriptives**, distribuïdes segons la seva naturalesa en:

- **7 variables numèriques**, que representen magnituds quantitatives contínues o discretes.
- **10 variables categòriques**, que descriuen atributs qualitius amb múltiples categories possibles.
- **4 variables binàries**, que modelen característiques dicotòmiques o de resposta sí/no.

La inclusió de variables de diferent naturalesa permet obtenir una representació completa i multidimensional de cada estudiant, facilitant així la identificació de patrons complexos i relacions no trivials entre factors acadèmics, personals i contextuais.

Aquesta fase constitueix la base estructural del sistema, ja que la qualitat, diversitat i representativitat de les dades recopilades condicionen directament el rendiment i la fiabilitat dels models analítics implementats en etapes posteriors.




Figura2: Anàlisi del domini i recollida de dades

- *Mòdul de metadades*

Un cop recopilades les dades inicials, el següent component dins de l'arquitectura de l'IDSS és el **mòdul de metadades**, encarregat de gestionar i documentar tota la informació descriptiva associada al conjunt de dades utilitzat pel sistema. Aquest mòdul actua com una capa de contextualització de la informació, proporcionant una estructura formal que permet comprendre, interpretar i administrar adequadament cadascuna de les variables disponibles.

La principal funció d'aquest mòdul és centralitzar tota la informació auxiliar necessària per garantir la correcta interpretació i tractament posterior de les dades durant les fases de preprocessament i modelització. En concret, aquest component emmagatzema i organitza els següents elements:

- **Origen de les dades**, especificant la procedència de cada font d'informació incorporada al sistema.
- **Tipus de variables**, identificant la naturalesa de cada atribut segons la seva classificació (numèrica, categòrica o binària).
- **Rang de les variables**, establint els valors mínims, màxims o dominis admissibles per a cada característica.

Aquest mòdul resulta especialment rellevant dins del sistema, ja que permet mantenir la traçabilitat i consistència de la informació al llarg de tot el flux de treball analític. A més, facilita la detecció d'incoherències, errors de format o valors fora de rang abans de l'execució de processos més avançats de preprocessament i entrenament dels models.

En conseqüència, el mòdul de metadades esdevé una eina essencial per assegurar la qualitat i governança de les dades, millorant tant la robustesa del sistema com la interpretabilitat global de l'arquitectura desenvolupada.




Figura3: Mòdul de Metadada

- *Preprocessament de dades*

Després de la fase de recopilació, estructuració i documentació de la informació, el sistema incorpora un mòdul de **preprocessament de dades**, responsable de preparar el conjunt de dades abans de la seva utilització en els processos de modelització analítica. Aquesta etapa té com a finalitat transformar les dades originals en una estructura neta, coherent i adequada per al funcionament òptim dels algorismes de machine learning implementats dins de l'IDSS.

El preprocessament constitueix una fase crítica dins l'arquitectura del sistema, ja que permet detectar i corregir possibles anomalies presents al dataset original, així com adaptar la informació al format requerit pels diferents models predictius i descriptius.

Per assolir aquest objectiu, el mòdul es divideix en diversos subprocessos seqüencials:

- **Visualització exploratòria de dades (EDA)**, orientada a analitzar la distribució inicial de les variables i identificar patrons, tendències i possibles anomalies dins del conjunt de dades.
- **Filtratge i generació de la base de dades**, procés destinat a seleccionar únicament la informació rellevant per a l'estudi i estructurar la base de treball definitiva.
- **Detecció i tractament de valors absents**, on s'identifiquen els registres incomplets i s'aplica una imputació basada en la moda per a les variables de naturalesa categòrica.
- **Detecció i tractament d'outliers**, enfocada a identificar observacions anòmales susceptibles d'afectar negativament el rendiment dels models, emprant tècniques de reducció de dimensionalitat com l'Anàlisi de Components Principals (PCA) per facilitar-ne la detecció.
- **Selecció de característiques (Feature Selection)**, fase en la qual es determinen les variables amb major capacitat explicativa i predictiva per al problema analitzat.
- **Transformació i creació de noves variables**, procés final d'adaptació de les dades on s'inclou la codificació de variables categòriques i la generació de nous atributs derivats.

Com a resultat final d'aquest conjunt de processos, s'obté una **base de dades imputada i preprocessada**, que constitueix el dataset final preparat per alimentar els models analítics integrats dins del sistema. Aquesta base representa el punt d'entrada cap al mòdul de modelització, garantint que la informació utilitzada pels algorismes sigui consistent, completa i estructuralment adequada.




Figura4: Preprocessament de dades

- *Mòdul de modelització*

Un cop completada la fase de preprocessament de dades i obtinguda la base de dades imputada i preparada per al seu ús analític, el sistema incorpora el **mòdul de modelització**, responsable de transformar les dades processades en coneixement accionable per donar suport a la presa de decisions acadèmiques.

Aquest mòdul constitueix el nucli intel·ligent del Sistema Intel·ligent de Suport a la Decisió (IDSS), ja que integra els diferents models d'anàlisi de dades i aprenentatge automàtic encarregats de detectar patrons, generar prediccions i explicar els factors associats al risc d'abandonament acadèmic.

Per assolir aquests objectius, el mòdul es divideix en quatre components principals.

- Clustering jeràrquic

El primer component del mòdul de modelització correspon al **clustering jeràrquic**, una tècnica d'aprenentatge no supervisat utilitzada per identificar agrupacions naturals dins del conjunt de dades sense necessitat de disposar d'etiquetes prèvies.

L'objectiu principal d'aquest model dins del sistema és segmentar els estudiants en diferents grups homogenis segons les seves característiques acadèmiques, socioeconòmiques i contextuals, permetent identificar perfils comuns de comportament i patrons compartits entre estudiants amb característiques similars. Aquest procés de segmentació facilita una comprensió més profunda de la composició de la població estudiantil i aporta una capa addicional d'anàlisi descriptiva al sistema, contribuint a detectar perfils potencialment associats a diferents nivells de risc acadèmic.

- Classificació supervisada

El segon component correspon al **model de classificació supervisada**, destinat a predir el risc d'abandonament acadèmic de cada estudiant de manera individualitzada.

Aquest model utilitza dades històriques prèviament etiquetades per aprendre patrons associats a casos d'abandonament i no abandonament, permetent posteriorment generar prediccions sobre nous estudiants introduïts al sistema.

La seva funció principal és proporcionar una estimació quantitativa i categòrica del nivell de risc de cada estudiant, constituint la base del sistema de detecció primerenca implementat dins l'IDSS.

- Motor d'explicabilitat

El tercer component del mòdul és el **motor d'explicabilitat**, encarregat d'identificar i mostrar els factors principals que han influït en la predicció de risc generada pel model de classificació.

Aquest submòdul permet interpretar les decisions del sistema, augmentant la transparència i comprensibilitat dels resultats generats. La seva finalitat és facilitar que tutors, orientadors i responsables acadèmics entenguin els motius pels quals un estudiant ha estat classificat dins d'un determinat nivell de risc.

Aquesta funcionalitat resulta especialment rellevant en entorns educatius, on la interpretabilitat de les prediccions és fonamental per garantir confiança, justificació i acceptació en l'ús del sistema.

- Intervention aware learning


Finalment, el quart component del mòdul de modelització correspon a l'**Intervention-Aware Learning**, un enfocament que amplia el model supervisat tradicional incorporant l'impacte de les intervencions aplicades sobre els estudiants.

A diferència dels models estàtics, aquest component té en compte l'evolució temporal del risc, analitzant com canvien les variables dels estudiants al llarg del temps en funció de les accions realitzades, com ara tutories o reforç acadèmic.

Per fer-ho, el sistema compara periòdicament les dades dels estudiants i integra la informació relativa a la predicció inicial, les intervencions aplicades i l'evolució real observada. Això permet identificar quines accions són més efectives per a cada perfil d'estudiant.

Aquesta informació es fa servir en els processos de reentrenament del sistema, ajustant els models en funció de l'impacte real de les intervencions i millorant així la seva capacitat predictiva.

Cal destacar que, en l'estat actual del projecte, aquest component es planteja com una línia d'evolució futura, ja que requereix dades temporals per al seu correcte funcionament.

*Figura5: Mòdul de modelització*

- *Sortides del sistema*

Una vegada finalitzat el procés de modelització i generades les corresponents prediccions i anàlisis, el Sistema Intel·ligent de Suport a la Decisió produeix un conjunt de **sortides estructurades** destinades a facilitar la interpretació dels resultats i donar suport directe a la presa de decisions acadèmiques per part dels usuaris finals. Aquest conjunt de sortides constitueix la capa de retorn d'informació del sistema, transformant els resultats analítics obtinguts pels models en informació comprensible, accionable i orientada a la intervenció educativa. Per tal d'oferir una visió integral del risc i facilitar diferents nivells d'anàlisi, les sortides del sistema es divideixen en quatre components principals.

- Classificació de risc

La primera sortida generada pel sistema correspon a la **classificació del risc acadèmic de cada estudiant**, resultat directe del model de classificació supervisada. Aquest mecanisme permet categoritzar cada estudiant en diferents nivells de risc segons la probabilitat estimada d'abandonament acadèmic, establint tres possibles classificacions:

- **Sense risc**, quan no es detecten indicadors significatius de possible abandonament.
- **Risc futur**, quan es detecta una probabilitat moderada de risc potencial a mitjà termini.
- **Risc immediat**, quan el sistema identifica una elevada probabilitat d'abandonament imminent.

Aquesta categorització facilita una primera identificació ràpida dels estudiants susceptibles de requerir seguiment o intervenció.

- **Recomanacions d'intervenció**

La segona sortida del sistema consisteix en la generació de **recomanacions d'intervenció personalitzades**, orientades a proposar possibles accions correctives o preventives segons el nivell de risc detectat.

Aquestes recomanacions es basen en la informació obtinguda pels models analítics i tenen com a objectiu facilitar la definició d'estratègies de suport adequades per a cada cas particular.

Entre les possibles accions recomanades pel sistema es troben:

- Tutories personalitzades
- Suport acadèmic específic
- Recursos educatius complementaris

Aquest component permet transformar les prediccions en propostes d'acció concretes, facilitant la presa de decisions per part del personal acadèmic.

- **Llista prioritzada d'estudiants**

El sistema també genera una **llista prioritzada d'estudiants**, en la qual els alumnes són ordenats segons la probabilitat estimada de risc d'abandonament.

Aquesta funcionalitat permet establir un mecanisme de priorització operativa, facilitant que els responsables acadèmics puguin focalitzar els seus esforços primer en aquells estudiants amb major necessitat potencial d'intervenció.

Mitjançant aquesta ordenació, el sistema contribueix a optimitzar l'assignació de recursos i temps disponibles dins de l'organització educativa.


- **Indicadors agregats i informes**

Finalment, el sistema proporciona un conjunt d'**indicadors agregats i informes analítics**, orientats a oferir una visió global de la situació acadèmica de la institució.

Aquests indicadors permeten analitzar el comportament agregat del risc des de diferents perspectives, incloent:

- **Risc per curs acadèmic**
- **Risc per centre o unitat educativa**
- **Evolució temporal dels nivells de risc**

Aquesta informació resulta especialment útil per als perfils de gestió i direcció, ja que facilita l'anàlisi estratègica i la planificació institucional basada en dades.

*Figura6: Sortides del sistema*

2. CAPA D'INTERACCIÓ AMB ELS USUARIS

La capa d'interacció amb els usuaris és l'encarregada de connectar els resultats generats pel sistema amb la seva aplicació pràctica en l'àmbit educatiu. Aquesta capa permet que els diferents perfils d'usuari interpretin la informació, prenguin decisions i executin accions d'intervenció sobre els estudiants.

A més, integra mecanismes de seguiment i avaluació que permeten retroalimentar el sistema amb noves dades, afavorint la seva millora contínua mitjançant processos de reentrenament.

- *Arribada d'un nou usuari*

L'arquitectura del sistema preveu la incorporació de **nous estudiants**, els quals constitueixen el punt d'entrada de nova informació dins del flux operatiu de l'IDSS. Aquests registres s'incorporen a la **capa de dades i analítica**, on són tractats inicialment abans de ser analitzats pels models.

Un cop introduïdes les dades del nou estudiant, aquestes passen directament al **mòdul de preprocessament de dades**, on es duen a terme els processos necessaris per garantir la seva qualitat i coherència amb la base de dades existent. Aquest tractament inclou la gestió de valors absents, la transformació de variables i l'adaptació al format requerit pels models.

Aquest procés assegura que la nova informació sigui compatible amb el sistema i pugui ser utilitzada de manera eficient en les fases posteriors de modelització, permetent així generar prediccions i recomanacions personalitzades per a cada nou estudiant.




Figura7: Arribada d'un nou usuari

- *Interfície segons l'usuari*

La interfície del sistema està dissenyada per adaptar-se als diferents perfils d'usuari que interactuen amb l'IDSS, garantint que cada actor disposi de la informació rellevant segons les seves necessitats i responsabilitats dins de l'àmbit educatiu.

En aquest sentit, es diferencien tres tipus principals d'usuaris:

- Usuaris operatius: Com tutors, professors i orientadors, que utilitzen el sistema per fer el seguiment individual dels estudiants i aplicar intervencions directes.
- Usuaris tàctics: Com coordinadors acadèmics o caps d'estudis, que fan servir la informació per supervisar grups d'estudiants i gestionar recursos educatius.
- Usuaris estratègics: Com equips de direcció o unitats de qualitat, que utilitzen els indicadors agregats per a la presa de decisions a nivell institucional.

Aquesta diferenciació permet adaptar la visualització i l'accés a la informació, facilitant una utilització més eficient del sistema segons el rol de cada usuari.




Figura8: Interfície segons el tipus d'usuari


- *Mòdul de decisió i intervenció*

El mòdul de decisió i intervenció és l'encarregat de transformar els resultats generats pel sistema en **accions concretes sobre els estudiants**, amb l'objectiu de prevenir situacions de risc d'abandonament acadèmic.

A partir de la classificació del risc i les recomanacions proporcionades pel sistema, els usuaris poden aplicar diferents tipus d'intervenció adaptades a les necessitats de cada estudiant. Entre les principals accions contemplades es troben:

- **Tutories personalitzades**, orientades al seguiment individual de l'estudiant.
- **Reforç acadèmic**, per millorar el rendiment en assignatures específiques.
- **Suport acadèmic**, mitjançant recursos o programes d'ajuda addicionals.
- **Orientació personalitzada**, enfocada a aspectes personals o motivacionals.
- **Reassignació de recursos**, per optimitzar l'ús dels recursos educatius disponibles.

Aquest mòdul permet que el sistema no només identifiqui situacions de risc, sinó que també faciliti la seva gestió activa, contribuint a una intervenció més eficient i basada en dades.

*Figura9: Decisió i intervenció*

- *Knowledge Base i seguiment*

El mòdul de **Knowledge Base i seguiment** té com a objectiu emmagatzemar i gestionar la informació derivada de les intervencions realitzades sobre els estudiants, així com la seva evolució al llarg del temps. Aquest component actua com una base de coneixement del sistema, on es registra informació rellevant com ara si s'han aplicat les recomanacions proposades, quin tipus d'intervenció s'ha dut a terme, quan s'ha aplicat i quin resultat ha tingut. A més, permet fer un seguiment continu de l'evolució del risc i del comportament de cada estudiant, així com analitzar l'efectivitat de les intervencions tant a nivell individual com per grups d'usuaris.

Aquest mòdul resulta essencial per generar coneixement acumulatiu dins del sistema i constitueix la base per a processos posteriors d'avaluació i millora contínua.

- *Avaluació i reentrenament*

El mòdul d'**avaluació i reentrenament** té com a objectiu analitzar el rendiment del sistema i garantir la seva millora contínua al llarg del temps. Aquest procés es basa en la incorporació de **noves dades reals**, com ara el resultat final dels estudiants (abandona o no abandona), així com en l'anàlisi de la qualitat de les prediccions generades pel model. A més, es tenen en compte altres factors rellevants com la possible deriva de les dades o canvis en els patrons de comportament, així com l'efectivitat de les intervencions aplicades. A partir d'aquesta avaluació, el sistema activa processos de **reentrenament dels models**, permetent actualitzar-los amb informació recent i millorar la seva capacitat predictiva. D'aquesta manera, es garanteix que el sistema es mantingui adaptat a l'evolució del context educatiu i continuï oferint resultats fiables. Aquest mòdul tanca el cicle del sistema, ja que permet retroalimentar els models amb nova informació i assegurar un funcionament continu, adaptatiu i basat en dades.

3.5. DESCRIPCIÓ DE LES FONTS D'INFORMACIÓ

En aquest projecte, les fonts d'informació utilitzades són principalment de naturalesa estructurada i provenen d'un dataset extern obtingut a través de la plataforma Kaggle. Aquest conjunt de dades constitueix la base principal sobre la qual es construeix tot el sistema IDSS.

La font principal és el dataset *Student Exam Performance Dataset*, que conté informació acadèmica i socioeducativa dels estudiants. Aquest dataset inclou variables de diferent tipologia (numèriques, categòriques i binàries) que permeten analitzar el rendiment acadèmic i identificar possibles factors associats al risc d'abandonament o baix rendiment.

Aquestes dades es poden considerar una font secundària, ja que no han estat recollides directament pel grup, sinó que provenen d'una recopilació prèvia. Tot i això, presenten una estructura adequada i un volum suficient de registres (més de 6000 observacions), fet que permet garantir una anàlisi robusta i fiable.

Pel que fa a la naturalesa de la informació, el dataset integra diferents tipus de variables:

- Variables acadèmiques: puntuacions d'exàmens, assistència, hores d'estudi o resultats previs.
- Variables socioeconòmiques: nivell educatiu dels pares, ingressos familiars o accés a recursos.
- Variables de context personal: motivació, activitats extraescolars o influència de l'entorn.

Aquesta combinació de fonts d'informació permet obtenir una visió global de l'estudiant, integrant factors acadèmics i personals que són clau per a la predicció del risc.

A més de la font principal, el sistema contempla l'ús de fonts d'informació internes en un escenari de producció real. Aquestes inclourien sistemes institucionals com:

- Sistemes de gestió acadèmica (ERP educatiu), amb informació sobre matrícules, crèdits i historial acadèmic.
- Plataformes d'aprenentatge (LMS), que proporcionen dades d'activitat, participació i seguiment.
- Bases de dades administratives, amb informació socioeconòmica o demogràfica actualitzada.

Aquestes fonts internes permetrien alimentar el model en temps real i mantenir actualitzades les prediccions del sistema.

Finalment, també es considera una font d'informació rellevant el propi sistema IDSS, a través del seu mecanisme de feedback. Les prediccions generades, les intervencions aplicades i els resultats finals (abandona o no abandona) es registren i s'incorporen com a noves dades per al reentrenament del model. D'aquesta manera, el sistema es converteix en una font dinàmica d'informació que evoluciona amb el temps.

En conjunt, les fonts d'informació utilitzades combinen dades externes estructurades, possibles fonts institucionals i informació generada pel propi sistema, permetent construir un model robust, adaptable i orientat a la presa de decisions en context educatiu.

3.6. DESCRIPCIÓ DE LES EINES DE PROGRAMARI

En aquest projecte s'han utilitzat diverses eines de programari orientades a l'anàlisi de dades i al desenvolupament d'un sistema intel·ligent de suport a la decisió (IDSS).

L'eina principal ha estat **RStudio**, utilitzada com a entorn de desenvolupament per al llenguatge **R**, que ha permès implementar les fases de preprocessament, anàlisi exploratòria i tractament de dades. **R** s'ha escollit per la seva potència en anàlisi estadística i manipulació de dades.

S'han utilitzat diferents llibreries específiques:

- **dplyr** i **tidyr** per a la neteja i transformació de dades.
- **ggplot2** per a la visualització i EDA.
- **stats** per a tècniques com el PCA.

Paral·lelament, s'ha utilitzat **RapidMiner** com a eina de suport per al modelatge i l'experimentació amb tècniques de machine learning. Aquesta plataforma permet construir fluxos de treball de manera visual, facilitant la implementació de models de classificació i clustering, així com la seva validació i comparació de resultats.

Les dades utilitzades s'han obtingut a través de **Kaggle**, que ha proporcionat el dataset principal del projecte. A nivell de sistema, es contempla l'ús de **Shiny** per a la creació de dashboards interactius que permetin visualitzar els resultats i facilitar la presa de decisions dins l'IDSS.

Finalment, per al treball col·laboratiu i la documentació, s'han utilitzat eines com **Google Drive** i **Google Docs**, que han permès la coordinació del grup i la redacció conjunta de l'informe.

En conjunt, aquestes eines cobreixen tot el procés, des del tractament de dades fins al modelatge i la seva aplicació en un sistema de suport a la decisió.

3.7. DISSENY DEL PREPROCESSAMENT

3.7.1. *Naturalesa del model predictiu*

El model basat en dades generat en el procés de KDD té la naturalesa d'un model predictiu de classificació implementat com una peça de programari. Durant el procés d'extracció de coneixement, a partir de les dades històriques acadèmiques (notes, assistència, crèdits matriculats, variables socioeconòmiques, etc.), s'entrena un algoritme d'aprenentatge automàtic capaç d'identificar patrons associats al risc d'abandonament.

Des del punt de vista formal, el model és una funció matemàtica que relaciona un conjunt de variables d'entrada amb una probabilitat de sortida (probabilitat d'abandonament o nivell de risc). Tanmateix, en la seva aplicació real dins del sistema IDSS, aquesta funció es materialitza com una estructura computacional entrenada que pot ser executada automàticament sobre noves dades.

Per tant, no es tracta d'un gràfic ni d'un conjunt manual de regles, sinó d'un model estadístic o d'aprenentatge automàtic entrenat amb dades històriques i implementat com a component programari dins del sistema de suport a la decisió. Aquest model rep dades actuals dels estudiants i retorna una predicció quantitativa (probabilitat) que posteriorment es tradueix en una classificació de risc útil per a la presa de decisions acadèmiques.

3.7.2. Ús del model en producció

En producció, el model s'utilitza com un component programari integrat dins del sistema IDSS que funciona com a servei d'inferència automàtica. El model rep dades actualitzades dels estudiants procedents dels sistemes institucionals (ERP acadèmic, LMS i bases de dades administratives), executa el càlcul predictiu i retorna una estimació del risc d'abandonament.

Des del punt de vista formal, el model és una funció matemàtica de classificació entrenada prèviament amb dades històriques. Aquesta funció relaciona un conjunt de variables d'entrada (notes, assistència, crèdits, variables socioeconòmiques, etc.) amb una probabilitat de sortida. No obstant això, en producció no es presenta com una equació explícita que l'usuari hagi de calcular manualment, sinó com una estructura computacional entrenada que s'executa automàticament sobre noves dades.

El procés d'ús en producció segueix les etapes següents:

1. **Recepció de dades actuals** dels estudiants mitjançant API o connexió directa a la base de dades institucional.
2. **Preprocessament automàtic**, incloent neteja de dades, tractament de valors absents i càlcul de variables derivades (mitjana de notes, variació del rendiment, percentatge d'assistència, ràtio de crèdits aprovats, etc.).
3. **Execució del model (inferència)**, que genera una probabilitat de risc per a cada estudiant.
4. **Transformació de la probabilitat en una categoria de risc** (Sense risc / Risc futur / Risc imminent) mitjançant llindars definits pel sistema.

Per tant:

- **No és simplement una equació manual**, tot i que matemàticament es basa en una funció estadística o d'aprenentatge automàtic.
- **No és únicament un conjunt de regles deterministes**, encara que pot incorporar regles de negoci complementàries (per exemple, per establir l·lindars o prioritzar intervencions).
- **Sí que requereix visualització i interpretació per part de l'usuari**, ja que els resultats es mostren mitjançant un dashboard amb llistes prioritzades, indicadors de risc i evolució temporal, facilitant la presa de decisions per part del coordinador o tutor.

En conseqüència, el model en producció actua com un **motor predictiu automatitzat**, mentre que la interpretació estratègica i l'execució de les intervencions continuen essent responsabilitat dels agents humans del sistema educatiu.

3.7.3. Filtratge i generació DB

En aquesta fase del preprocessament s'ha dut a terme el filtratge de la base de dades i la generació del conjunt de dades final que s'utilitzarà en les etapes posteriors del sistema.

Inicialment, es parteix del dataset original, que conté 6607 registres i 22 variables de diferent naturalesa (numèriques, categòriques i binàries). A partir d'aquest conjunt inicial, es realitza un procés de neteja i preparació amb l'objectiu d'obtenir una base de dades consistent, sense valors perduts i adequada per al modelatge.

El filtratge no s'ha plantejat com una eliminació massiva de variables, sinó com una selecció funcional en funció de l'ús posterior. En aquest sentit, es diferencien dos nivells:

- **Filtratge global del dataset**, on es mantenen totes les variables originals un cop tractades.
- **Filtratge específic per al PCA**, on es seleccionen únicament les variables numèriques contínues rellevants per a la detecció exploratòria d'outliers.

Finalment, es genera una nova base de dades preprocessada (`student_preprocessed.csv`), que conté totes les observacions sense valors nuls i amb les transformacions aplicades. Aquesta base serà la que s'utilitzarà com a entrada per als models del sistema IDSS.

3.7.4. Detecció de missings i tractament

La detecció de valors absents s'ha realitzat mitjançant un anàlisi exhaustiu del dataset, calculant tant el nombre com el percentatge de valors perduts per a cada variable.

Els resultats mostren que només tres variables presenten valors nuls:

- *Parental_Education_Level* (1,36%)
- *Teacher_Quality* (1,18%)
- *Distance_from_Home* (1,01%)

La resta de variables no presenten valors absents, la qual cosa indica una bona qualitat general de les dades.

Atès que els valors perduts es concentren únicament en variables categòriques i que el seu percentatge és molt reduït (aproximadament un 1%), s'ha optat per un tractament simple i robust basat en la **imputació per la moda global**.

En concret:

- *Teacher_Quality* s'imputa amb la categoria més freqüent (*Medium*).
- *Parental_Education_Level* s'imputa amb (*High School*).
- *Distance_from_Home* s'imputa amb (*Near*).

Aquesta decisió es justifica per:

- la baixa proporció de valors perduts,
- la naturalesa categòrica de les variables,
- i la voluntat de mantenir la interpretabilitat del model.

Després d'aquesta imputació, el dataset queda completament lliure de valors nuls.

3.7.5. *Detecció outliers i tractament*

La detecció d'outliers s'ha abordat com una fase d'anàlisi exploratòria amb l'objectiu d'identificar possibles observacions anòmales dins del conjunt de dades.

Per a això, s'ha aplicat una **Anàlisi de Components Principals (PCA)** sobre un subconjunt de variables numèriques contínues seleccionades:

- *Hours_Studied*
- *Attendance*
- *Sleep_Hours*
- *Previous_Scores*
- *Tutoring_Sessions*

S'ha exclòs la variable "Exam_score" ja que tot i que l'objectiu del sistema és predir el risc d'abandonament, aquesta s'ha considerat una variable de resultat (indicador de rendiment acadèmic) i així evitem introduir possibles biaixos en la detecció de patrons de les variables explicatives.




Figura10: Gràfic PCA per explorar outliers

A partir de la projecció en les dues primeres components principals (PC1 i PC2), s'ha calculat la distància de Mahalanobis per detectar observacions extremes. Utilitzant un llindar basat en la distribució chi-quadrat (nivell de confiança del 99%), s'han identificat 34 observacions com a potencials outliers. No obstant això, l'anàlisi visual i estadística indica que aquestes observacions no corresponen a errors de dades, sinó a casos poc freqüents però plausibles dins del context del dataset. Per aquest motiu, s'ha decidit **no eliminar cap observació**, mantenint la integritat del conjunt de dades. Així, el tractament dels outliers ha estat conservador, prioritzant la preservació de la informació original.

3.7.6. Filter selection

El procés de *filter selection* s'ha aplicat amb l'objectiu de seleccionar les variables més adequades per a cada etapa del preprocessament, especialment en l'anàlisi amb PCA. En lloc d'eliminar variables de forma global, s'ha adoptat una estratègia basada en el context d'ús:

- Per al dataset final, es conserven totes, ja que poden ser rellevants per als models predictius.
- Per a l'anàlisi PCA, es realitza un filtratge específic, seleccionant únicament variables numèriques contínues.

Aquest filtratge s'ha fet amb els criteris següents:

- Inclusió de variables quantitatives contínues.
- Exclusió de variables categòriques i binàries.
- Exclusió de la variable objectiu (*Exam_Score*).
- Exclusió de variables amb naturalesa ordinal discreta (*Physical_Activity*).

Aquesta selecció permet aplicar el PCA de manera adequada, evitant biaixos derivats de variables no contínues i assegurant una interpretació correcta dels resultats.

3.7.7. Transformació i creació de noves variables

En aquesta fase s'han aplicat transformacions sobre el dataset amb l'objectiu de facilitar el seu ús en models de machine learning, mantenint alhora la interpretabilitat de les dades. La principal transformació realitzada ha estat la **binarització de variables dicotòmiques**, concretament:

- *Extracurricular_Activities*
- *Internet_Access*
- *Learning_Disabilities*

Aquestes variables, originalment en format *Yes/No*, s'han convertit a format numèric (1/0), permetent així la seva utilització en models quantitatius. Pel que fa a la resta de variables categòriques (com *High/Medium/Low*, *Near/Moderate/Far*, etc.), s'ha decidit **mantenir-les en el seu format original**, amb l'objectiu de preservar la seva interpretabilitat i evitar transformacions innecessàries en aquesta fase. No s'han creat noves variables derivades en aquesta etapa del preprocessament. Aquesta decisió respon a una estratègia progressiva, deixant la possible generació de noves variables per fases posteriors del projecte, en funció de les necessitats dels models.

3.8. ANÁLISIS DEL CONJUNT DE DADES (EDA)

Les dades analitzades provenen del fitxer [student_final.csv](#), que conté informació acadèmica, personal i socioeconòmica d'estudiants recopilada originalment de Kaggle i preprocessada per al projecte. El preprocessament previ ha inclòs la imputació de valors perduts per moda i la detecció d'outliers (conservats per preservar la informació original).

3.8.1. Dimensions i estructura del dataset

El dataset conté 6,607 registres (estudiants) i 21 variables. Cada fila representa un estudiant individual amb les seves característiques acadèmiques, personals i contextuais.

Propietat	Valor
Nombre de registres (files)	6,607
Nombre de variables	21
Variables numèriques	7
Variables binàries	4
Variables categòriques	10
Variable objectiu	1
Valors perduts	0

Figura11: Taula segons les dimensions i valors del dataset

3.8.2. Descripció detallada de les variables

A continuació es descriu cada variable del dataset, indicant el seu tipus, rang de valors i significat en el context de la detecció d'abandonament escolar.

Variables numèriques continues (7):

Variable	Descripció	Tipus	Rang	Mitjana $\pm$ DE
Hours_Studied	Nombre d'hores setmanals dedicades a l'estudi fora de l'horari lectiu.	Numèrica	1 – 44	20.0 $\pm$ 6.0
Attendance	Percentatge d'assistència a classe de l'estudiant.	Numèrica	60 – 100	80.0 $\pm$ 11.5
Sleep_Hours	Nombre d'hores de son diàries de l'estudiant.	Numèrica	4 – 10	7.0 $\pm$ 1.5
Previous_Scores	Puntuació obtinguda en avaluacions prèvies (escala 0-100).	Numèrica	50 – 100	75.1 $\pm$ 14.4
Tutoring_Sessions	Nombre de sessions de tutoria o reforç acadèmic rebudes.	Numèrica	0 – 8	1.5 $\pm$ 1.2
Physical_Activity	Nivell d'activitat física setmanal (escala ordinal discreta).	Numèrica	0 – 6	3.0 $\pm$ 1.0
Exam_Score	Puntuació obtinguda a l'examen final (variable de resultat acadèmic).	Numèrica	55 – 101	67.2 $\pm$ 3.9

Figura12: Taula descriptiva de les variables numèriques

Variables binàries (4):

Variable	Descripció	Valors	Distribució
Extracurricular_Activities	Indica si l'estudiant participa en activitats extraescolars.	0 (No) / 1 (Sí)	No: 2669 (40.4%) Sí: 3938 (59.6%)
Internet_Access	Indica si l'estudiant disposa d'accés a internet a casa.	0 (No) / 1 (Sí)	No: 499 (7.6%) Sí: 6108 (92.4%)
Learning_Disabilities	Indica si l'estudiant presenta alguna discapacitat d'aprenentatge diagnosticada.	0 (No) / 1 (Sí)	No: 5912 (89.5%) Sí: 695 (10.5%)
Gender	Gènere de l'estudiant.	Male / Female	Male: 3814 (57.7%) Female: 2793 (42.3%)

Figura13: Taula descriptiva de les variables binàries

Variables categòriques ordinals i nominals (9):

Variable	Descripció	Categories	Distribució
Parental_Involvement	Grau d'implicació dels pares en l'educació de l'estudiant.	Low / Medium / High	Low: 1337 (20.2%) Medium: 3362 (50.9%) High: 1908 (28.9%)
Access_to_Resources	Nivell d'accés a recursos educatius (materials, tecnologia, etc.).	High / Medium / Low	High: 1975 (29.9%) Medium: 3319 (50.2%) Low: 1313 (19.9%)
Motivation_Level	Nivell de motivació percebut de l'estudiant.	Low / Medium / High	Low: 1937 (29.3%) Medium: 3351 (50.7%) High: 1319 (20.0%)
Family_Income	Nivell d'ingressos del nucli familiar.	Low / Medium / High	Low: 2672 (40.4%) Medium: 2666 (40.4%) High: 1269 (19.2%)
Teacher_Quality	Percepció de la qualitat del professorat.	Medium / High / Low	Medium: 4003 (60.6%) High: 1947 (29.5%) Low: 657 (9.9%)
School_Type	Tipus de centre educatiu.	Public / Private	Public: 4598 (69.6%) Private: 2009 (30.4%)
Peer_Influence	Tipus d'influència predominant del grup d'iguals.	Positive / Negative / Neutral	Positive: 2638 (39.9%) Negative: 1377 (20.8%) Neutral: 2592 (39.2%)
Parental_Education_Level	Nivell educatiu màxim assolit pels pares.	High School / College / Postgraduate	High School: 3313 (50.1%) College: 1989 (30.1%) Postgraduate: 1305 (19.8%)
Distance_from_Home	Distància entre el domicili i el centre educatiu.	Near / Moderate / Far	Near: 3951 (59.8%) Moderate: 1998 (30.2%) Far: 658 (10.0%)

*Figura14: Taula descriptiva de les variables categòriques***Variable objectiu (1):**

Variable	Descripció	Valors	Distribució
dropout	Indica si l'estudiant ha abandonat els estudis. Aquesta és la variable que el sistema IDSS ha de predir.	0 (No abandona) / 1 (Abandona)	No: 5288 (80.0%) Sí: 1319 (20.0%)

Figura15: Taula descriptiva dels objectius

Classificació resum per tipus de variable:

Tipus	Variables	N
Numèriques contínues	Hours_Studied, Attendance, Sleep_Hours, Previous_Scores, Tutoring_Sessions, Physical_Activity, Exam_Score	7
Binàries	Extracurricular_Activities, Internet_Access, Learning_Disabilities, Gender	4
Catègòriques ordinals	Parental_Involvement, Access_to_Resources, Motivation_Level, Family_Income, Teacher_Quality, Peer_Influence, Parental_Education_Level, Distance_from_Home	8
Catègòrica nominal	School_Type	1
Variable objectiu	dropout (0 = No abandona, 1 = Abandona)	1

Figura16: Taula de classificació de resum per tipus de variable

3.8.3. Estadístics descriptius de variables numèriques

Variable	Mitjan a	Desv. Est.	Mín	Q1	Medi ana	Q3	Màx	Asimetria a	Kurtosis s	IQR
Hours_Studied	19.98	5.99	1.0	16.0	20.0	24.0	44.0	0.01	0.02	8.0
Attendance	79.98	11.55	60.0	70.0	80.0	90.0	100.0	0.01	-1.19	20.0
Sleep_Hours	7.03	1.47	4.0	6.0	7.0	8.0	10.0	-0.02	-0.5	2.0
Previous_Scores	75.07	14.4	50.0	63.0	75.0	88.0	100.0	-0.0	-1.19	25.0
Tutoring_Sessions	1.49	1.23	0.0	1.0	1.0	2.0	8.0	0.82	0.64	1.0
Physical_Activity	2.97	1.03	0.0	2.0	3.0	4.0	6.0	-0.03	-0.06	2.0
Exam_Score	67.24	3.89	55.0	65.0	67.0	69.0	101.0	1.64	10.58	4.0

Figura17: Taula dels estadístics descriptius de variables numèriques

Observacions clau sobre les distribucions:

- **Distribucions simètriques:** Hours_Studied, Attendance, Sleep_Hours, Previous_Scores i Physical_Activity presenten asimetria propera a 0, indicant distribucions equilibrades.
- **Tutoring_Sessions — asimetria positiva (0.82):** la majoria d'estudiants fan 0-2 sessions, amb una cua llarga cap a valors alts. Aquesta asimetria és natural ja que la tutoria és un recurs optatiu.
- **Exam_Score:** Distribució més concentrada. La gran majoria d'estudiants puntuen en un rang estret (55-75). La kurtosis extremadament alta indica una distribució altament concentrada en la mitjana, amb les cues molt aplanades suggerint valors atípics que requereixen d'atenció.

3.8.4. Anàlisi de la Variable Objectiu: dropout




Figura18: Gràfic de Barres i Piechart de la variable objectiu

El dataset presenta un desequilibri de classes 80/20: 5288 estudiants no abandonen (80.0%) davant de 1319 que sí ho fan (20.0%). El ràtio és de 4:1.

Implicacions per a l'IDSS:

- Amb un 20% de positius, el desequilibri és moderat però suficient per esbiaixar models que optimitzin accuracy. Un classificador trivial que predigui sempre "no dropout" ja obtindria un 80% d'accuracy, la qual cosa invalida aquesta mètrica.
- Serà necessari aplicar tècniques de balanceig (SMOTE o class weight) i avaluar amb recall, F1-score i AUC-ROC.
- El criteri de l'IDSS prioritza la detecció d'estudiants en risc (minimitzar falsos negatius), per tant el recall és la mètrica prioritària.

3.8.5 Anàlisi Univariant

3.8.5.1. Variables numèriques




Figura19: Gràfics de Barres de les variables numèriques

Interpretació de les distribucions:

- La majoria de variables numèriques (Hours_Studied, Attendance, Sleep_Hours, Previous_Scores, Physical_Activity) mostren distribucions uniformes o simètriques amb mitjana $\approx$ mediana.
- El perfil mitjà d'un estudiant estudia entre 15-25h setmanals, dorm entre 6-8h diàries, realitza activitat física de forma freqüent, no assisteix pràcticament a tutories i obté una puntuació al voltant 6-7.
- Attendance té un mínim del 60%, Previous_Scores de 50 en puntuació. Llindars mínims que criden l'atenció ja que podrien ser més amples.

3.8.5.2. Variables categòriques




Figura20: Gràfics de Barres de les variables categòriques

S'observa un cert desbalanceig en les variables ternàries, hi ha sempre un valor predominant a les gràfiques. En general l'estudiant té una motivació moderada, de classe mitja-baixa, que viu a prop del centre educatiu, predominant l'escola pública secundària i on predomina també pares amb educació d'escola secundària per part dels pares.

3.8.6. Anàlisi Bivariant (relació amb dropout)

Aquesta és la secció central de l'EDA. S'analitza la relació de cada variable amb la variable objectiu dropout mitjançant tests estadístics per distingir diferències reals de soroll aleatori.

3.8.6.1. Variables numèriques vs. dropout




Figura21: Violin plots: Variables numèriques vs dropout

Tests Mann-Whitney U (comparació no paramètrica degut a distribucions no normals):

Variable	Mitjana No drop.	Mitjana Dropout	Diferència	Dif. rel. (%)	p-value	Effect size	Signif.
Hours_Studied	21.11	15.44	5.67	26.8	4.90e-204	0.541	Si
Attendance	82.11	71.42	10.69	13.0	2.64e-199	0.535	Si
Sleep_Hours	7.02	7.07	-0.05	-0.7	0.3482	0.016	No
Previous_Scores	76.47	69.47	7.0	9.2	3.58e-56	0.281	Si
Tutoring_Sessions	1.5	1.45	0.05	3.4	0.2645	0.019	No
Physical_Activity	2.96	2.98	-0.01	-0.5	0.6227	0.008	No
Exam_Score	68.22	63.29	4.93	7.2	0.00e+00	0.809	Si

Figura22: Test Mann - Whitney U

Variables amb diferències SIGNIFICATIVES ($p < 0.001$):

- **Attendance:** Els estudiants que abandonen tenen ~10.7 punts menys d'assistència (71.42% vs 82.11%). Diferència relativa del 13%.
- **Hours_Studied:** Els que abandonen estudien ~5.7 hores menys (15.44h vs 21.11h). Diferència relativa del 27% — la més gran en termes relatius.
- **Previous_Scores:** Notes prèvies ~7 punts inferiors en el grup dropout.
- **Exam_Score:** ~5 punts menys en el grup dropout. Coherent amb el seu rol de variable de resultat acadèmic.

Variables SENSE diferència significativa ($p > 0.05$):

- **Sleep_Hours** ($p=0.3482$): Dormir més o menys no discrimina el dropout.
- **Tutoring_Sessions** ($p=0.2645$): El nombre de tutories no difereix entre grups.
- **Physical_Activity** ($p=0.6227$): L'activitat física no té cap relació amb l'abandonament.

Conclusió: Sleep_Hours, Tutoring_Sessions i Physical_Activity no aporten valor predictiu per al model IDSS. El perfil de risc es defineix per l'engagement acadèmic (hores d'estudi + assistència + notes prèvies).

3.8.6.2. Motivation_Level: El predictor dominant




Figura23: Taxa d'abandonament i Boxplot de Exam Score per Motivació i Dropout

Nivell de Motivació	N estudiants	N dropout	Taxa dropout (%)
Low	1937	885	45.7
Medium	3351	415	12.4
High	1319	19	1.4

Figura24: Resum en format taula de nivell de motivació

Test Chi-quadrat: $\chi^2 = 1206.00$, p-value = $1.32e-262$, Cramér's V = 0.4272

Motivation_Level és, amb diferència, la variable més discriminant de tot el dataset. La diferència entre motivació Low (45.7% de dropout) i High (1.4%) és de 44 punts percentuals. Un estudiant amb motivació baixa té un risc 32 vegades major d'abandonar que un amb motivació alta.

El Cramér's V de 0.43 indica una associació forta (molt per sobre del llindar de 0.3), convertint-la en el predictor individual més potent del dataset.

Implicació per l'IDSS: Un estudiant amb motivació baixa hauria d'activar automàticament el sistema d'intervenció.

3.8.6.3. Resta de variables categòriques vs. dropout




Figura25: Gràfics de la taxa de dropout per categoria

Tests Chi-quadrat per a totes les variables categòriques i binàries:

Variable	Chi²	p-value	g.ll.	Cramér's V	Signif.
Parental_Involvement	3.86	0.1450	2	0.0242	No
Access_to_Resources	1.38	0.5026	2	0.0144	No
Motivation_Level	1206.0	1.32e-262	2	0.4272	Sí
Family_Income	5.56	0.0622	2	0.029	No
Teacher_Quality	7.63	0.0220	2	0.034	Sí
School_Type	0.19	0.6671	1	0.0053	No
Peer_Influence	1.28	0.5283	2	0.0139	No
Parental_Education_Level	7.45	0.0241	2	0.0336	Sí
Distance_from_Home	0.96	0.6197	2	0.012	No
Extracurricular_Activities	2.8	0.0944	1	0.0206	No
Internet_Access	3.87	0.0493	1	0.0242	Sí
Learning_Disabilities	4.76	0.0291	1	0.0268	Sí
Gender	0.0	0.9958	1	0.0001	No

Figura26: Taula Resum del Test Chi-quadrat

Classificació de resultats:

→ **Associació FORTA ($V \geq 0.3$):** Únicament Motivation_Level ($V \approx 0.43$), ja analitzada a la secció anterior.

→ **Associació FEBLE però significativa ($p < 0.05$, $V < 0.05$):** Teacher_Quality ($V \approx 0.034$), Parental_Education_Level ($V \approx 0.034$), Internet_Access ($V \approx 0.024$) i Learning_Disabilities ($V \approx 0.027$). Estadísticament significatives però amb efectes pràctics negligibles ($V < 0.05$) i per tant desestimables.

→ **SENSE associació significativa ($p > 0.05$):** Parental_Involvement, Access_to_Resources, Family_Income, School_Type, Peer_Influence, Distance_from_Home, Gender i Extracurricular_Activities. Les taxes de dropout entre categories varien menys de 2 punts percentuals, no discriminen.

Conclusió: Fora de Motivation_Level, la resta de variables categòriques tenen un poder discriminatiu molt baix o nul. Factors com l'ingrés familiar, el tipus d'escola, la implicació parental o el gènere no mostren cap relació significativa amb el dropout.

3.8.6.4. Variables binàries vs. dropout




Figura27: Gràfics en relació a la variable dropout i les variables binàries

Les diferències de dropout entre categories de les variables binàries són mínimes: Internet_Access mostra la diferència més gran (23.4% vs 19.7%), però amb un $V=0.024$ l'efecte pràctic és negligible. Gender presenta taxes idèntiques (20.0% vs 19.9%, $V \approx 0.0001$). Cap d'aquestes variables justificaria una intervenció diferenciada en l'IDSS.

3.8.7. Anàlisi de Correlacions




Figura28: Matriu de correlacions

La matriu de correlacions mostra que la majoria de variables numèriques són independents entre si. Les excepcions notables són les correlacions amb dropout: Exam_Score ($r=-0.56$), Hours_Studied ($r=-0.38$) i Attendance ($r=-0.37$) mostren associacions moderades, mentre que la parella Attendance-Exam_Score ($r=0.67$) és la correlació interpredictor més alta del dataset.




Figura29: Gràfic de correlació Spearman amb dropout

Variable	Correlació Spearman	Interpretació
Exam_Score	-0.5625	Correlació negativa moderada-forta
Hours_Studied	-0.375	Correlació negativa moderada
Attendance	-0.3706	Correlació negativa moderada
Previous_Scores	-0.1943	Correlació negativa feble
Tutoring_Sessions	-0.0137	Sense correlació
Physical_Activity	0.0061	Sense correlació
Sleep_Hours	0.0115	Sense correlació

Figura30: Taula de la correlació Spearman

Interpretació:

- **Exam_Score** ($r = -0.56$): correlació negativa moderada-forta. A millor nota, menys abandonament. És la variable numèrica més correlacionada, però com a variable de resultat, pot no estar disponible per a predicció precoç.
- **Hours_Studied i Attendance** ($r \approx -0.37/-0.38$): correlació negativa moderada. Conformen, juntament amb Previous_Scores, el clúster d'engagement acadèmic.
- **Previous_Scores** ($r = -0.19$): correlació negativa feble. Les notes prèvies protegeixen, però menys del que s'esperaria.
- **Sleep_Hours, Tutoring_Sessions, Physical_Activity** ($r \approx 0$): tres variables que mesuren aspectes d'estil de vida que, en aquestes dades, no es relacionen amb l'abandonament.

3.8.8. Anàlisi de Components Principals (PCA)

El PCA s'ha aplicat sobre 5 variables numèriques predictores (Hours_Studied, Attendance, Sleep_Hours, Previous_Scores, Tutoring_Sessions) amb l'objectiu d'explorar l'estructura dimensional de les dades i detectar possibles redundàncies entre variables.


Variància explicada:

Figura31: Gràfics de les components principals del PCA

Variància explicada per component:

Component	Var. explicada (%)	Var. acumulada (%)
PC1	21.0	21.0
PC2	20.43	41.43
PC3	19.79	61.22
PC4	19.7	80.92
PC5	19.08	100.0

Figura32: Taula de la variància explicada per cada component

El resultat més rellevant del PCA és que les cinc components principals expliquen cadascuna un percentatge gairebé idèntic de la variància (~20%). Això indica que les variables originals són altament independents entre si: no existeixen dimensions latents dominants que capturin la variabilitat de múltiples variables simultàniament.

Confirma l'absència de multicolinealitat. Si les variables originals estiguessin fortament correlacionades, la primera component capturaria un percentatge molt superior de variància (>40-50%). El fet que sigui només del 21% confirma els resultats de la matriu de correlacions, on cap parell de predictors supera $|r|=0.5$.

No hi ha redundància. No podem reduir les 5 variables a 2-3 components sense perdre informació substancial. Les 5 variables aporten informació diferent i complementària.

Donat que no es pot reduir la dimensionalitat sense pèrdua d'informació, es recomana mantenir les variables originals en el model en lloc d'utilitzar les components principals.

3.8.9. Perfils d'Estudiants en Risc vs. Sense Risc

Variable	Mitjana No dropout	Mitjana Dropout	Diferència	Dif. (%)
Hours_Studied	21.11	15.44	5.67	26.8
Attendance	82.11	71.42	10.69	13.0
Sleep_Hours	7.02	7.07	-0.05	-0.7
Previous_Scores	76.47	69.47	7.0	9.2
Tutoring_Sessions	1.5	1.45	0.05	3.4
Physical_Activity	2.96	2.98	-0.01	-0.5
Exam_Score	68.22	63.29	4.93	7.2

Figura33: Taula comparativa de perfils d'Estudiants en Risc vs Sense Risc




Figura34: Gràfic comparatiu de No Dropout vs Dropout

Perfil de l'estudiant en risc d'abandonament:

- Estudia significativament menys (~15h vs ~21h, -27%).
- Assisteix menys a classe (~71% vs ~82%, -13%).
- Té un historial acadèmic inferior (notes prèvies ~69.5 vs ~76.5, -9%).
- Mostra una motivació predominantment baixa.
- Les variables d'estil de vida (son, exercici, tutories) NO diferencien els grups.

En resum, l'estudiant en risc es caracteritza per un patró de désengament acadèmic: menys dedicació, menys presència i menys rendiment previ, combinat amb una motivació baixa. Les variables contextuais (família, recursos, escola) no contribueixen a definir el perfil.

3.8.10. Interacció Motivació × Assistència




Figura35: Gràfic de Taxa d'Abandonament per Assistència i Motivació

El gràfic d'interacció revela un patró clau: la motivació actua com a moderador de l'efecte de l'assistència.

- **Motivació baixa:** Amb motivació Low, la taxa de dropout es manté alta (~40-50%) independentment del nivell d'assistència. Ni l'alta assistència protegeix un estudiant poc motivat.
- **Motivació mitjana:** la taxa decreix gradualment amb l'assistència, mostrant un patró protector progressiu.
- **Motivació alta:** la taxa és molt baixa en tots els nivells d'assistència.

Implicació: les intervencions de l>IDSS haurien de prioritzar la motivació sobre l'assistència. Forçar l'assistència sense abordar la motivació no reduirà l'abandonament.

3.8.11. Conclusions i Recomanacions

Nivell	Variable	Justificació
Alt	Motivation_Level	V=0.43, 45.7% vs 1.4% dropout
Alt	Hours_Studied	r=-0.38, diferència 27%
Alt	Attendance	r=-0.37, diferència 13%
Moderat	Previous_Scores	r=-0.19, p<0.001
Moderat	Exam_Score	r=-0.56, però és variable de resultat
Nul	Sleep_Hours	p=0.35, r≈0
Nul	Tutoring_Sessions	p=0.26, r≈0
Nul	Physical_Activity	p=0.62, r≈0
Nul	Parental_Involvement	p=0.14, V=0.024
Nul	Access_to_Resources	p=0.50, V=0.014
Nul	Family_Income	p=0.06, V=0.029
Nul	School_Type	p=0.67, V=0.005
Nul	Peer_Influence	p=0.53, V=0.014
Nul	Distance_from_Home	p=0.62, V=0.012
Marginal	Teacher_Quality	p=0.02, V=0.034
Marginal	Parental_Education_Level	p=0.02, V=0.034
Marginal	Internet_Access	p=0.05, V=0.024
Marginal	Learning_Disabilities	p=0.03, V=0.027

Figura36: Taula resum de conclusions i recomanacions

1. L'abandonament escolar està dominat per dos factors:

La motivació i el compromís acadèmic (hores d'estudi + assistència + notes prèvies) expliquen la pràctica totalitat de les diferències observades entre estudiants que abandonen i els que no.

2. Les variables socioeconòmiques i demogràfiques no discriminen:

Contràriament a la intuïció, factors com l'ingrés familiar, el tipus d'escola, la implicació parental o el gènere no mostren cap relació significativa amb l'abandonament. Això pot ser una limitació del dataset o indicar que, controlant per motivació i engagement, aquests factors perden importància.

3. Les variables d'estil de vida no aporten informació:

Sleep_Hours, Physical_Activity i Tutoring_Sessions no discriminen el dropout. Que les tutories no protegeixin contra l'abandonament és rellevant.

4. Motivation_Level és el predictor excepcional:

Amb un Cramér's V de 0.43, un estudiant amb motivació baixa té un 45.7% de risc vs 1.4% amb motivació alta.

5. L'efecte moderador de la motivació:

La motivació no només és un predictor directe sinó també un moderador: amb motivació baixa, ni l'assistència alta ni les hores d'estudi protegeixen l'estudiant.

6. Desequilibri de classes:

Ratio 80/20 (4:1). Desequilibri moderat que pot requerir tractament amb SMOTE o class_weight.

Mètriques d'avaluació: prioritzar recall i F1-score sobre accuracy.

Recomanacions per a la fase de modelatge

- **Variables a incloure:** Motivation_Level, Hours_Studied, Attendance, Previous_Scores. Opcionalment, Exam_Score si està disponible al moment de la predicció.
- **Variables a descartar:** Sleep_Hours, Physical_Activity, Tutoring_Sessions, Gender, School_Type, Distance_from_Home, Peer_Influence. No aporten informació i afegeixen soroll.
- **Encoding:** Motivation_Level amb codificació ordinal (Low=0, Medium=1, High=2) per respectar l'ordre natural. La resta de categòriques que es mantinguin, amb one-hot encoding.
- **Balanceig:** SMOTE o class weight per la naturalesa del criteri de l'IDSS.
- **Explicabilitat:** SHAP values per interpretar prediccions individuals, coherent amb l'arquitectura IDSS.

4. MODELS DEL SISTEMA

4.1. CLUSTERING JERÀRQUIC

4.1.1. Descripció

Per dur a terme aquest projecte i desenvolupar el Sistema Intel·ligent de Suport a la Decisió (IDSS), el clustering jeràrquic s'ha utilitzat com una eina clau per analitzar les dades dels estudiants i identificar perfils amb comportaments similars.

En aquest context, aquest mètode ens serveix per agrupar els estudiants de manera automàtica segons variables acadèmiques i socioeducatives, sense haver de definir prèviament categories com “bon estudiant” o “en risc”. Això permet descobrir patrons reals dins de les dades i entendre millor com es distribueixen els diferents perfils.

Concretament, dins del nostre sistema, el clustering ens ajuda a detectar grups d'estudiants amb característiques semblants en termes de rendiment, hàbits d'estudi i factors personals, cosa que és essencial per identificar possibles situacions de risc d'abandonament escolar.

A més, el fet de generar aquests perfils facilita la presa de decisions per part del sistema IDSS, ja que permet orientar millor les intervencions educatives, com ara reforç acadèmic o seguiment personalitzat, en funció del tipus d'estudiant.

Per fer-ho, s'ha utilitzat el mètode jeràrquic amb criteri de Ward, que permet obtenir grups interns homogenis i fàcilment interpretables, aspecte clau per a l'aplicació pràctica dins del context educatiu.

4.1.2. Implementació

Per implementar el clustering jeràrquic dins del sistema, s'han seguit diversos passos estructurats per garantir una correcta anàlisi de les dades.

En primer lloc, s'ha carregat el conjunt de dades i s'han seleccionat únicament les variables numèriques, ja que són les necessàries per calcular distàncies entre estudiants. Posteriorment, s'han escalat les dades mitjançant normalització per evitar que algunes variables tinguin més pes que altres.

A continuació, s'ha calculat la matriu de distàncies utilitzant la distància euclidiana, i s'ha aplicat l'algorisme de clustering jeràrquic amb el mètode de Ward (ward.D2), que permet obtenir grups interns homogenis.

Un cop aplicat el model, s'ha generat un **dendrograma**, que representa gràficament com es van agrupant els estudiants.




Figura37: Dendrograma del Clustering Jeràrquic

Aquest gràfic permet visualitzar l'estructura jeràrquica dels clusters i identificar possibles punts de tall per definir el nombre de grups. Per determinar el nombre òptim de clusters, s'ha utilitzat el **mètode del colze (Elbow method)**, que analitza la variabilitat interna dels grups en funció del nombre de clusters.




Figura38: Gràfic per utilitzar el mètode del colze

A partir del gràfic, s'observa que el punt on la millora comença a disminuir és al voltant de $k = 4$, que és el valor seleccionat. Un cop definit el nombre de clusters, s'ha assignat cada estudiant a un dels quatre grups obtinguts.

Finalment, per facilitar la interpretació dels resultats, s'ha aplicat una reducció de dimensionalitat mitjançant **Anàlisi de Components Principals (PCA)**, permetent representar els estudiants en un espai de dues dimensions.




Figura39: Clusters PCA

Aquesta visualització permet observar la distribució dels clusters i comprovar visualment la separació entre els diferents grups.

4.1.3. Resultats

L'aplicació del clustering jeràrquic ha permès segmentar el conjunt d'estudiants en **quatre grups diferenciats ($k = 4$)**, tal com s'ha determinat mitjançant el mètode del colze (*Figura38*).

La distribució dels estudiants entre els clusters és la següent:

- **Cluster 1:** 4417 estudiants
- **Cluster 2:** 1058 estudiants
- **Cluster 3:** 495 estudiants
- **Cluster 4:** 637 estudiants

Aquesta distribució mostra un clar predomini d'un dels grups, mentre que els altres dos representen subconjunts més específics dins de la població analitzada.

La visualització mitjançant PCA (*FIGURA 39*) permet observar una separació moderada entre els clusters, amb certa superposició entre alguns grups. Aquest comportament és habitual en dades reals i indica que, tot i existir una estructura interna, els límits entre grups no són completament definits.

Per validar la qualitat del clustering, s'ha calculat el coeficient de correlació cofenètica, obtenint un valor de **0.57**, que indica una qualitat moderada en la representació de les distàncies originals.

En conjunt, els resultats mostren que el model és capaç de detectar una estructura interna en les dades i segmentar els estudiants en grups diferenciats. La interpretació detallada d'aquests grups i la seva relació amb el risc d'abandonament es desenvolupa en l'apartat de següent apartat de profiling.

4.2. MODEL DE PROFILING

4.2.1. Descripció

Un cop obtinguts els clusters mitjançant el model de clustering jeràrquic, s'ha aplicat un model de *profiling* amb l'objectiu d'interpretar i caracteritzar els diferents grups d'estudiants identificats.

En el context d'aquest projecte, el *profiling* és essencial dins del sistema IDSS, ja que permet transformar els resultats del clustering en informació interpretable per a la presa de decisions educatives. Concretament, aquest model permet entendre quines variables defineixen cada cluster i identificar patrons associats al rendiment acadèmic i al risc d'abandonament.

Per aconseguir-ho, s'han utilitzat tècniques de visualització i resum estadístic que faciliten la comparació entre clusters i la detecció de diferències significatives.

4.2.2. Implementació

Per dur a terme el model de *profiling*, s'ha desenvolupat un procés complet orientat a caracteritzar en profunditat els clusters obtinguts prèviament amb el clustering jeràrquic. Aquest procés combina tècniques de visualització, resum estadístic i transformació de variables per facilitar la interpretació dels resultats.

En primer lloc, s'ha realitzat un **preprocessament de les dades**. Les variables qualitatives s'han convertit a factors per poder ser tractades adequadament en l'anàlisi. Posteriorment, s'han eliminat els missings per evitar distorsions en els càlculs. A continuació, s'han separat les variables en dos grups: variables numèriques i variables categòriques, ja que el tractament posterior és diferent en cada cas.

Un cop preparades les dades, s'ha reaplicat el clustering jeràrquic amb les mateixes condicions (distància euclidiana i mètode de Ward) per garantir la coherència amb l'anàlisi anterior i disposar de l'assignació de clusters dins del mateix entorn de treball. A partir d'aquí, s'ha iniciat l'anàlisi de *profiling* pròpiament dita.

En primer lloc, s'han generat els **Class Panel Graphs (CPG)**, que consisteixen en un conjunt de gràfics que mostren la distribució de cada variable separada per cluster. Per a les variables numèriques s'han utilitzat histogrames, mentre que per a les variables categòriques s'han utilitzat gràfics de barres. Aquesta representació permet observar visualment com es distribueixen els valors dins de cada grup i detectar diferències entre clusters.



Figura40: Class Panel Graph

A continuació, s'ha desenvolupat el **Traffic Light Panel (TLP)**, una eina de síntesi visual que resumeix el comportament de cada variable en cada cluster mitjançant un sistema de colors. Per construir aquest panell, primer s'ha calculat un valor representatiu per cada variable i cluster:

- Mitjana en el cas de variables numèriques
- Moda en el cas de variables categòriques

En el cas de les variables numèriques, els valors s'han discretitzat en tres nivells (baix, mitjà, alt) utilitzant percentils (33% i 66%) com a punts de tall. Això permet classificar cada variable dins de cada cluster en tres categories comparables.

A més, s'ha definit una **direcció de la variable**, és a dir, si un valor alt és positiu o negatiu. Aquesta decisió és clau per assignar correctament els colors:

- **Verd:** situació favorable
- **Groc:** situació intermèdia
- **Vermell:** situació desfavorable

En el cas de variables categòriques, s'ha definit manualment un mapping de colors segons el significat de cada categoria. Per exemple:

- *Learning_Disabilities*: "Yes" es considera desfavorable (vermell), mentre que "No" es considera favorable (verd)
- *Extracurricular_Activities*: participar es considera positiu (verd)
- *Gender*: es tracta com a variable neutra (groc)
- *School_Type*: s'ha simplificat la interpretació

Aquest procés permet construir el **Traffic Light Panel complet**, que mostra de manera global el comportament de totes les variables.




Figura41: Gràfic TLP

Posteriorment, s'ha generat una versió reduïda del TLP eliminant aquelles variables que no presenten variació entre clusters, amb l'objectiu de centrar l'anàlisi en les variables realment discriminants.




Figura42: Gràfic TLP versió reduïda

Finalment, s'ha construït el **Annotated Traffic Light Panel (aTLP)**, que amplia el TLP incorporant informació sobre la variabilitat interna de cada cluster. Per fer-ho, s'ha calculat el coeficient de variació (CV) per a cada variable numèrica dins de cada cluster.

Aquest valor s'ha normalitzat i s'ha utilitzat per ajustar la intensitat dels colors:

- Colors més intensos indiquen clusters més homogenis
- Colors més suaus indiquen més dispersió interna

Aquest enfocament permet no només identificar si una variable és favorable o desfavorable, sinó també valorar la consistència d'aquest comportament dins del cluster.




Figura43: Gràfic aTLP

Posteriorment, s'ha generat una versió reduïda del aTLP eliminant aquelles variables que no presenten variació entre clusters, amb l'objectiu de centrar l'anàlisi en les variables realment discriminants.




Figura44: Gràfic aTLP versió reduïda

En conjunt, aquest procés de *profiling* transforma els resultats del clustering en una representació visual clara, estructurada i interpretable, facilitant la seva aplicació pràctica dins del sistema IDSS.

4.2.3. Resultats

L'anàlisi conjunta del *Traffic Light Panel* (TLP) i del *Annotated Traffic Light Panel* (aTLP) ha permès obtenir una visió global i alhora detallada dels perfils d'estudiants identificats pel clustering jeràrquic. Mentre que el TLP facilita la identificació de patrons generals mitjançant el sistema de colors, l'aTLP aporta informació addicional sobre la consistència interna d'aquests patrons dins de cada cluster, incorporant la variabilitat de les dades.

A partir d'aquesta anàlisi, s'identifiquen **quatre perfils diferenciats d'estudiants**:

- En primer lloc, el **Cluster 1**, que agrupa la major part dels estudiants, es caracteritza per un predomini de valors intermedis (groc) en la majoria de variables. No obstant això, presenta alguns elements rellevants: valors favorables (verd) en variables com *Distance_from_Home*, *dropout* (indicant baixa probabilitat d'abandonament) i *Internet_Access*, però també valors desfavorables (vermell) en aspectes com *Parental_Education_Level* i *Physical_Activity*. Aquest patró reflecteix un perfil globalment equilibrat però amb certes debilitats específiques. A més, l'aTLP mostra una intensitat moderada-baixa, indicant una certa variabilitat interna i, per tant, un grup relativament heterogeni amb possibles casos de risc moderat.
- En segon lloc, el **Cluster 2** presenta una concentració clara de valors desfavorables (vermell) en variables clau. Destaca especialment el *dropout* en vermell, indicant una major tendència a l'abandonament, així com valors negatius en *Attendance*, *Exam_Score*, *Hours_Studied* i *Parental_Education_Level*. Tot i que hi ha alguns aspectes favorables com *Distance_from_Home* o *Internet_Access*, el patró global és clarament negatiu. L'aTLP mostra colors intensos, evidenciant una alta homogeneïtat interna. Per tant, aquest cluster es pot identificar clarament com el grup amb **major risc d'abandonament i pitjor situació acadèmica**.
- En tercer lloc, el **Cluster 3** mostra un perfil intermig amb una combinació de factors positius i negatius. Tot i tenir *dropout* en vermell (indicant risc d'abandonament), presenta valors favorables en variables com *Distance_from_Home*, *Internet_Access* i *Peer_Influence*. No obstant això, també incorpora valors desfavorables en *Family_Income* i altres variables acadèmiques. Aquest contrast indica un perfil amb certa inestabilitat, on conviuen factors protectors i factors de risc. L'aTLP reflecteix una variabilitat moderada, suggerint que es tracta d'un grup amb comportaments mixtos i que requereix seguiment específic.
- Finalment, el **Cluster 4**, tot i ser menys nombrós, mostra un patró generalment més favorable que la resta. El *dropout* apareix en vermell, indicant que encara existeix risc d'abandonament, però aquest cluster destaca per la presència de diversos valors positius com *Distance_from_Home*, *Internet_Access* i *Previous_Scores*. Tot i això, també presenta alguns factors negatius com *Parental_Education_Level* i altres variables puntuals. En conjunt, es pot interpretar com un perfil relativament favorable però no exempt de risc, amb una estructura més equilibrada que els clusters de major risc.

En conjunt, la combinació del *Traffic Light Panel* (TLP) i de l'*Annotated Traffic Light Panel* (aTLP) permet no només identificar quins factors són favorables o desfavorables en cada cluster, sinó també analitzar el grau de consistència interna d'aquests patrons. Aquesta doble perspectiva és especialment rellevant, ja que permet diferenciar entre grups homogenis i grups més heterogenis.

En conseqüència, els resultats del *profiling* confirmen l'existència de **quatre perfils principals d'estudiants**:

- Un perfil **favorable i relativament homogeni** (Cluster 1), amb presència destacada de valors positius i baixa tendència a l'abandonament, sent el grup que requereix **menor intervenció educativa**
- Un perfil **clarament de risc i homogeni** (Cluster 2), caracteritzat per una elevada concentració de factors desfavorables i major probabilitat d'abandonament
- Un perfil **intermig amb factors de risc específics** (Cluster 3), amb combinació d'elements favorables i desfavorables que requereixen seguiment
- Un perfil **intermig amb certes debilitats estructurals** (Cluster 4), amb predominança de valors neutres però amb alguns factors negatius que poden afectar el rendiment

Aquesta segmentació resulta especialment útil dins del sistema IDSS, ja que permet **prioritzar les intervencions educatives**, centrant els esforços en els clusters amb major risc (especialment el Cluster 2 i parcialment el Cluster 3), mentre que el Cluster 1 pot requerir únicament un seguiment general.

4.3. MODEL DE CLASSIFICACIÓ SUPERVISADA

4.3.1. Descripció

L'objectiu és desenvolupar un model de classificació supervisada capaç de predir l'abandonament escolar dels estudiants a partir de les seves característiques acadèmiques, socials i personals.

Aquest problema es planteja com una tasca de classificació binària, on la variable objectiu (*dropout*) indica si un estudiant abandona (1) o no (0). El dataset presenta un cert desbalanceig, amb aproximadament un 20% de casos d'abandonament, fet que fa necessari utilitzar mètriques adequades com el *recall* i el *F1-score* per avaluar el rendiment dels models.

Per tal d'identificar el model més adequat, s'han entrenat i comparat diversos algoritmes de classificació:

- Regressió Logística
- Multilayer Perceptron (MLP)
- XGBoost

L'objectiu no només és obtenir un model amb alta capacitat predictiva, sinó també analitzar quines variables tenen més influència en l'abandonament escolar.

4.3.2. Implementació

Els models s'han implementat en Python utilitzant principalment la llibreria *scikit-learn*, així com *XGBoost* per al model de boosting avançat.

Prèviament, les dades ja havien estat preprocessades, incloent la transformació de variables categòriques en variables numèriques mitjançant *one-hot encoding*. Per tant, en aquesta fase només s'ha realitzat la separació en conjunt d'entrenament i test (80%-20%), mantenint la proporció de la variable objectiu mitjançant *stratified sampling*.

S'han entrenat tots els models utilitzant els mateixos conjunts de dades per garantir una comparació justa. Per a l'avaluació, s'han utilitzat les següents mètriques:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-score**
- **ROC-AUC**

A més, s'han analitzat les matrius de confusió per entendre el comportament dels models i identificar errors com falsos positius i falsos negatius.

4.3.3. Resultats

Els resultats mostren diferències significatives entre els models analitzats.

Els tres models amb millor rendiment segons el *F1-score* han estat:

- **XGBoost (0.9509)**
- **MLP (0.9488)**
- **Regressió Logística (0.9429)**

El model XGBoost presenta el millor rendiment global, amb un excel·lent equilibri entre *precision* (0.947) i *recall* (0.954), així com un valor molt elevat de *ROC-AUC* (0.998). Això indica una gran capacitat per discriminar entre estudiants que abandonaran i els que no.

El model MLP obté resultats molt similars, demostrant la seva capacitat per capturar relacions complexes entre variables. No obstant això, presenta l'inconvenient de ser menys interpretable.

Per altra banda, la regressió logística destaca especialment pel seu *recall* perfecte (1.0), la qual cosa implica que detecta tots els casos d'abandonament. Tot i que genera alguns falsos positius, aquest comportament pot ser desitjable en contextos educatius, on és preferible identificar tots els alumnes en risc encara que això impliqui un cert nombre d'errors.

Els models com KNN i SVM han mostrat un rendiment inferior, probablement degut a la manca d'escalat de variables i a la naturalesa del dataset. El Decision Tree, tot i tenir un *recall* elevat, presenta menor precisió, mentre que Random Forest mostra una alta precisió però menor capacitat per detectar tots els casos d'abandonament.

4.3.4 Anàlisi de variables

L'anàlisi de la importància de variables revela resultats consistents entre diferents models:

- **Exam_Score** és la variable més rellevant en tots els models basats en arbres
- **Motivation_Level** (especialment nivell baix) té un impacte molt elevat en l'abandonament
- **Hours_Studied** i **Attendance** mostren una forta relació negativa amb l'abandonament
- **Previous_Scores** també té un paper important

Altres variables rellevants inclouen:

- **Tutoring_Sessions**
- **Access_to_Resources**
- **Parental_Involvement**
- **Distance_from_Home**
- **Teacher_Quality**

Aquests resultats indiquen que l'abandonament escolar està fortament relacionat amb el rendiment acadèmic, la motivació i el grau de compromís de l'estudiant.

4.3.5 Conclusions classificació supervisada

Els models basats en boosting, especialment XGBoost, ofereixen el millor rendiment global per a la predicció de l'abandonament escolar. No obstant això, la regressió logística destaca per la seva interpretabilitat i la seva capacitat de detectar tots els casos de risc.

En termes de factors determinants, es confirma que el rendiment acadèmic, la motivació i la implicació de l'estudiant són els principals indicadors d'abandonament, fet que pot ser de gran utilitat per a la detecció precoç i la implementació de mesures preventives en l'àmbit educatiu.

4.4. MOTOR D'EXPLICABILITAT

Per completar el sistema, s'ha incorporat un motor d'explicabilitat amb l'objectiu d'interpretar les prediccions del model supervisat final. Aquesta part és important dins de l'IDSS perquè no només interessa saber si un estudiant està en risc, sinó també entendre quins factors han fet que el model prengui aquesta decisió. Això permet que tutors i orientadors puguin justificar millor les intervencions i confiar més en el sistema.

4.4.1. Descripció

El motor d'explicabilitat s'ha construït sobre el model XGBoost, que és el que ha obtingut el millor rendiment en la classificació supervisada. Per interpretar-lo, s'ha utilitzat la tècnica SHAP, que permet explicar la contribució de cada variable a la predicció.

Aquesta explicabilitat s'ha treballat en dos nivells:

- **Global**, per veure quines variables són les més importants en el conjunt del model.
- **Local**, per entendre per què un estudiant concret ha estat classificat com a risc alt o baix.

D'aquesta manera, el sistema no només prediu, sinó que també mostra els principals factors que expliquen el risc acadèmic.

4.4.2. Implementació

La implementació s'ha fet en Python a partir de la base de dades preprocessada. Igual que en la classificació supervisada, s'han separat les dades en entrenament i test, i les variables categòriques s'han codificat amb one-hot encoding.

Després d'entrenar el model XGBoost, s'ha aplicat SHAP per obtenir:

- la importància global de les variables,
- un resum visual del seu impacte,
- i explicacions individuals per a diferents casos.

Per a la part local, s'han seleccionat tres estudiants representatius:

- un cas de **risc alt**,
- un cas **intermedi o borderline**,
- i un cas de **risc baix**.

Això permet mostrar com varia l'explicació segons el perfil de l'estudiant.

4.4.3. Resultats

Els resultats mostren que el model XGBoost, a més de tenir un rendiment molt alt, també es pot interpretar de manera coherent. Les mètriques finals han estat:

- **Accuracy:** 0.9796
- **Precision:** 0.9472
- **Recall:** 0.9508
- **F1-score:** 0.9490
- **ROC-AUC:** 0.9981




Figura45: Matriu de Confusió - XGBoost

Pel que fa a les variables més importants, tant la importància interna del model com l'anàlisi amb SHAP mostren resultats consistents. Les variables amb més pes són principalment:

- Exam_Score
- Motivation_Level_Low
- Motivation_Level_Medium
- Hours_Studied
- Attendance
- Previous_Scores




Figura46: Gràfic Shap Global amb la importància mitjana absoluta

Això confirma que el risc d'abandonament està molt relacionat amb el rendiment acadèmic, la motivació i el compromís de l'estudiant.

Les explicacions locals també són coherents. En el cas d'alt risc, la predicció s'explica sobretot per una combinació de nota baixa, motivació baixa, poques hores d'estudi i assistència reduïda. En canvi, en el cas de baix risc, el model es recolza en factors protectors com més hores d'estudi, millor historial acadèmic i millor assistència.

En conjunt, el motor d'explicabilitat aporta una capa addicional molt útil dins del sistema, ja que transforma una predicció automàtica en una decisió interpretable i més fàcil d'utilitzar en un context educatiu.

4.4.4. Conclusions

En conjunt, el motor d'explicabilitat confirma que el model XGBoost pren decisions coherents i interpretables. Els principals factors associats al risc d'abandonament són sobretot Exam_Score, Motivation_Level, Hours_Studied, Attendance i Previous_Scores.

Les explicacions locals mostren també un patró clar: els estudiants amb més risc solen combinar pitjors notes, menor motivació, menys hores d'estudi i menor assistència, mentre que els casos de baix risc presenten el patró contrari.

Hem observat també que factors com la motivació o l'assistència son més importants fins i tot que la nota de l'examen, cosa que ens porta a pensar que molts cops l'abandonament té més a veure amb la mentalitat i dedicació que amb el resultat o nota real de l'examen.

Per tant, aquest mòdul aporta valor a l'IDSS perquè permet entendre millor les prediccions del sistema i facilita una presa de decisions més justificada en l'àmbit educatiu.

4.5. INTERVENTION IMPACT ANALYSIS

4.5.1. Plantejament Inicial i Evolució del Disseny de Recerca

L'objectiu conceptual d'aquesta línia d'investigació consistia a dissenyar un sistema d'anàlisi dinàmic i longitudinal per fer el seguiment de la trajectòria del risc d'abandonament escolar (*dropout*). En lloc de concebre la predicció com un indicador estàtic o una "foto fixa" d'un moment puntual del curs, es pretenia estructurar una plataforma capaç de avaluar seqüencialment la informació en intervals semestral. Aquest enfocament temporal havia de permetre capturar les fluctuacions en variables altament crítiques com el rendiment en els exàmens (*Exam_Score*) o el component motivacional de l'estudiant (*Motivation_Level*).

Sota aquest paradigma, el sistema transcendia la simple funció predictiva per esdevenir un registre històric actiu de polítiques acadèmiques. Cada actualització de dades portava associada una traça clara de les mesures d'acompanyament aplicades (com hores de reforç o tutories adaptades), verificant-ne l'impacte directe en la mitigació de la vulnerabilitat de l'alumne.

No obstant això, durant el desenvolupament es va constatar que el desplegament d'aquesta infraestructura de traces contínues en temps real requeria un volum de recursos i una complexitat tècnica que excedien l'abast i el calendari del projecte. Davant d'això, es va optar per una solució més pragmàtica i perfectament viable: validar la hipòtesi de l'impacte de les intervencions mitjançant un disseny analític basat en simulacions de seguiment a mitjà termini, el qual s'ha materialitzat en el mòdul **Anàlisi de l'Impacte de la Intervenció** (*Intervention Impact Analysis*).

4.5.2. Implementació

En primer lloc, es realitza un bolcat i actualització de l'històric de dades d'aquells alumnes que han rebut accions correctives, registrant els nous indicadors postintervenció. En el nostre cas, degut a no tenir accés als alumnes que conformaven la nostra base de dades, vam decidir generar dades sintètiques alterant mínimament els valors de l'alumnat que havia rebut intervencions. Tot i no ser la situació idíl·lica, era la única opció factible dintre de les plantejades.

Posteriorment, amb la informació ja actualitzada, s'aplica exactament el mateix sistema de classificació supervisat que es va emprar sis mesos enrere (el qual va determinar que aquests alumnes presentaven un risc considerable d'abandonament). Això permet contrastar l'evolució del risc abans i després de l'acció tutorial.

A continuació, es presenten les visualitzacions gràfiques que il·lustren el comportament del model i l'evolució de l'alumnat:



Figura47: Gràfics del Intervention Impact Analysis

4.5.3. Conclusions

Si bé la naturalesa i l'abast original de l'*Intervention-Based Learning* van haver de ser replantejats perquè excedien els objectius reals del projecte, atès que la seva implementació hauria requerit el desenvolupament integral d'un nou Sistema Intel·ligent de Suport a les Decisions (IDSS), la solució alternativa ha demostrat una gran solidesa.

L'anàlisi a mitjà termini obtinguda no només valida l'efectivitat de les mesures aplicades, sinó que esdevé una eina robusta per detectar anomalies en el comportament del mateix model predictiu. Així mateix, s'ha consolidat com un instrument de gran utilitat per comparar i auditar l'eficiència de la plataforma en funció de la tipologia de cada centre escolar.

5. REPRESENTACIÓ DEL CONEIXEMENT

En el nostre sistema intel·ligent de suport a la decisió per a la detecció del risc d'abandonament escolar, la representació del coneixement s'ha implementat principalment mitjançant un sistema **Case-Based Reasoning (CBR)** combinat amb una **base de regles de producció**. Aquesta combinació permet que el sistema no només predigui el risc d'un nou estudiant, sinó que també justifiqui la decisió a partir de casos similars i proposi intervencions educatives concretes.

El sistema utilitza com a coneixement principal l'experiència acumulada en una base de casos d'estudiants històrics. Cada cas representa un estudiant amb diferents variables acadèmiques, personals i contextuais, juntament amb l'etiqueta final d'abandonament o no abandonament. Quan arriba un nou estudiant, el sistema busca els casos més semblants, reutilitza la informació dels casos recuperats, adapta la solució al perfil concret de l'estudiant i, si es confirma posteriorment el resultat real, pot incorporar aquest nou cas a la base de coneixement.

Aquesta estructura segueix el cicle clàssic de les **4R del CBR**:

- **Retrieve**, recuperació dels casos més similars.
- **Reuse**, reutilització dels casos per estimar el risc.
- **Revise**, revisió i adaptació de la solució mitjançant regles d'intervenció.
- **Retain**, retenció del nou cas si aporta coneixement nou al sistema.

5.1. FORMALISME UTILITZAT

El formalisme principal utilitzat és el **Case-Based Reasoning (CBR)**. Aquest enfocament representa el coneixement a partir de casos previs, de manera que el sistema pot raonar per analogia: si un nou estudiant s'assembla molt a estudiants anteriors que van abandonar, el sistema pot inferir que també presenta un risc elevat.

Cada cas està format per un conjunt de variables que descriuen el perfil de l'estudiant. Aquestes variables inclouen aspectes acadèmics, com l'assistència, les hores d'estudi, les notes anteriors i la nota d'examen; aspectes personals, com el nivell de motivació, les hores de son o l'activitat física; i aspectes contextuais, com els recursos disponibles, la implicació familiar, els ingressos familiars, la qualitat docent o la influència dels companys. A més del CBR, el sistema incorpora una **base de regles de producció** en la fase de revisió. Aquestes regles tenen la forma: "*Si es compleix una condició del perfil de l'estudiant → recomanar una intervenció*".

Per exemple, si l'estudiant té un nivell de motivació baix, el sistema recomana una tutoria motivacional. Si l'assistència és inferior al 75%, recomana un seguiment específic d'assistència. Això permet transformar la predicció del risc en recomanacions accionables per a l'orientador o el tutor.

Per tant, el sistema combina dos tipus de coneixement:

“Coneixement basat en casos històrics + Coneixement expert basat en regles”

Aquesta combinació aporta més valor que una predicció numèrica aïllada, ja que permet obtenir una explicació del resultat i generar accions concretes.

5.2. ESTRUCTURA PRINCIPAL

L'estructura principal de la base de coneixement està organitzada al voltant dels diferents fitxers del sistema CBR. Cada fitxer representa una part concreta del cicle de raonament.

El fitxer *cbr_case.py* defineix l'esquema dels casos. En aquest fitxer s'estableixen les variables que formen part de cada estudiant, el pes de cada variable i la funció de similitud corresponent. Els pesos indiquen la importància relativa de cada característica dins del càlcul global de similitud. Per exemple, variables com *Attendance*, *Exam_Score*, *Hours_Studied* i *Motivation_Level* tenen pesos elevats perquè són factors especialment rellevants en el risc d'abandonament.

Les variables es classifiquen en tres tipus principals. Les variables numèriques, com l'assistència o les notes, es comparen mitjançant una normalització Min-Max. Les variables ordinals, com el nivell de motivació o l'accés a recursos, es transformen en valors entre 0 i 1 segons un mapa ordinal. Finalment, les variables binàries, com les dificultats d'aprenentatge, es comparen segons si els valors coincideixen o no.

La similitud global entre un nou estudiant i un cas històric es calcula de manera ponderada:

$$sim(q, c) = \sum \frac{pes_i \cdot similitud_i(q_i, c_i)}{\sum pes_i}$$

Això significa que no totes les variables tenen el mateix impacte. Les variables més importants tenen més influència en el resultat final de similitud.

→ El fitxer *cbr_retrieve.py* implementa la fase de recuperació. Aquest mòdul carrega el fitxer *student_preprocessed.csv* i converteix cada fila del dataset en un cas de la base de coneixement. A cada cas se li assigna un identificador intern, com STU-0001, per garantir la traçabilitat. Després, per a un nou estudiant, calcula la similitud amb tots els casos existents i retorna els top_k casos més semblants.

→ El fitxer ***cbr_reuse.py*** implementa la fase de reutilització. A partir dels casos recuperats, calcula la probabilitat estimada d'abandonament combinant dues fonts d'evidència. D'una banda, utilitza la proporció ponderada de casos similars que van abandonar. De l'altra, calcula una puntuació de risc pròpia, coherent amb la funció `calculateRisk()` del dashboard. Aquesta combinació evita que el resultat depengui únicament dels veïns recuperats i permet que el perfil concret del nou estudiant tingui pes en la predicció final.

→ El fitxer ***cbr_revise.py*** implementa la fase de revisió. Aquesta fase aplica una base de regles d'intervenció al perfil del nou estudiant. Les regles detecten condicions concretes de risc, com baixa motivació, baixa assistència, poques hores d'estudi, manca de recursos o baixa implicació familiar, i les converteixen en recomanacions educatives.

→ El fitxer ***cbr_retain.py*** implementa la fase de retenció. Aquesta fase decideix si el nou cas s'ha d'incorporar a la base de casos un cop es coneix l'etiqueta real d'abandonament. El sistema només incorpora el cas si l'etiqueta real està confirmada i si el cas no és massa similar a casos ja existents. Això evita duplicats i permet que la base de coneixement creixi amb informació realment útil.

→ Finalment, el fitxer ***cbr_main.py*** actua com a orquestrador del sistema. Executa el pipeline principal, connectant les fases de recuperació, reutilització i revisió, i mostra els resultats de forma llegible per a la seva integració amb el dashboard del sistema IDSS.

5.3. FONTS DE CONEIXEMENT

Les fonts de coneixement del sistema provenen de diferents elements. La primera font és el dataset preprocessat d'estudiants, emmagatzemat en el fitxer ***student_preprocessed.csv***. Aquest dataset constitueix la base de casos inicial. Cada fila representa un estudiant i conté les variables utilitzades per descriure el seu perfil, així com l'etiqueta final dropout, que indica si l'estudiant abandona o no.

La segona font de coneixement són els pesos assignats a cada variable. Aquests pesos provenen de la importància de les variables segons el model XGBoost i de la lògica definida a la funció ***calculateRisk()*** del dashboard. Això permet connectar el coneixement estadístic dels models predictius amb el sistema de raonament basat en casos.

La tercera font de coneixement són les regles d'intervenció definides a ***cbr_revise.py***. Aquestes regles representen coneixement expert sobre quines accions educatives poden ser adequades segons el perfil de risc de l'estudiant. Per exemple, una baixa assistència activa una intervenció de seguiment d'assistència, mentre que una baixa motivació activa una tutoria motivacional.

La quarta font de coneixement és la validació humana o institucional que es pot incorporar mitjançant la fase **Retain**. Quan un orientador, tutor o sistema de seguiment confirma si un estudiant ha abandonat o no, aquesta informació es pot afegir a la base de casos. D'aquesta manera, el sistema pot aprendre progressivament de nous casos reals.

Per tant, el coneixement del sistema no prové d'una única font, sinó de la combinació de dades històriques, models predictius, criteris experts i validació posterior dels resultats.

5.4. ROL DINS DEL SISTEMA

El rol de la base de coneixement dins del sistema és actuar com una capa intermèdia entre els models predictius i el dashboard final. El sistema no es limita a mostrar una predicció generada per un model de machine learning, sinó que afegeix una capa de raonament que permet interpretar millor el resultat i proposar accions concretes.

Quan s'introdueix un nou estudiant, el CBR compara el seu perfil amb els casos històrics. Això permet justificar la predicció amb una idea intuïtiva: "aquest estudiant s'assembla a altres estudiants que en el passat van presentar aquest comportament". Aquesta aproximació és especialment útil en un sistema de suport a la decisió, perquè facilita la confiança dels usuaris en el resultat.

A més, el sistema calcula una probabilitat estimada d'abandonament, una puntuació de risc i un nivell de risc classificat com a baix, mitjà o alt. Aquesta informació ajuda l'orientador o responsable acadèmic a prioritzar els estudiants que necessiten més atenció.

La fase de revisió transforma el resultat en recomanacions pràctiques. Això és molt important perquè l'objectiu del sistema no és només detectar risc, sinó també donar suport a la presa de decisions. Per exemple, si el sistema detecta un risc alt associat a baixa assistència i baixa motivació, no només informa del risc, sinó que recomana intervencions com seguiment d'assistència i tutoria motivacional.

Per tant, la representació del coneixement té tres funcions principals dins del sistema:

Explicar el risc detectat

Justificar-lo amb casos similars

Proposar intervencions adaptades al perfil de l'estudiant.

Això converteix el sistema en un veritable IDSS i no només en un classificador predictiu.

5.5. SORTIDES I VALIDACIÓ

Les sortides principals del sistema CBR són diverses. En primer lloc, el sistema retorna els casos més similars de la base de coneixement. Per a cada cas recuperat, s'indica el seu identificador, la similitud amb el nou estudiant, si va abandonar o no, i alguns valors rellevants com la motivació, l'assistència o les hores d'estudi.

En segon lloc, el sistema genera una predicció estructurada que inclou la probabilitat estimada d'abandonament, la puntuació de risc en una escala de 0 a 100, el nivell de risc i la similitud màxima amb la base de casos. Aquestes sortides permeten interpretar de manera quantitativa el risc de l'estudiant.

En tercer lloc, el sistema identifica els factors de risc més rellevants. Aquesta part és important per a l'explicabilitat, ja que mostra quines variables contribueixen més al risc detectat. Per exemple, el sistema pot destacar una baixa assistència, poques hores d'estudi o una motivació baixa com a factors principals.

En quart lloc, el sistema genera intervencions recomanades. Aquestes intervencions estan definides en el catàleg de regles i s'adapten al perfil concret de l'estudiant. Les intervencions poden incloure tutoria motivacional, seguiment d'assistència, reforç acadèmic, suport en recursos educatius, implicació familiar o gestió de la influència entre iguals.

Finalment, el sistema proporciona un missatge d'urgència segons el nivell de risc. Si el risc és alt, recomana una intervenció prioritària en les pròximes 48 hores. Si el risc és mitjà, recomana un seguiment preventiu en les pròximes dues setmanes. Si el risc és baix, recomana una monitorització ordinària.

La validació del sistema es pot fer a diferents nivells. En primer lloc, es pot validar la fase de recuperació comprovant que els casos retornats siguin realment similars al nou estudiant i que la funció de similitud funcioni correctament per a variables numèriques, ordinals i binàries. En segon lloc, es pot validar la fase de reutilització comparant la probabilitat estimada i el nivell de risc amb les etiquetes reals d'un conjunt de test. En tercer lloc, es pot validar la fase de revisió revisant si les intervencions recomanades són coherents amb el perfil de l'estudiant i amb el criteri d'experts educatius.

També es pot validar la fase de retenció comprovant que només s'incorporen nous casos quan tenen una etiqueta real confirmada i quan aporten informació nova a la base de coneixement. Això és important per evitar que el sistema acumuli casos duplicats o poc fiables.

En conjunt, la validació ha de comprovar tant la part quantitativa del sistema, és a dir, la qualitat de la predicció, com la part qualitativa, és a dir, la utilitat i coherència de les recomanacions generades.

5.6. INTEGRACIÓ EN L'ARQUITECTURA

La base de coneixement s'integra dins l'arquitectura general del sistema com una capa de raonament situada entre les dades preprocessades, els models predictius i el dashboard final.

Inicialment, el sistema carrega el fitxer *student_preprocessed.csv*, que conté les dades dels estudiants ja preprocessades. Aquest fitxer serveix com a base de casos inicial. Quan arriba un nou estudiant, el sistema calcula la similitud entre aquest nou perfil i tots els casos de la base.

Després, la fase **Retrieve** selecciona els casos més semblants. La fase Reuse utilitza aquests casos per calcular la probabilitat d'abandonament i el nivell de risc. Aquesta fase també manté coherència amb el dashboard perquè replica la lògica de càlcul de risc definida a *calculateRisk()*.

A continuació, la fase **Revise** aplica les regles d'intervenció. Aquesta fase és la que converteix la sortida predictiva en una recomanació útil per a l'usuari final. Les recomanacions generades poden ser mostrades directament al dashboard, juntament amb el nivell de risc, la probabilitat d'abandonament i els casos similars.

Finalment, la fase **Retain** permet actualitzar la base de coneixement quan es disposa de l'etiqueta real confirmada. Aquesta fase és especialment important perquè permet que el sistema millori progressivament amb nous casos reals. Si un nou estudiant presenta un perfil diferent dels casos ja existents i es confirma posteriorment si ha abandonat o no, el sistema pot afegir-lo a la base de casos.

D'aquesta manera, la representació del coneixement no és un component aïllat, sinó que està completament integrada dins del funcionament del sistema IDSS. Connecta les dades històriques amb la predicció, l'explicació i la recomanació d'accions, aportant valor tant a nivell tècnic com a nivell de presa de decisions educatives.

6. COMPONENTS DE RAONAMENT

Els components de raonament són els elements del sistema encarregats de transformar les sortides dels models en informació útil per a la presa de decisions. En el nostre IDSS, aquests components no només mostren una predicció numèrica del risc d'abandonament, sinó que interpreten aquest resultat, l'expliquen i el connecten amb possibles accions d'intervenció.

En primer lloc, el sistema incorpora un component de raonament basat en **perfils d'estudiants**, derivat del clustering i profiling. Aquest component permet comparar un nou alumne amb els perfils identificats prèviament i assignar-lo al grup que presenta característiques més similars. D'aquesta manera, el sistema no analitza l'estudiant de manera aïllada, sinó dins d'un patró general de comportament acadèmic i contextual.

En segon lloc, hi ha un component de raonament predictiu basat en el **model de classificació supervisada**. Aquest model estima el nivell de risc d'abandonament de cada alumne a partir de variables com l'assistència, les hores d'estudi, la motivació, el resultat de l'examen i altres factors personals o acadèmics. La seva funció dins del sistema és proporcionar una primera alerta sobre possibles casos de risc.

A continuació, el sistema incorpora un component d'**explicabilitat**, que permet interpretar els factors que han influït més en la predicció. Aquest component és important perquè evita que el model funcioni com una "caixa negra" i ajuda l'usuari a entendre per què un estudiant ha estat classificat amb un determinat nivell de risc. Això incrementa la confiança en el sistema i facilita una presa de decisions més informada.

Finalment, el component d' **Intervention Impact analysis** actua com a motor de recomanació. A partir del perfil de l'alumne, del nivell de risc i dels factors explicatius detectats, el sistema proposa accions d'intervenció adequades, com ara tutoria motivacional, seguiment acadèmic, monitorització ordinària o altres mesures de suport. Aquest component connecta directament l'anàlisi de dades amb l'acció educativa.

Integració dins l'arquitectura general

Dins de l'arquitectura de l'IDSS, els components de raonament se situen entre els models analítics i la interfície final del sistema. Primer, les dades dels estudiants són processades pels models de clustering, classificació i explicabilitat. Després, els components de raonament combinen aquestes sortides per generar una interpretació global del cas.

Aquesta interpretació és finalment enviada al dashboard, on l'usuari pot consultar el perfil assignat, el risc estimat, els factors principals que expliquen la situació de l'alumne i la intervenció recomanada. Per tant, aquests components tenen un paper clau dins del sistema, ja que converteixen els resultats tècnics dels models en coneixement aplicable i comprensible per donar suport a la presa de decisions.

7. VALIDACIÓ

7.1. ENQUESTA REALITZADA

Per tal de complementar la validació del sistema amb un cas més proper a un entorn real, es va dissenyar i distribuir una enquesta mitjançant Google Forms adreçada a persones conegudes.

L'objectiu principal d'aquesta enquesta era obtenir un petit conjunt de dades externes que permetés provar el funcionament de l'IDSS fora del dataset original utilitzat durant el desenvolupament del projecte.

L'enquesta es va plantejar seguint l'estructura general de la base de dades principal, recollint informació acadèmica, contextual i socioeducativa dels participants. D'aquesta manera, es buscava generar respostes comparables amb les variables del dataset original, de manera que posteriorment poguessin ser introduïdes dins del flux normal del sistema i utilitzades en la fase de validació.

A diferència de la base original, que provenia d'una font externa estructurada, aquesta nova base s'ha obtingut directament a partir de respostes reals. Això aporta valor al projecte perquè permet analitzar com es comporta el sistema davant dades recollides en un context més natural, amb possibles diferències de format, escala o manera de respondre. Per tant, aquesta enquesta no només serveix com a conjunt de proves, sinó també com una primera aproximació a un possible escenari d'ús real del sistema.

Un cop obtingudes les respostes, aquestes es van descarregar en format tabular i es van tractar com una nova font d'entrada per a l'IDSS. A partir d'aquí, es va iniciar una fase específica de preprocessament amb l'objectiu d'adaptar-les a l'estructura i al format de la base principal del projecte. Aquest enfocament és coherent amb el flux general del sistema, que preveu la incorporació de noves dades i el seu tractament abans de passar als models de classificació, explicabilitat i validació.

7.2. PREPROCESSAMENT DELS RESULTATS

Un cop descarregades les respostes de l'enquesta, es va dur a terme un preprocessament específic per transformar aquesta nova base en un conjunt de dades compatible amb el dataset principal del projecte. L'objectiu no era tornar a fer un preprocessament complet des de zero, sinó adaptar els resultats del formulari perquè poguessin entrar correctament al dashboard i ser processats pels mateixos models del sistema.

En primer lloc, es va revisar l'estructura general de la base obtinguda a partir del formulari i es van ajustar els noms de les variables per fer-los coincidir exactament amb els de la base original. Aquest pas era necessari perquè els models entrenats ja esperen una estructura concreta d'entrada, tant pel que fa als noms de les columnes com al tipus de valors associats a cadascuna.

En segon lloc, es van harmonitzar les categories i formats de resposta. Això va incloure, entre altres aspectes, la normalització de valors textuais, la conversió de certes respostes al format original i l'estandardització de les variables binàries al mateix estil que el dataset principal. En aquest punt es va prendre com a referència la base original del projecte, de manera que la nova base de validació mantingués el màxim grau de coherència possible amb les dades sobre les quals s'havien entrenat els models.

Un dels ajustos més rellevants va ser el tractament de la variable **Hours_Studied**. Es va detectar que en el formulari aquesta variable s'havia respost en hores diàries, mentre que a la base original corresponia a una escala més compatible amb hores setmanals. Per evitar incoherències importants en la predicció, es va adaptar aquesta variable a una escala equivalent a la del dataset principal. Aquesta correcció era especialment important, ja que es tracta d'una de les variables amb més pes en els models de classificació i també en el motor d'explicabilitat.

Finalment, es va generar una base de validació final ja preprocesada i preparada per ser utilitzada dins de la interfície del sistema. Aquesta base conserva l'estructura del dataset principal, manté la coherència semàntica de les variables i permet aplicar directament els models del projecte sobre dades recollides externament. En conseqüència, aquest preprocessament actua com un pont entre la recollida manual de dades i la seva aplicació efectiva dins del flux normal de l'IDSS, de manera coherent amb el paper del mòdul de preprocessament dins de l'arquitectura general del sistema.

7.3. APLICACIÓ AL IDSS - VALIDACIÓ

En aquest apartat es presenta la validació dels diferents components del nostre IDSS a partir de les respostes obtingudes en les enquestes. L'objectiu és comprovar si els resultats generats pels models són comprensibles, útils i coherents per donar suport a la presa de decisions.

La validació s'estructura en quatre blocs: el **clustering i profiling**, el **model de classificació supervisada**, el **model d'explicabilitat** i l'**Intervention Impact Analysis**. Per a cada component s'analitzen les respostes dels participants per valorar-ne la utilitat, la confiança i l'aplicabilitat dins del sistema.

7.3.1. Clustering i Profiling

Per validar el component de **clustering i profiling**, s'ha comprovat si els nous alumnes introduïts a la fase de validació quedaven assignats al perfil que els corresponia segons les característiques definides prèviament en l'anàlisi dels clústers.

Inicialment, el dendrograma del clustering jeràrquic es va tallar en **4 clústers**, ja que aquesta partició permetia obtenir grups diferenciats i interpretables. Cada clúster representava un perfil d'estudiant amb característiques concretes relacionades amb el rendiment acadèmic, l'assistència, les hores d'estudi, la motivació i el risc d'abandonament.




Figura48: Dendrograma amb les respostes de validació


La validació s'ha fet comparant les respostes dels alumnes de prova amb la descripció dels perfils obtinguts anteriorment. Per exemple, els casos amb risc molt alt, baixa motivació, baixa assistència, poques hores d'estudi i notes baixes haurien de quedar associats als perfils de major risc, especialment al **Cluster 2** o al **Cluster 3**, ja que aquests es caracteritzaven per tenir valors desfavorables en variables com Attendance, Exam_Score, Hours_Studied i dropout.

En canvi, els alumnes amb **risc baix**, motivació alta, bona assistència, més hores d'estudi i bons resultats acadèmics haurien de quedar classificats en perfils més favorables o equilibrats, com el **Cluster 1** o el **Cluster 4**, ja que aquests presentaven una situació generalment més estable i menys associada a l'abandonament.

A partir dels casos observats, es pot veure que els alumnes amb risc del **100%** són classificats en perfils de risc, fet que és coherent amb la definició dels clústers. Per exemple, alumnes amb motivació baixa, assistència reduïda, poques hores d'estudi i una nota d'examen baixa reben accions com la **tutoria motivacional**, cosa que reforça la interpretació del perfil com a estudiant en situació de risc.

Tot i això, també s'observen alguns casos amb **risc del 0%** classificats com a "Perfil d'alumne 3". Aquests alumnes presenten motivació alta, assistència elevada, més hores d'estudi i bones notes, de manera que la seva assignació pot indicar que aquest perfil no representa únicament risc alt, sinó també un grup mixt amb factors protectors importants. Això és coherent amb la descripció inicial del **Cluster 3**, que combinava factors positius i negatius, però també mostra que seria convenient revisar o afinar la interpretació d'aquest perfil per evitar confusions.

Per tant, la validació del clustering permet comprovar que, en general, el sistema assigna els alumnes a perfils coherents amb les seves característiques. A més, ajuda a detectar possibles punts de millora en la descripció dels perfils, especialment en aquells clústers amb comportaments més mixtos o heterogenis. Si haguéssim tingut més varietat de respostes, poder se'ns hagués classificat algun alumne amb algun perfil del Clúster 1 o 4.



ID	RISC	PERFIL	MOTIVACIÓ	ASSIST.	HORES	EXAM	ACCIÓ
VAL-0001	100%	Perfil d'alumne 2	Low	20%	0	60	Tutoria motivacional
VAL-0009	100%	Perfil d'alumne 3	Low	80%	7	60	Tutoria motivacional
VAL-0023	0%	Perfil d'alumne 3	High	95%	28	80	Monitorització ordinària
VAL-0024	0%	Perfil d'alumne 3	High	90%	14	70	Monitorització ordinària
VAL-0026	0%	Perfil d'alumne 3	High	85%	14	75	Monitorització ordinària

Figura49: Exemples de perfils d'estudiants classificats de les respostes de validació

7.3.2. Model de classificació supervisada

Per validar la part supervisada del sistema, s'ha aplicat el mateix pipeline de classificació sobre la base de validació obtinguda a partir de l'enquesta i posteriorment preprocessada. L'objectiu d'aquesta fase ha estat comprovar si el model manté un comportament coherent quan rep dades externes al conjunt original, però amb la mateixa estructura de variables i format d'entrada.

La validació s'ha dut a terme utilitzant els mateixos models analitzats anteriorment: Regressió Logística, MLP i XGBoost. Igual que en l'apartat de modelatge inicial, s'han utilitzat les mètriques

Accuracy, Precision, Recall, F1-score i ROC-AUC, ja que permeten comparar directament el rendiment sobre la base original i sobre la base de validació. En el model inicial, XGBoost havia estat el model amb millor rendiment global, amb valors molt elevats de precisió, recall i F1-score, mentre que la regressió logística destacava sobretot pel recall perfecte.

En aplicar el mateix esquema a la base de validació, s'observa una baixada general del rendiment respecte a la base original, fet esperable perquè es tracta d'un conjunt extern, més petit i menys estable. Tot i així, els resultats continuen sent coherents amb el comportament general del sistema. En aquesta validació, tant MLP com XGBoost obtenen una accuracy de 0.8333 i un F1-score de 0.6667, mentre que la regressió logística baixa fins a una accuracy de 0.6667 i un F1-score de 0.5000. També es veu que XGBoost i MLP mantenen una precision de 1.0, però amb un recall de 0.5, mentre que la regressió logística queda més desequilibrada.

Aquest comportament indica que el model continua identificant correctament part dels casos de risc, però amb menys estabilitat que en l'escenari original. La baixada és especialment visible en la regressió logística, probablement perquè és un model més sensible a petits canvis en la distribució de les variables i a desajustos entre la base d'entrenament i la base validada. En canvi, XGBoost es manté com l'opció més robusta, ja que conserva un comportament més estable i continua oferint una bona base per a la interpretació posterior amb SHAP, que ja havia estat definida com a motor d'explicabilitat del sistema.

En conjunt, aquesta validació confirma que el model supervisat continua funcionant de manera raonable fora del dataset original, tot i que els resultats s'han d'interpretar amb prudència perquè la mostra de validació és molt reduïda. Malgrat això, el sistema manté la seva capacitat de detectar patrons de risc i XGBoost continua sent el model més adequat per integrar dins del IDSS.




Figura50: Comparació de les matrius de confusió amb la base de dades originals i la base de validació

7.3.3. Model d'explicabilitat

Un cop validat el model supervisat, s'ha analitzat també el comportament del motor d'explicabilitat sobre la base de validació. Aquesta part és important perquè dins del sistema no només interessa obtenir una predicció de risc, sinó també entendre quins factors estan influïnt en aquesta decisió. En el model original, el motor d'explicabilitat es va construir sobre XGBoost utilitzant SHAP, amb una anàlisi tant global com local.

Per fer aquesta validació, s'ha utilitzat novament el model XGBoost i s'han generat explicacions SHAP sobre la base validada. Això ha permès comparar si les variables més influents continuen sent semblants a les observades en la base original i si les explicacions individuals continuen tenint sentit. En el model inicial, les variables principals eren sobretot Exam_Score, Motivation_Level, Hours_Studied, Attendance i Previous_Scores, mostrant una relació clara entre rendiment acadèmic, motivació i risc d'abandonament.

Els resultats de validació mostren que el patró general es manté parcialment. A nivell global, torna a aparèixer Motivation_Level_Low com la variable amb més impacte mitjà segons SHAP, i també continuen tenint pes Hours_Studied, Attendance i Previous_Scores. Això reforça la idea que la motivació i el compromís acadèmic continuen sent els factors centrals del sistema. No obstant això, en la base de validació apareixen també altres variables amb més pes relatiu, com Distance_from_Home_Moderate o Extracurricular_Activities_Yes, fet que probablement s'explica per la mida reduïda de la mostra i per la major variabilitat d'aquest conjunt.

A nivell local, les explicacions dels casos individuals continuen sent interpretables. En el cas d'alt risc, la predicció es relaciona sobretot amb motivació baixa, poques hores d'estudi i altres factors desfavorables. En canvi, en els casos de baix risc, el model es recolza en l'absència de motivació baixa i en un perfil més estable. Per tant, encara que les explicacions siguin una mica menys netes que en la base original, el comportament general del motor continua sent coherent amb la lògica del sistema.

En conjunt, la validació del model d'explicabilitat mostra que SHAP continua sent útil també fora del dataset original. Les variables principals no canvien de manera radical i les explicacions locals segueixen permetent justificar les prediccions de manera entenedora. Això reforça el valor del motor d'explicabilitat dins del IDSS, ja que permet interpretar els resultats del model també en un escenari de validació amb dades noves.




Figura 51: Comparació del SHAP amb la base de dades originals i la base de validació

7.3.4. Intervention Impact Analysis

Com s'ha avançat en l'apartat 4.5, finalment es va optar per una aproximació diferent a l'hora d'analitzar l'impacte de les intervencions en l'alumnat. Tot i que inicialment es va plantejar el desenvolupament d'un model predictor, la detecció de les necessitats de l'IDSS actual i la definició de l'abast del projecte van fer reorientar l'estratègia. Es va considerar més útil i complet dissenyar la *baseline* per a una hipotètica actualització de les dades, així com avaluar de manera gràfica l'impacte individual de cada intervenció. Incorporar aquestes mètriques directament en un model hauria implicat redissenyar l'IDSS des de zero, fet que s'allunyava de l'objectiu principal: complementar el sistema actual amb dades dinàmiques cada sis mesos.

Per aquest motiu, en lloc de desenvolupar un model d'aprenentatge basat en intervencions, s'ha dut a terme un anàlisi descriptiu de l'alumnat. Consistentment amb aquest enfocament, no s'inclou una validació formal del model, ja que aquesta no escau en un estudi de naturalesa descriptiva.

7.4. ÈTICA I IMPACTE

L'ús d'un IDSS en l'àmbit educatiu pot tenir un impacte positiu, ja que permet detectar de manera precoç estudiants amb possible risc d'abandonament i facilita una intervenció més ràpida i fonamentada en dades. D'aquesta manera, el sistema pot ajudar tutors, orientadors i centres educatius a prioritzar casos i optimitzar recursos.

Tot i això, aquest tipus de sistemes també comporta riscos ètics. En primer lloc, es treballa amb dades acadèmiques i personals dels estudiants, de manera que la privacitat i la protecció de dades són aspectes essencials. En un entorn real, caldria garantir el compliment de la normativa vigent i limitar l'accés a la informació.

En segon lloc, existeix el risc de biaix, ja que els models poden reflectir patrons previs o desigualtats presents en les dades. Això podria afectar determinats perfils d'estudiants i generar classificacions injustes si no s'interpreten correctament.

També cal tenir en compte el risc d'estigmatització. Classificar un alumne com a "alt risc" no ha de suposar una etiqueta fixa, sinó un senyal d'alerta per reforçar el seguiment i l'acompanyament. Per això, el sistema s'ha d'utilitzar com una eina de suport i no com un mecanisme de decisió automàtica. Per reduir aquests riscos, el projecte incorpora un motor d'explicabilitat que permet entendre millor les prediccions del model. Això aporta transparència i facilita que el professorat pugui interpretar els resultats abans de prendre decisions.

En conjunt, el sistema pot ser molt útil si s'utilitza de manera responsable. El seu impacte serà positiu sempre que es combini amb supervisió humana, control dels biaixos i respecte per la privacitat dels estudiants.

7.5. PERSPECTIVA DE GÈNERE

Pel que fa a la perspectiva de gènere, en aquest projecte s'ha considerat important revisar si la variable **Gender** tenia un paper rellevant dins del sistema o si podia introduir algun tipus de biaix en la detecció del risc d'abandonament. En l'anàlisi del dataset original, aquesta variable no va mostrar una relació significativa amb la variable objectiu dropout, ja que les taxes d'abandonament entre categories eren pràcticament idèntiques. Per aquest motiu, no es va considerar una variable discriminant dins de l'IDSS, ni tampoc justificava una intervenció diferenciada segons el gènere.

En la base de validació obtinguda a partir de l'enquesta, la distribució per gènere ha estat desigual, amb una presència més alta d'homes que de dones. Això limita molt qualsevol interpretació sòlida, ja que la mostra és reduïda i no és representativa per extreure conclusions generals. Per tant, en aquesta fase no s'ha utilitzat la perspectiva de gènere per establir regles específiques ni per modificar el comportament dels models.

Tot i això, des d'un punt de vista ètic, és important tenir present que en un desplegament real del sistema sí que convindria monitoritzar periòdicament el rendiment dels models per gènere, amb l'objectiu de detectar possibles diferències injustificades en les prediccions. D'aquesta manera, es podria garantir que el sistema continuï sent una eina de suport justa, transparent i no discriminatòria.

7.6. VALIDACIÓ GENERAL

7.6.1. Validació general del sistema IDSS

La validació general del nostre Intelligent Decision Support System (IDSS) s'ha dissenyat per comprovar que el sistema funciona correctament tant a nivell individual com global. Com que l'objectiu principal del sistema és donar suport a la detecció del risc d'abandonament escolar, no n'hi ha prou amb validar només els models predictius, sinó que també cal comprovar la qualitat de les dades, la integració entre components, la interpretabilitat dels resultats i la utilitat real per als usuaris finals.

Aquesta validació es divideix en tres nivells principals:

1. Validació dels components individuals del sistema.
2. Validació de les interaccions entre components.
3. Validació del rendiment global del sistema i del suport a la presa de decisions.

D'aquesta manera es busca assegurar que cada part del sistema és fiable, que la comunicació entre mòduls és correcta i que el resultat final aporta valor als stakeholders, com ara professorat, tutors, coordinadors acadèmics o responsables de seguiment de l'alumnat.

7.6.2. Validació dels components del sistema

Cada component del sistema ha de ser validat de manera independent per comprovar que compleix la seva funció dins de l'arquitectura general. En el nostre cas, els principals components són: el mòdul de dades, els models data-driven, les fonts de coneixement, el motor de raonament, el mòdul d'explicabilitat i el dashboard final.

Component	Metodologia o procés de validació	Resultat esperat	Hardware ben dimensionat?
Data / Preprocessament	Revisió de valors nuls, formats, duplicats, variables mal codificades i coherència de les dades preprocessades respecte al dataset original.	Dataset net, coherent i preparat per alimentar els models.	Sí, ja que el volum de dades és assumible en un ordinador estàndard.
Models data-driven	Validació amb mètriques com accuracy, precision, recall, F1-score i matriu de confusió. Separació entre dades d'entrenament i test.	Models capaços de detectar patrons associats al risc d'abandonament escolar.	Sí, perquè l'entrenament no requereix GPU ni infraestructura avançada.
Clustering / Perfils d'estudiants	Anàlisi de la qualitat dels grups, interpretació dels perfils i coherència amb variables acadèmiques i personals.	Grups interpretables que ajudin a entendre perfils d'estudiants similars.	Sí, el cost computacional és moderat.
Knowledge Sources	Revisió manual de regles, casos o coneixement expert introduït al sistema. Validació de la coherència amb el domini educatiu.	Coneixement comprensible, justificat i alineat amb l'objectiu del sistema.	Sí, ja que són components lleugers.
Motor de raonament / IDSS	Proves amb casos d'estudiants de diferents nivells de risc per comprovar si la sortida és coherent.	Classificació o recomanació adequada segons el perfil de l'estudiant.	Sí, perquè el raonament es basa en regles i resultats dels models.
Mòdul explicabilitat	Revisió de si les explicacions indiquen correctament els factors que influeixen en el risc.	Explicacions clares i útils per als usuaris.	Sí, no requereix alta capacitat de càlcul.
Dashboard / Interfície	Proves d'usabilitat amb diferents tipus d'usuaris i revisió visual de gràfiques, alertes i resultats.	Interfície clara, robusta i fàcil d'interpretar.	Sí, pot executar-se en un entorn web o local bàsic.

Figura52: Taula de la validació de dels components del sistema

7.6.3. *Validació de les interaccions entre components*

Un cop validats els components de manera individual, cal validar les interaccions entre ells. Això és important perquè un component pot funcionar correctament per separat, però generar errors quan s'integra amb la resta del sistema.

La primera interacció a validar és la comunicació entre el mòdul de dades i els models. Les dades preprocessades han de tenir exactament el format que els models esperen. Això implica validar el nom de les variables, el tipus de dada, l'ordre de les columnes i la presència de totes les variables necessàries. Si aquesta connexió no és correcta, el model pot generar errors o prediccions incorrectes. També s'ha de validar la interacció entre els models i les fonts de coneixement. Les sortides dels models, com ara una predicció de risc o un perfil de cluster, han de ser interpretables i utilitzables pel sistema de raonament. Per exemple, si un model classifica un estudiant com a risc alt, aquesta informació ha de poder ser utilitzada per aplicar regles o generar recomanacions.

Una altra interacció important és la que es dona entre les knowledge sources i el motor de raonament. En aquest punt s'ha de comprovar que les regles, casos o criteris definits s'apliquen correctament. Per validar-ho, es poden crear casos controlats on ja se sap quina hauria de ser la resposta esperada del sistema.

Finalment, cal validar la comunicació entre el motor IDSS i el dashboard. La informació generada pel sistema ha d'arribar correctament a la interfície final, sense perdre significat ni format. El nivell de risc, les explicacions i les recomanacions han de mostrar-se de manera clara i ordenada.

En general, la validació de les interaccions ha de comprovar que la comunicació entre components és fluida, que no hi ha errors de transmissió de dades, que la latència és acceptable i que es tenen en compte aspectes de seguretat i ètica en el tractament de la informació.

7.6.4. *Validació dels inputs i outputs*

La validació dels inputs i outputs és essencial perquè el sistema depèn directament de la qualitat de les dades d'entrada i de la claredat de les respostes generades.

Els inputs principals del sistema són les dades dels estudiants. Aquestes dades poden incloure variables acadèmiques, personals o contextuais, com ara l'assistència, les notes, el temps d'estudi, el comportament acadèmic o altres factors relacionats amb el risc d'abandonament. La validació dels inputs consisteix a comprovar que aquestes dades són correctes, completes, coherents i que es troben en el format adequat.

També cal comprovar que el sistema és robust davant inputs incomplets o incorrectes. Per exemple, si falten algunes dades d'un estudiant, el sistema hauria d'avisar l'usuari o aplicar un tractament adequat, però no hauria de fallar completament. Això és important perquè en un entorn real les dades poden no estar sempre perfectament completes.

Pel que fa als outputs, el sistema ha de generar resultats clars i útils. Els outputs principals poden ser el nivell de risc d'abandonament, el perfil de l'estudiant, els factors que expliquen aquest risc i possibles recomanacions d'actuació. Aquests resultats s'han de validar comprovant si són coherents amb els casos analitzats i si són comprensibles per als usuaris finals.

Un bon output no ha de ser només correcte des del punt de vista tècnic, sinó també fàcil d'interpretar. Per exemple, no és suficient dir que un estudiant té una probabilitat elevada d'abandonament; el sistema també hauria d'explicar quins factors han influït en aquesta decisió, com ara baixa assistència, baix rendiment o poca participació.

7.6.5. *Validació del rendiment global del sistema*

Per validar el rendiment global del sistema s'han seleccionat diverses característiques rellevants. Aquestes característiques no només fan referència al rendiment tècnic, sinó també a la utilitat, sostenibilitat, explicabilitat, confiança i manteniment a llarg termini.

Característica rellevant	KPI	Procés de mesura	Disseny experimental i casos d'ús	Conclusions i comentaris
Impacte en el rendiment acadèmic	Reduir en un 10-15% el nombre d'estudiants amb resultats baixos	Comparar el percentatge d'estudiants amb resultats baixos abans i després d'utilitzar l'IDSS	Aplicar el sistema a un conjunt d'estudiants, identificar els casos de risc i fer seguiment després de les intervencions proposades	Aquest KPI permet comprovar si el sistema ajuda a detectar abans els estudiants amb dificultats i si les intervencions tenen un efecte positiu

Millora de la taxa d'aprovat	Augmentar en un 5-10% la taxa d'aprovat després de les intervencions	Comparar la taxa d'aprovat abans i després d'aplicar les accions de suport recomanades pel sistema	Seleccionar estudiants detectats amb risc mitjà o alt, aplicar mesures de reforç i analitzar si augmenta el nombre d'aprovat	Aquest indicador valida si l'IDSS aporta valor real en la presa de decisions educatives
Efectivitat del reforç	Incrementar el nombre d'estudiants que milloren la seva nota després del reforç	Comparar les notes dels estudiants abans i després de rebre reforç o seguiment	Fer seguiment dels estudiants que han rebut una intervenció després de ser detectats pel sistema	Permet comprovar si les recomanacions del sistema ajuden a millorar el rendiment individual dels estudiants
Performance del model	Recall dels estudiants en risc, accuracy i F1-score	Avaluar el model amb dades de test i comparar les prediccions amb els valors reals	Utilitzar casos d'estudiants amb risc alt, mitjà i baix per comprovar si el sistema els classifica correctament	És important prioritzar el recall, ja que interessa detectar el màxim nombre possible d'estudiants en risc
Usabilitat del sistema	Percentatge d'usuaris que entenen correctament el resultat del dashboard	Qüestionari o prova d'usabilitat amb usuaris finals	Tutors, professors o coordinadors interpreten diferents casos mostrats pel dashboard	El sistema ha de ser clar i fàcil d'utilitzar per persones no tècniques

Explicabilitat	Percentatge de decisions que inclouen una explicació comprensible	Revisar si cada resultat mostra els factors que expliquen el risc detectat	Presentar casos d'estudiants i comprovar si l'usuari entén per què el sistema genera una alerta	Les explicacions són necessàries perquè l'usuari confii en el sistema i pugui justificar les decisions
Robustesa	Nombre d'errors davant dades incompletes o contradictòries	Introduir registres amb valors absents, extrems o inconsistents	Provar casos com estudiants amb bones notes però baixa assistència, o amb dades incompletes	El sistema ha de continuar funcionant i avisar quan la informació no sigui suficient
Suport a la presa de decisions	Grau d'utilitat percebut pels stakeholders	Enquesta de valoració després d'utilitzar el sistema	Els usuaris valoren si les alertes i recomanacions els ajuden a decidir accions de seguiment	Aquest KPI valida si el sistema aporta valor real als professionals educatius
Ètica i compliment	Revisió de biaixos, privacitat i ús responsable de les dades	Analitzar les variables utilitzades i comprovar que no generen discriminació	Comparar resultats entre diferents perfils d'estudiants i revisar si les recomanacions són justes	El sistema ha de ser una eina de suport, no una eina de decisió automàtica definitiva
Cost computacional i manteniment	Temps d'execució i facilitat per actualitzar components	Mesurar el temps de resposta i revisar la modularitat de l'arquitectura	Executar el sistema amb diferents volums de dades i provar l'actualització d'un model o regla	El sistema ha de ser eficient, mantenible i adaptable a futures necessitats

Figura53: Taula validació del rendiment global del sistema

7.6.6. Casos d'ús per a la validació

Per validar el sistema de manera realista, es poden definir diferents casos d'ús que representin situacions habituals o rellevants dins del context educatiu.

Un primer cas seria el d'un estudiant amb risc alt d'abandonament. Aquest perfil podria tenir baixa assistència, baix rendiment acadèmic i altres indicadors negatius. En aquest cas, el sistema hauria d'identificar un risc elevat i proposar una recomanació d'intervenció o seguiment.

Un segon cas seria el d'un estudiant amb risc mitjà. Aquest alumne podria presentar alguns factors negatius, però no prou greus per ser classificat com a risc alt. El sistema hauria d'indicar un risc moderat i recomanar una observació o seguiment més proper.

Un tercer cas seria el d'un estudiant amb risc baix. Aquest perfil tindria bones notes, bona assistència i indicadors generals positius. El sistema hauria de classificar-lo com a risc baix i no generar una alerta innecessària.

També és important validar casos amb dades incompletes. En aquest escenari, el sistema hauria de demostrar que és robust i que pot gestionar la falta d'informació sense fallar. Si la informació és insuficient, hauria d'indicar-ho clarament a l'usuari.

Finalment, es poden validar casos contradictoris, per exemple un estudiant amb bones notes però baixa assistència *Figura54*, o un estudiant amb notes baixes però alta assistència *Figura55*. Aquests casos són útils per comprovar si el sistema és capaç de generar una resposta raonada i no depèn només d'una variable concreta.




Figura54: Estudiant amb baixa assistència i bones notes




Figura55: Estudiant amb alta assistència i notes baixes

7.6.7. Conclusió

En conclusió, la validació general del nostre IDSS permet comprovar que el sistema és correcte, útil, comprensible i adequat per al context educatiu. Aquesta validació inclou tant aspectes tècnics com humans, ja que un sistema de suport a la decisió no només ha de funcionar bé internament, sinó que també ha de ser entès i acceptat pels usuaris finals.

El sistema es considerarà validat si els seus components funcionen correctament, si la comunicació entre mòduls és fluida, si els inputs i outputs són clars, si les prediccions són coherents, si les recomanacions aporten valor i si els usuaris confien en els resultats.

D'aquesta manera, el nostre IDSS pot actuar com una eina de suport per identificar de manera preventiva estudiants amb risc d'abandonament escolar i ajudar els professionals a prendre decisions més ràpides, informades i justificades.

8. INTERFÍCIE

Per completar el desenvolupament del IDSS, s'ha desenvolupat una interfície en forma de dashboard interactiu. L'objectiu principal d'aquesta interfície és facilitar la interpretació dels resultats generats pels diferents components del sistema i convertir les prediccions del model en informació útil per al professorat i els responsables de seguiment acadèmic.

Aquesta interfície actua com a capa final d'interacció entre l'usuari i el sistema IDSS. Per tant, no es limita únicament a mostrar resultats numèrics, sinó que permet consultar la situació general de la cohort, identificar estudiants amb risc, revisar casos individuals, entendre els factors que expliquen cada predicció, simular possibles intervencions i registrar accions de seguiment. D'aquesta manera, el dashboard transforma els resultats analítics en una eina pràctica de suport a la presa de decisions educatives.

La interfície s'ha implementat com una aplicació web estàtica, formada principalment pels fitxers `index.html`, `styles.css`, `app.js` i `actions_store.js`. Aquesta decisió permet executar el sistema de manera local, sense necessitat d'un backend ni d'una base de dades externa. Les dades preprocessades, les prediccions i la informació dels perfils d'estudiants es carreguen a partir de fitxers CSV i JSON exportats dins del repositori del projecte.



Figura56: Visió global de la interfície

8.1. ESTRUCTURA GENERAL DEL DASHBOARD

El dashboard s'organitza en diferents pestanyes accessibles des del menú lateral. Cada pestanya respon a una necessitat concreta dins del procés de decisió docent. Les principals vistes desenvolupades són la vista global, la vista d'estudiants, la vista de validació, el simulador i la pestanya de nou alumne.

La vista global proporciona una lectura agregada de la cohort i permet obtenir una primera visió de l'estat general del sistema. La vista d'estudiants permet passar del nivell agregat a l'anàlisi individual, mostrant una llista prioritzada d'alumnes i una fitxa detallada per a cada cas. La vista de validació separa els alumnes procedents del conjunt de validació, fet que permet comprovar el comportament del sistema sobre dades diferents del conjunt principal. Finalment, el simulador i la pestanya de nou alumne permeten explorar escenaris hipotètics i avaluar nous casos de manera manual.

Aquesta estructura facilita una navegació clara i ordenada, evitant sobrecarregar l'usuari amb tota la informació en una sola pantalla.

8.2. VISITA GLOBAL

La vista global és la primera pantalla del dashboard i està pensada com un resum executiu de la situació acadèmica de la cohort. El seu objectiu és permetre que el professorat identifiqui ràpidament quants estudiants poden requerir atenció, com es distribueixen els nivells de risc i si hi ha revisions o intervencions pendents.

A la part superior es mostren diversos indicadors resum, com el nombre total d'estudiants, el percentatge d'abandonament observat, el nombre d'alumnes classificats amb risc alt i l'estat de l'explicabilitat del sistema. Aquests indicadors permeten obtenir una primera lectura quantitativa abans d'entrar en el detall dels perfils o dels casos individuals.

Un dels elements principals d'aquesta vista és la matriu de perfils d'alumne per nivell de risc. Aquesta matriu creua els perfils identificats mitjançant clustering amb els nivells de risc estimats pel sistema. Per facilitar la comprensió per part del professorat, s'ha evitat utilitzar directament el terme cluster a la interfície, substituint-lo per l'expressió perfil d'alumne. Aquesta decisió fa que la visualització sigui més interpretable per a usuaris no tècnics.

La matriu permet detectar quins perfils concentren més alumnes amb risc alt, quins grups són més estables i quins perfils haurien de ser prioritaris en cas d'intervenció. Això reforça la funció del dashboard com a eina de suport tàctic i operatiu.




Figura57: Vista global del Dashboard

A més, la vista global incorpora una agenda de seguiment. Aquesta agenda no prové directament del model predictiu, sinó de les intervencions que el professorat registra manualment des de la fitxa individual de cada alumne. L'agenda diferencia entre casos urgents, revisions programades durant la setmana i alumnes amb seguiment actiu. D'aquesta manera, la interfície no només mostra el risc detectat, sinó que també ajuda a gestionar les accions que s'han decidit aplicar.

8.3. VISITA D'ESTUDIANTS I FITXA INDIVIDUAL

La pestanya d'estudiants permet consultar una llista prioritzada d'alumnes. Aquesta vista és una de les parts més importants del dashboard, ja que permet passar de l'anàlisi general a la revisió individual de cada cas.

La taula mostra informació rellevant per a cada estudiant, com l'identificador, el percentatge de risc, el perfil d'alumne, el nivell de motivació, l'assistència, les hores d'estudi, la nota d'examen i l'acció recomanada o l'estat del seguiment. També s'han incorporat filtres per nivell de risc, motivació i cerca per text, així com la possibilitat d'ordenar les columnes principals. Això facilita que el professorat pugui prioritzar els casos que requereixen una actuació més immediata.




Figura58: Vista dels estudiants de manera general

En seleccionar un alumne concret, el dashboard mostra una fitxa individual amb una explicació local del cas. Aquesta fitxa té com a objectiu ajudar l'usuari a entendre per què aquell estudiant ha estat classificat amb un determinat nivell de risc.

La fitxa inclou un resum del risc, les variables principals de l'alumne i els factors que han influït en la predicció. Per exemple, si un estudiant presenta una assistència inferior al lílndar de referència, poques hores d'estudi o una motivació baixa, aquests elements apareixen com a factors de risc destacats. En lloc de mostrar directament valors tècnics del model, com pesos interns o valors SHAP en format cru, el dashboard transforma aquests resultats en una explicació més propera al llenguatge docent. També s'inclou un bloc de perfil de seguiment, on es mostra a quin perfil pertany l'alumne i quines característiques generals defineixen aquest grup. Aquesta informació prové de l'anàlisi de clustering i profiling desenvolupada anteriorment, però s'ha adaptat a un llenguatge més comprensible per al professorat.

STU-0002

100%

Risc d'abandonament: 99.9%

Motivació baixa, assistència 64%, 19 hores d'estudi.

Simular aquest alumne

Factors de risc de l'alumne

FACTOR

VALOR DE L'ALUMNE

LLINDAR

LECTURA

Motivació baixa

Baixa

Baixa

Critic

Nota d'examen

61

< 64

Critic

Assistència

64%

< 75%

Critic

Pròxim pas

Tutoria motivacional: Revisió individual d'objectius, barreres i compromís amb el curs.

PERFIL DE SEGUIMENT

Perfil d'alumne 2

Concentració de valors desfavorables en variables acadèmiques clau.

Perfil força consistent dins del grup d'alumnes Major probabilitat d'abandonament i baix rendiment acadèmic

Stratègia prioritària d'intervenció

Intervenció prioritària i seguiment proper.

PLA D'INTERVENCIÓ PERSONALITZAT

Què fer i què revisar

El percentatge futur és orientatiu: mostra el risc estimat si l'alumne millora els indicadors indicats. No és una predicció garantida ni modifica les dades originals.

Ara

0 punts d'assistència

Fort de partida amb les dades actuals de l'alumne.

RISC ACTUAL 100%

Sense canvis aplicats

Objectiu d'indicadors assolit: 64% - 19h estudi - examen 61 - motivació baixa

Acció inicial

Tutoria motivacional

Revisió individual d'objectius, barreres i compromís amb el curs.

RISC ESTIMAT SI S'INICIA LA INTERVENCIÓ 55%

Primer contacte i acord de seguiment.

Objectiu d'indicadors assolit: 68% - 20h estudi - examen 62 - motivació baixa

Revisió en 4 setmanes

Revisar assistència, estudi i llibres.

Compromís: si hi ha millores s'organitzaran alumnat d'espere al final del període.

RISC ESTIMAT SI MILLORA ELS INDICADORS 78%

+7 punts d'assistència, +4 h d'estudi i primeres llibres registrades.

Objectiu d'indicadors assolit: 71% - 23h estudi - examen 63 - motivació baixa

Objectiu a 8 setmanes

Consolidar hàbits i aquiescència

Actuar a una situació de seguiment proper i a monitorització individual.

RISC ESTIMAT SI MILLORA ELS INDICADORS 48%

+12 punts d'assistència, +7 h d'estudi, +7 punts d'examen i motivació mitjana.

Objectiu d'indicadors assolit: 76% - 26h estudi - examen 66 - motivació mitjana

ACCIONS SUGGERIDES

Tutoria motivacional

Revisió individual d'objectius, barreres i compromís amb el curs.

Reforç acadèmic

Sessions focalitzades en les competències amb pitjor rendiment.

Seguiment d'assistència

Contacte preventiu i pauta setmanal de presència a classe.

Intervenció prioritària

Revisió tutorial, reforç acadèmic i seguiment proper del cas.

REGISTRAR INTERVENCIÓ

Aplicar acció i programar revisió

Acció

Revisió

Data de revisió

Tutoria motivacional

4 setmanes

18/06/2026

Notes del professor

Optional, màxim 300 caràcters

Aplicar i programar revisió

Figura59: Fitxa dels estudiants de manera individual

102

8.4. PLA D'INTERVENCIÓ I REGISTRE DE SEGUIMENT

Un dels elements més rellevants de la interfície és el pla d'intervenció proposat. Aquest apartat mostra una seqüència orientativa d'accions i revisions per a l'alumne seleccionat. El pla pot incloure una situació inicial, una acció recomanada, una revisió posterior i un objectiu de millora.

Aquest pla no modifica les dades originals ni garanteix una predicció futura, sinó que funciona com una simulació orientativa. La seva finalitat és mostrar com podria evolucionar el risc si l'alumne millorés determinats indicadors, com l'assistència, les hores d'estudi o la motivació. Això ajuda el professorat a passar de la diagnosi a una possible actuació concreta.

La fitxa individual també mostra accions suggerides pel sistema, com tutoria motivacional, seguiment d'assistència, pla d'estudi guiat, reforç acadèmic o suport en recursos educatius. Aquestes accions no s'han d'interpretar com una decisió automàtica obligatòria, sinó com recomanacions de suport. La decisió final continua corresponent sempre al professorat o a l'equip educatiu.

A més, s'ha incorporat un registre d'intervencions. Aquest formulari permet seleccionar una acció, programar una data de revisió, afegir notes opcionals i deixar constància del seguiment aplicat. Les intervencions registrades poden tenir diferents estats, com pendent, en seguiment, a revisar o tancat. Quan un alumne té una intervenció activa, aquesta informació apareix també a la taula d'estudiants i a l'agenda de seguiment.

En aquest prototip, les intervencions es guarden al navegador mitjançant localStorage. Aquesta decisió és adequada per al context acadèmic del projecte, ja que permet demostrar el flux complet de seguiment sense modificar els fitxers originals ni afegir una base de dades externa. En una versió de producció, aquesta informació s'hauria d'emmagatzemar en una base de dades associada al centre educatiu o al sistema de gestió acadèmica.

8.5. VALIDACIÓ, SIMULACIÓ D'INTERVENCIONS I AVALUACIÓ D'ALUMNES NOUS

La pestanya de validació permet consultar els alumnes del conjunt de validació. La seva estructura és similar a la vista d'estudiants, però separa aquests casos del conjunt principal. Aquesta separació és important perquè permet comprovar el comportament del sistema sobre dades que no formen part del conjunt original utilitzat durant el desenvolupament.

La vista de validació inclou filtres, taula d'alumnes, risc estimat, perfil d'alumne i explicació individual. Aquesta funcionalitat reforça la interpretació del model i permet comprovar si les explicacions generades continuen sent útils en dades noves.

SISTEMA INTEL·LIGENT DE SUPORT A LA DECISIÓ

Validació del sistema

Buscar:
 Nivell de risc:
 Motivació:

MOSTRA DE VALIDACIÓ 27 resultats

Alumnes per comprovar

ID ↑	RISC ↓	PERFIL ↑	MOTIVACIÓ	ASSIST. ↑	HORES	EXAM ↑	ACCIÓ ↑
VAL-0001	100%	Perfil d'alum	Low	20%	0	60	Tutoria mo...
VAL-0009	100%	Perfil d'alum	Low	80%	7	60	Tutoria mo...
VAL-0011	100%	Perfil d'alum	Low	80%	7	60	Tutoria mo...
VAL-0014	100%	Perfil d'alum	Low	80%	0	65	Tutoria mo...
VAL-0015	100%	Perfil d'alum	Low	0%	7	60	Tutoria mo...
VAL-0016	100%	Perfil d'alum	Low	80%	0	50	Tutoria mo...
VAL-0017	100%	Perfil d'alum	Low	20%	0	49	Tutoria mo...
VAL-0018	100%	Perfil d'alum	Low	60%	7	60	Tutoria mo...
VAL-0020	100%	Perfil d'alum	Low	80%	14	50	Tutoria mo...
VAL-0022	100%	Perfil d'alum	Low	55%	0	40	Tutoria mo...

Figura60: Resultat de la validació amb les respostes de l'enquesta

A més de permetre la consulta dels estudiants ja existents dins del dataset, el dashboard incorpora dues funcionalitats orientades a explorar escenaris i analitzar casos nous: el simulador d'intervencions i la vista de nou alumne. Aquestes dues eines amplien la utilitat de la interfície, ja que permeten anar més enllà de la visualització descriptiva dels resultats i aproximar el sistema a un ús més pràctic dins d'un context educatiu real.

El simulador d'intervenció permet modificar les variables principals d'un alumne i observar com podria variar el risc estimat en funció d'aquests canvis. Aquesta funcionalitat és especialment útil perquè ajuda el professorat a entendre de manera interactiva quins factors tenen més pes en la situació d'un alumne concret.

Entre les variables que es poden ajustar hi ha el nivell de motivació, l'assistència, les hores d'estudi, les notes prèvies, la nota d'examen, el nombre de tutories i l'accés a recursos. Quan es modifica algun d'aquests valors, el dashboard recalcula el risc estimat i mostra una comparació entre la situació

original i l'escenari simulat. D'aquesta manera, es pot analitzar, per exemple, què passaria si un alumne millorés l'assistència, augmentés les hores d'estudi o rebés més suport tutorial.

Cal destacar que aquesta funcionalitat no modifica les dades originals del CSV ni altera les prediccions exportades pel model. El seu objectiu és exploratori i pedagògic: permet al professorat comprendre millor com determinades intervencions podrien influir en el risc estimat d'un alumne. A més, el simulador també mostra accions recomanades per al cas simulat, fet que permet comparar la situació inicial amb un escenari hipotètic de millora.




Figura61: Simulador d'un estudiant

La segona funcionalitat és la vista de nou alumne, que permet introduir manualment les dades d'un estudiant que no existeix dins del dataset original. Aquesta opció és important perquè mostra com es podria utilitzar el sistema amb alumnes futurs o amb casos que encara no han estat incorporats a la base de dades.

El formulari permet introduir l'identificador de l'alumne, el nivell de motivació, el percentatge d'assistència, les hores d'estudi, la nota prèvia, la nota d'examen, el nombre de tutories i el nivell d'accés a recursos. Un cop introduïdes aquestes dades, el dashboard calcula una estimació del risc i genera una explicació similar a la dels alumnes existents. També assigna un perfil aproximat d'alumne i proposa possibles accions de seguiment.

Aquesta funcionalitat tampoc modifica el CSV ni afegeix l'alumne a les dades originals. El càlcul es fa temporalment dins del navegador i serveix per demostrar com el sistema podria aplicar-se a nous casos en un entorn real. Això resulta especialment rellevant perquè permet comprovar que el dashboard no només funciona amb dades ja carregades, sinó que també pot donar suport a l'avaluació de nous estudiants.

Figura62: Vista d'un alumne nou

En conjunt, el simulador i la vista de nou alumne fan que el dashboard sigui una eina més completa i flexible. Aquestes funcionalitats permeten analitzar l'impacte potencial d'una intervenció, comparar la situació original i la simulada, provar casos nous sense modificar les dades originals, entendre millor la relació entre variables acadèmiques i risc estimat, i generar recomanacions de seguiment per a alumnes que encara no formen part del dataset.

Per tant, aquestes dues pestanyes reforcen la utilitat del dashboard com a eina de suport a la decisió docent. El sistema no només permet consultar què està passant amb els alumnes existents, sinó també explorar possibles escenaris futurs i avaluar nous casos de manera controlada. Això contribueix a apropar el prototip a un ús real, on el professorat podria utilitzar-lo tant per fer seguiment dels alumnes actuals com per anticipar necessitats d'intervenció en estudiants nous.

8.6. IMPLEMENTACIÓ TÈCNICA

La interfície s'ha implementat com una aplicació web estàtica utilitzant HTML, CSS i JavaScript natiu. Aquesta decisió redueix la complexitat tècnica i facilita l'execució local del projecte.

El fitxer `index.html` defineix l'estructura de les pestanyes, taules, panells i formularis. El fitxer `styles.css` conté el disseny visual de la interfície, incloent colors, distribució dels elements i indicadors visuals. El fitxer `app.js` incorpora la lògica principal de càrrega de dades, càlculs, filtres, simulació i renderització de les vistes. Finalment, `actions_store.js` s'encarrega de gestionar la persistència local de les intervencions docents mitjançant `localStorage`.

Quan s'obre el dashboard, el sistema carrega les dades a partir dels fitxers exportats del projecte. A continuació, parseja els CSV, normalitza els valors numèrics, associa cada alumne amb el seu perfil, incorpora les prediccions exportades i calcula les accions recomanades. Si les prediccions del model estan disponibles, aquestes s'utilitzen com a font principal; en cas contrari, el dashboard pot mostrar una estimació basada en criteris transparents. Això fa que la interfície sigui més robusta davant possibles absències de fitxers o dades incompletes.

8.7. DECISIONS DE DISSENY I LIMITACIONS

El dashboard s'ha dissenyat amb una orientació funcional. No es tracta només d'una pàgina informativa, sinó d'una eina de treball per ajudar el professorat a identificar, interpretar i gestionar casos de risc acadèmic.

Algunes decisions de disseny han estat especialment importants. En primer lloc, s'ha adaptat el llenguatge per evitar terminologia massa tècnica. Per exemple, s'ha substituït `cluster` per perfil d'alumne i s'han evitat referències internes com aTLP dins de la interfície. En segon lloc, s'han utilitzat colors diferenciats per representar els nivells de risc i badges visuals per indicar l'estat del seguiment. També s'han organitzat els continguts en targetes i taules compactes per facilitar la lectura ràpida de la informació.

Tot i això, la interfície presenta algunes limitacions. En primer lloc, el registre d'intervencions es desa localment al navegador i no en una base de dades centralitzada. Aquesta solució és suficient per a un prototip acadèmic, però en un entorn real caldria implementar persistència al servidor. En segon lloc, les simulacions d'intervenció són orientatives i no representen una predicció garantida del futur. Finalment, les recomanacions generades pel sistema no substitueixen el criteri professional del professorat, sinó que han de ser enteses com una eina de suport a la decisió.

8.8. VALOR APORTAT PER LA INTERFÍCIE

La interfície desenvolupada aporta valor perquè converteix els resultats analítics del projecte en una eina pràctica i interpretable. El professorat no rep únicament una llista d'estudiants amb risc, sinó un entorn que permet entendre els factors principals de cada cas, consultar perfils d'alumne, prioritzar intervencions, simular possibles millores, registrar accions docents i programar revisions.

En aquest sentit, el dashboard actua com la capa d'interacció del Sistema Intel·ligent de Suport a la Decisió. Els models proporcionen prediccions i explicacions, però és la interfície la que transforma aquests resultats en informació comprensible i accionable. Això reforça l'objectiu principal del projecte: desenvolupar un sistema que no només sigui tècnicament correcte, sinó també útil per donar suport a la presa de decisions en un context educatiu real.

9. GESTIÓ GENERAL DEL PROJECTE

La gestió del projecte s'ha dut a terme de manera coordinada i progressiva des de després del parcial, moment a partir del qual el grup ha organitzat millor les tasques i ha pogut avançar de forma més constant. En general, estem contents amb el funcionament del grup i amb el resultat obtingut, ja que s'ha aconseguit tirar endavant el projecte mantenint una bona comunicació i una visió comuna dels objectius.

Un dels aspectes que més ha ajudat ha estat la trobada setmanal del grup. Aquest espai ha estat clau per posar en comú els avenços, resoldre dubtes i prendre decisions conjuntes, ja que la comunicació per altres mitjans sovint és més complicada o menys eficient. Gràcies a aquestes reunions, hem pogut fer un seguiment més clar de l'estat del projecte i repartir les tasques segons les necessitats de cada moment.

Tot i això, cal destacar que la càrrega de treball no sempre ha estat del tot equilibrada. En alguns moments, algunes persones han assumit més pes que d'altres, especialment en les parts més tècniques o en aquelles que requerien més continuïtat. Tot i aquest desequilibri puntual, el grup ha intentat adaptar-se i continuar avançant de manera conjunta, mantenint la implicació necessària per assolir els objectius plantejats.

Un aspecte molt positiu ha estat la realització de l'informe. A diferència d'altres fases o treballs, aquesta vegada s'ha portat més al dia, fet que ha evitat problemes importants d'última hora. Això ha permès revisar millor el contingut, integrar les diferents parts del projecte amb més coherència i reduir l'acumulació de feina al final.

En conclusió, la gestió general del projecte ha estat satisfactòria. La trobada setmanal, la comunicació constant i el fet d'haver avançat progressivament amb l'informe han estat factors clau per al bon desenvolupament del treball. Com a aspecte de millora, seria convenient equilibrar millor la càrrega de feina entre tots els membres del grup, però en conjunt valorem positivament l'organització i el resultat final del projecte.

10. MILLORES I FUTURES IMPLEMENTACIONS

Tot i que el sistema desenvolupat ha permès construir un prototip funcional d'un Sistema Intel·ligent de Suport a la Decisió per a la detecció del risc d'abandonament escolar, durant el projecte s'han identificat diverses línies de millora i futures implementacions que podrien augmentar la robustesa, utilitat i aplicabilitat real del sistema.

Una de les millores més importants seria poder validar el sistema en una escola o centre educatiu real. En aquest projecte, la validació s'ha realitzat mitjançant una enquesta pròpia i una base de validació reduïda, fet que ens ha permès comprovar si el model era capaç de generar prediccions coherents sobre dades externes al dataset original. No obstant això, aquesta validació no permet avaluar completament el funcionament del sistema en un context real. Per exemple, no podem saber amb certesa si les accions recomanades pel sistema serien aplicades pel professorat, si aquestes intervencions ajudarien realment els estudiants o si contribuirien a reduir l'abandonament escolar.

Per aquest motiu, una futura implementació clau consistiria a desplegar el sistema en un centre educatiu durant un període determinat, per exemple un semestre o un curs acadèmic complet. Això permetria comparar les prediccions inicials del model amb l'evolució real dels estudiants, registrar les intervencions aplicades i analitzar si aquestes han tingut un impacte positiu. D'aquesta manera, es podria validar no només la capacitat predictiva del model, sinó també la utilitat real del sistema com a eina de suport a la decisió docent.

Una altra millora important seria ampliar el dashboard perquè pogués treballar amb dades actualitzades en temps real o gairebé real. Actualment, la interfície funciona a partir de fitxers CSV i JSON ja exportats, fet que és suficient per a un prototip acadèmic. No obstant això, en un entorn real seria necessari connectar el dashboard amb els sistemes interns del centre, com plataformes de gestió acadèmica, entorns virtuals d'aprenentatge o bases de dades administratives. Això permetria actualitzar automàticament informació com l'assistència, les notes, les activitats realitzades o altres indicadors rellevants.

Relacionat amb això, també seria necessari millorar el sistema de persistència de les accions i del seguiment dels alumnes. En el prototip actual, les intervencions registrades es guarden localment al navegador mitjançant localStorage. Aquesta solució és útil per demostrar el funcionament del sistema, però no és suficient per a un ús real. En una futura versió, les accions aplicades, les dates de revisió, les notes del professorat i l'evolució dels estudiants haurien de guardar-se en una base de dades centralitzada i segura. Això permetria consultar l'historial complet de cada alumne, fer seguiment longitudinal i coordinar millor les accions entre tutors, orientadors i responsables acadèmics.

També es podria implementar un sistema de monitorització longitudinal del risc. En lloc de generar una única predicció puntual, el sistema podria recalculer periòdicament el nivell de risc de cada alumne i mostrar-ne l'evolució al llarg del temps. Això permetria detectar si un estudiant millora després d'una intervenció o si, per contra, el seu risc augmenta progressivament. Aquesta millora seria especialment rellevant per convertir el sistema en una eina de seguiment continu i no només en un instrument de classificació inicial.

Una altra línia de millora seria aprofundir en l'anàlisi de l'efectivitat de les intervencions. Actualment, el sistema proposa accions segons els factors de risc detectats, però no disposa de dades reals suficients per saber quines intervencions funcionen millor per a cada perfil d'alumne. En una futura versió, es podria incorporar un mòdul específic que analitzés l'impacte de cada acció aplicada. Per exemple, es podria estudiar si les tutories motivacionals són més efectives en alumnes amb baixa motivació, si el reforç acadèmic funciona millor en estudiants amb notes baixes o si el seguiment d'assistència redueix el risc en alumnes amb absències freqüents.

També seria interessant millorar la personalització de les recomanacions. En el prototip actual, les accions suggerides es basen en regles i factors principals de risc. En una versió futura, aquestes recomanacions podrien adaptar-se millor al perfil de cada alumne, combinant informació del model predictiu, el perfil obtingut mitjançant clustering, l'historial d'intervencions i els resultats observats en casos similars. Això permetria passar d'un sistema que recomana accions generals a un sistema capaç de proposar intervencions més individualitzades.

Des del punt de vista tècnic, una altra millora rellevant seria implementar una política formal de reentrenament del model. En un entorn educatiu real, els patrons dels estudiants poden canviar amb el temps, ja sigui per canvis en el pla docent, en el perfil de l'alumnat o en les metodologies d'ensenyament. Per aquest motiu, el model hauria de reentrenar-se periòdicament amb dades noves i validar-se abans de ser actualitzat. També seria necessari monitoritzar si el rendiment del model disminueix amb el temps, detectant possibles problemes de deriva de dades o canvis en la distribució de les variables.

Una altra millora important seria reforçar els mecanismes d'ètica, privacitat i control de biaixos. En una implementació real, el sistema treballaria amb dades sensibles dels estudiants, de manera que seria imprescindible garantir el compliment de la normativa de protecció de dades i limitar l'accés a la informació segons el rol de cada usuari. A més, caldria revisar periòdicament si el model genera resultats injustos per a determinats col·lectius o si alguna variable pot introduir biaixos no desitjats.

Aquesta revisió hauria d'incloure anàlisis per gènere, context socioeconòmic o altres característiques rellevants, sempre amb l'objectiu d'assegurar que el sistema funcioni com una eina de suport i no com un mecanisme automàtic de decisió.

També es podria millorar la interfície del dashboard incorporant noves funcionalitats visuals i d'usabilitat. Per exemple, es podrien afegir gràfics d'evolució temporal del risc, alertes automàtiques quan un alumne empitjori, informes exportables per al professorat o vistes específiques segons el tipus d'usuari. Els tutors podrien veure informació detallada dels seus alumnes, els coordinadors podrien accedir a una visió agregada per grups o cursos, i l'equip directiu podria consultar indicadors generals sobre l'evolució del risc al centre.

Finalment, una futura implementació podria convertir el prototip en una aplicació web completa amb backend, autenticació d'usuaris i connexió amb una base de dades. Això permetria gestionar millor els permisos, guardar l'historial de cada alumne, integrar el sistema amb plataformes educatives i garantir un funcionament més escalable. Aquesta evolució seria necessària si es volgués passar d'un prototip acadèmic a una eina aplicable en un centre educatiu real.

En conjunt, les principals millores futures se centren en tres direccions: validar el sistema en un context educatiu real, millorar la infraestructura tècnica del dashboard i aprofundir en l'avaluació de l'impacte de les intervencions. Aquestes ampliacions permetrien transformar el prototip actual en un sistema més robust, útil i fiable, capaç no només de predir el risc d'abandonament escolar, sinó també d'ajudar a reduir-lo mitjançant accions educatives més efectives i basades en dades.

11. CONCLUSIONS

El projecte ha demostrat la viabilitat i el potencial d'un Sistema Intel·ligent de Suport a la Decisió aplicat a la detecció del risc d'abandonament escolar. A partir de la combinació de tècniques d'anàlisi de dades, clustering, models supervisats, explicabilitat i representació del coneixement, s'ha construït un sistema capaç de transformar dades acadèmiques i socioeducatives en informació útil per a la presa de decisions.

Respecte a la primera entrega, s'han aplicat diverses millores importants. Una de les més rellevants ha estat la revisió del clustering jeràrquic i del profiling. Inicialment, el sistema treballava amb 3 clústers, però després de revisar els resultats i aplicar el mètode del colze, s'ha decidit passar a una segmentació de 4 clústers. Aquesta nova divisió permet obtenir perfils d'estudiants més diferenciats i interpretables, millorant la capacitat del sistema per identificar grups amb diferents nivells de risc i necessitats d'intervenció.

També s'ha modificat i ampliat el desplegament del Canvas, concretant millor les fases necessàries per portar el sistema a un entorn real. Aquest desplegament inclou la preparació amb el centre educatiu, la recollida i validació de dades, l'adaptació del model, la implementació en una eina interna o dashboard, la posada en producció i el seguiment continu del sistema.

Un altre avenç important ha estat la realització d'una enquesta per obtenir dades externes de validació. Aquestes respostes han permès provar el comportament de l'IDSS amb dades noves, diferents de les utilitzades inicialment per entrenar els models. Tot i que la mostra és reduïda, ha servit per comprovar si els diferents components del sistema mantenien una resposta coherent en un escenari més proper a una aplicació real.

A partir d'aquestes dades, s'ha dut a terme la validació dels principals models del sistema. S'ha validat el clustering i profiling comprovant si els nous alumnes quedaven assignats a perfils coherents; s'ha validat el model de classificació supervisada comparant el seu rendiment amb la base original i la base de validació; i també s'ha revisat el motor d'explicabilitat per comprovar si les variables més influents continuaven sent coherents amb la lògica del sistema. Aquesta validació ha permès detectar que el sistema funciona de manera raonable, tot i que els resultats amb dades externes s'han d'interpretar amb prudència per la mida limitada de la mostra.

També s'ha desenvolupat la part de representació del coneixement mitjançant un sistema CBR, basat en el cicle de les 4R: Retrieve, Reuse, Revise i Retain. Aquest component aporta valor perquè permet comparar un nou alumne amb casos històrics similars, estimar el seu risc i proposar intervencions

adaptades al seu perfil. Això fa que el sistema no sigui només predictiu, sinó també explicatiu i orientat a l'acció.

A més, s'ha realitzat la interfície del sistema, pensada perquè pugui ser utilitzada per un centre educatiu. El dashboard permet visualitzar una visió global dels estudiants, consultar fitxes individuals, veure el risc estimat, els factors explicatius, el perfil assignat i les intervencions recomanades. També incorpora apartats de validació, simulació i seguiment, fet que facilita que tutors, orientadors o coordinadors puguin interpretar els resultats i actuar de manera més informada.

En conjunt, el projecte ha evolucionat des d'un plantejament inicial centrat en l'anàlisi i els models cap a una proposta més completa d'IDSS. Actualment, el sistema integra dades, models predictius, perfils d'estudiants, explicabilitat, raonament basat en casos, recomanacions d'intervenció, validació i una interfície funcional. Això reforça la seva utilitat com a eina de suport a la presa de decisions educatives.

Tot i això, també s'han identificat limitacions. El sistema s'ha desenvolupat amb un dataset extern i la validació s'ha fet amb una mostra reduïda d'enquestes, de manera que en un entorn real caldria disposar de dades reals d'un centre educatiu i fer un seguiment temporal dels estudiants. També seria necessari continuar monitoritzant possibles biaixos, revisar periòdicament el rendiment dels models i validar les recomanacions amb professionals de l'àmbit educatiu.

Finalment, cal destacar que el treball en equip ha estat positiu, especialment després del parcial, quan el grup es va organitzar millor i va portar la redacció de l'informe més al dia. Tot i que en alguns moments la càrrega de feina no ha estat del tot equilibrada, la coordinació, les reunions setmanals i la comunicació entre membres han permès avançar de manera progressiva i assolir els objectius plantejats. En conclusió, el projecte constitueix una proposta robusta, coherent i amb potencial d'aplicació real per ajudar els centres educatius a detectar situacions de risc i prendre decisions més fonamentades.