

SISTEMA INTEL·LIGENT DE SUPORT A LA DECISIÓ (IDSS)

DETECCIÓ D'ESTUDIANTS EN RISC D'ABANDONAMENT ESCOLAR



Albert Campos, Adrià Hernandez, Oriol Martí, Júlia Pedrol, Albert Roca, i Jana Roman

INTRODUCCIÓ I DADES UTILITZADES



El Problema: Rendiment Acadèmic i Abandonament Escolar



SITUACIÓ ACTUAL

L'anàlisi del rendiment acadèmic permet detectar estudiants amb risc de fracàs o abandonament, però molts centres es basen en la intuïció i no en dades.

OBJECTIUS DEL SISTEMA

- Detectar patrons d'abandonament a partir de dades acadèmiques i socioeducatives
- Classificar els estudiants segons nivell de risc (alt risc / baix risc)
- Donar suport a docents i centres en la presa de decisions informada

IMPACTE ESPERAT

Millora en la taxa de retenció i rendiment acadèmic mitjançant intervencions personalitzades i basades en evidència




BENEFICIS CLAU



Identificació precoç: detectar alumnes que necessiten suport abans que empitjori.



Detecció de factors: analitzar variables que influeixen en el rendiment.



Presa de decisions: facilitar intervencions (reforç, tutories).

6670
ESTUDIANTS ANALITZATS

21
VARIABLES ESTUDIADAES

1%
MISSINGS

7 VARIABLES NUMÈRIQUES

5 VARIABLES BINÀRIES

9 VARIABLES QUALITATIVES

LA TASCA I LA DECISIÓ

El projecte té com a objectiu segmentar els estudiants mitjançant tècniques de clustering per identificar perfils acadèmics. Posteriorment, s'aplica un model supervisat per predir el risc de baix rendiment o abandonament dins de cada perfil. La decisió que es vol prendre és determinar quin tipus d'intervenció educativa aplicar segons el perfil de l'estudiant i el seu nivell de risc. Això permet decidir si cal suport acadèmic, seguiment personalitzat o cap intervenció.

PROPOSTA DE VALOR

La IA permet detectar patrons en el rendiment acadèmic i identificar estudiants amb risc de baixes notes, facilitant decisions educatives més eficients i basades en dades.

DADES

El dataset inclou dades demogràfiques i educatives (gènere, nivell dels pares, alimentació, curs preparatori) i les notes finals.

JUDICI

- Prioritat: evitar falsos negatius.
- S'accepten alguns falsos positius.
- Classificació: Alt risc / Baix risc.
- Revisió final a càrrec del professorat.

RESULTAT

Objectius: reduir en un 15% el nombre d'estudiants amb resultats baixos, augmentar en un 10% la taxa d'aprovat després de les intervencions i incrementar el nombre d'estudiants que milloren la seva nota després del reforç.

DESPLEGAMENT

Preparació: centre, objectius i RGPD.

Dades: recollida, neteja i validació.

Model: adaptació i validació real.

Pilot: prova amb usuaris.

Integració: dashboard i formació.

Producció: ús complet del sistema.

Seguiment: control i millora contínua.

RISCOS


- **Biaixos en les dades:** possibles desigualtats socioeconòmiques o demogràfiques que el model podria aprendre i amplificar.
- **Sobreajustament (overfitting):** que el model funcioni bé amb les dades d'entrenament però no amb dades reals.
- **Mala interpretació dels resultats:** ús incorrecte de les prediccions per part del professorat.
- **Riscos ètics:** estigmatització d'estudiants en classificar-los com a "alt risc".

BARRERES

Les principals barreres poden ser la resistència al canvi per part del professorat i de l'equip directiu, la manca de cultura de dades, les limitacions tècniques dels centres educatius i possibles problemes relacionats amb la protecció i privacitat de les dades dels estudiants.

ARQUITECTURA DE L'IDSS


ARQUITECTURA GLOBAL DEL SISTEMA



1. DADES



2. PREPROCESSAMENT



3. MODELS



4. RESULTATS




5. USUARIS



6. INTERVENCIÓ



7. REENTRENAMENT



MODEL DE DECISIÓ

1.PREDIR NIVELL DE RISC

- **Tipus:** Operativa (automatitzada)
- **Responsable de la decisió:** Sistema analític predictiu
- **Input:** Notes, GPA, assistència, crèdits, variables socioeconòmiques
- **Output:** Classificació de risc per a cada estudiant

4.MONITORITZAR I ACTUALITZAR

- **Tipus:** Operativa
- **Responsable de la decisió:** Sistema analític
- **Input:** Dades actualitzades, assistència, evolució
- **Output:** Actualització de probabilitat i grup de risc

2.ORDENAR ELS ESTUDIANTS SEGONS INTERVENCIÓ

- **Tipus:** Tàctica
- **Responsable de la decisió:** Coordinador acadèmic / Servei d'orientació
- **Input:** Classificació de risc, evolució recent, indicadors de desconnexió
- **Output:** Llista prioritzada d'estudiants en risc imminent

5.AVALUAR TENDÈNCIES GLOBALS

- **Tipus:** Estratègica
- **Responsable de la decisió:** Direcció acadèmica
- **Input:** Distribució de riscos, taxes, efectivitat
- **Output:** Informe institucional i recomanacions

3.ASSIGNAR TIPUS D'INTERVENCIÓ SEGONS EL RISC

- **Tipus:** Operativa
- **Responsable de la decisió:** Tutor acadèmic / Coordinador
- **Input:** Nivell de risc, historial, situació econòmica, recursos
- **Output:** Pla personalitzat (tutoria, suport econòmic, reforç)

RESULTAT PRINCIPAL

- CLASSIFICACIÓ BINÀRIA

EN RISC

SENSE RISC

TIPUS D'USUARIS DE L'IDSS



USUARIS OPERATIUS

INTERVENCIÓ DIRECTA

- **Perfils:** Tutors, professorat, orientadors
- **Necessitats:**
 - Identificar ràpidament nivell de risc
 - Entendre factors contribuents
 - Rebre recomanacions clares
 - Fer seguiment de l'evolució
- **Valor:** Detecció precoç i actuació immediata



USUARIS ESTRATÈGICS

POLÍTIQUES I PLANIFICACIÓ

- **Perfils:** Equips directius, direcció acadèmica, qualitat
- **Necessitats:**
 - Indicadors agregats (taxa de risc, evolució temporal)
 - Informes per definir polítiques i planificar programes
 - Comparar resultats entre cohorts o progrés
 - Ajustar recursos a nivell institucional
- **Valor:** Orientació d'estratègies a mitjà i llarg termini



USUARIS TÀCTICS

PRIORITZACIÓ I COORDINACIÓ

- **Perfils:** Coordinadors, cap d'estudis, orientació
- **Necessitats:**
 - Llistes ordenades per risc i urgència
 - Visió agregada per grups/cursos
 - Assignació de recursos (tutories, reforç)
 - Garantir atenció als casos més crítics
- **Valor:** Priorització i optimització de recursos



USUARIS TÈCNICS

MANTENIMENT DEL SISTEMA

- **Perfils:** Analistes de dades, equips IT, data scientists
- **Necessitats:**
 - Monitoritzar qualitat de dades
 - Reentrenar models periòdicament
 - Detectar canvis en patrons
 - Gestionar manteniment tècnic i APIs
- **Valor:** Fiabilitat i sostenibilitat del sistema en producció

PREPROCESSAMENT DE DADES I EDA

1. FILTRATGE I GENERACIÓ DE DB

- Selecció funcional de variables
- **Dataset original:** 6670 registres i 22 variables
- **Generació de la nova base:** *student_preprocessed.csv*

2. DETECCIÓ DE MISSINGS

- **3 variables amb valors nuls (1%):**
 - *parental_education_level*
 - *teacher_quality*
 - *distance_from_home*
- Imputació per moda global

3. DETECCIÓ D'OUTLIERS

- PCA + distància de Mahalanobis (99% confiança)
- 34 observacions identificades com a potencials outliers
- Tractament conservador: cap eliminació

4. FILTER SELECTION

- Selecció contextual de variables
- PCA: només variables numèriques contínues
- Exclusió de categòriques, binàries i variable objectiu

5. TRANSFORMACIÓ I NOVES VARIABLES

- **Binarització de variables dicotòmiques:**
 - *Extracurricular_Activities*
 - *Internet_Access*
 - *Learning_Disabilities*
- **Conversió Yes/No → 1/0**


RESULTAT DEL PREPROCESSAMENT

- Dataset completament net (0 valors nuls), sense observacions eliminades, variables binaritzades i preparades per alimentar els models analítics de l'IDSS.

REUSLTATS DEL EDA

- Desequilibri moderat de la variable objectiu (80% no dropout vs 20% dropout)
- Motivation_Level és el predictor més discriminant (45.7% dropout en motivació baixa vs 1.4% alta)
- Attendance, Hours_Studied i Previous_Scores mostren relació clara amb l'abandonament
- Variables com Sleep_Hours, Physical_Activity o Gender no aporten valor predictiu rellevant

MODELS DEL SISTEMA: CLUSTERING JERARQUIC



CLUSTER 1 - 66.22% DEL TOTAL
4417 ESTUDIANTS



CLUSTER 3 - 7.42% DEL TOTAL
495 ESTUDIANTS



CLUSTER 2 - 15.86% DEL TOTAL
1058 ESTUDIANTS



CLUSTER 4 - 9.55% DEL TOTAL
637 ESTUDIANTS



QUALITAT DEL CLUSTERING

0.57 COEFICIENT DE CORRELACIÓ COFONÈTICA

Indica qualitat moderada en la representació de les distàncies originals

4

CLUSTERS

6670

ESTUDIANTS

Ward

MÈTODE



ESTRUCUTRA DEL CLUSTERING

Separació moderada entre clusters amb certa superposició entre grups. Els límits entre grups no són completament definits, indicant una estructura interna realista.

PROFILING

SISTEMA DE COLOR DEL TRAFIC LIGHT PANEL



VERD

Situació favorable



GROC


Situació intermèdia



VERMELL

Situació desfavorable

Annotated Traffic Light Panel (aTLP)



CLUSTER 1

PERFIL FAVORABLE I RELATIVAMENT HOMOGENI

- Predomini de valors favorables i baixa tendència a l'abandonament
- Variabilitat moderada a l'aTLP, amb certa heterogeneïtat interna
- Grup estable que requereix principalment seguiment general

Menor risc educatiu global

CLUSTER 2

PERFIL DE RISC ALT I HOMOGENI

- Concentració de valors desfavorables en variables acadèmiques clau
- Alta coherència interna segons els resultats de l'aTLP
- Major probabilitat d'abandonament i baix rendiment acadèmic

Grup prioritari d'intervenció

CLUSTER 3

PERFIL INTERMIG AMB FACTORS DE RISC

- Combinació de factors protectors i elements de risc acadèmic
- Variabilitat moderada amb comportaments menys estables
- Requereix seguiment específic per possibles casos de risc

Perfil acadèmic intermig


CLUSTER 4

PERFIL INTERMIG AMB DEBILITATS ESTRUCTURALS

- Predomini de valors neutres amb alguns factors desfavorables
- Perfil relativament equilibrat però amb certes debilitats
- Pot presentar dificultats acadèmiques en casos concrets

Risc moderat i seguiment preventiu

MODEL DE CLASSIFICACIÓ SUPERVISADA



- **Problema:** Classificació binària (dropout: 0/1)
- **Desbalanceig:** 80% / 20%
- **Split:** 80% train / 20% test (stratified)

VARIABLES RELLEVANTS

- 1.Exam_Score:** variable més rellevant en tots els models
- 2.Motivation_Level_Low:** impacte molt elevat en l'abandonament
- 3.Hours_Studied:** forta relació negativa amb el dropout
- 4.Attendance:** menor assistència = major risc
- 5.Previous_Scores:** paper important en la predicció

	F1 - Score	Accuracy	Recall	ROC - AUC
MLP	0.9488	0.9795	0.947	0.9976
XGBoost	0.9509	0.9804	0.954	0.998
Logistic Regression	0.9429	0.9772	1	0.9995

CONCLUSIONS PRINCIPALS

- XGBoost ofereix el millor rendiment global.
- La regressió logística destaca pel recall perfecte (1.0), ideal per detectar tots els casos de risc.
- **Els factors clau:** rendiment acadèmic, motivació i compromís.

MOTOR D'EXPLICABILITAT

- Construït sobre **XGBoost** amb tècnica SHAP (SHapley Additive exPlanations). Permet interpretar les prediccions a dos nivells: global (importància de variables) i local (explicació per a cada estudiant individual).


0.9796
ACCURACY

0.9472
PRECISION

0.9508
RECALL

0.9490
F1-SCORE

0.9981
ROC - AUC



EXPLICACIÓ LOCAL - 3 CASOS REPRESENTATIUS:

Cas 1: Risc ALT

- Nota baixa, motivació baixa, poques hores d'estudi, assistència reduïda

Cas 2: Risc INTERMIG

- Factors mixtos de risc i protecció combinats

Cas 3: Risc BAIX

- Més hores d'estudi, millor historial acadèmic i assistència

INTERVENTION IMPACT ANALYSIS

PLANTEJAMENT INICIAL (intervention learning)

Sistema d'anàlisi **dinàmic i longitudinal** per fer seguiment de la trajectoria del risc d'abandonament escolar. Es va haver de descartar degut a l'alta complexitat del model, i quedava fora de l'abast del projecte realitzar **2 models IDSS diferents**.

CONCLUSIONS

Un anàlisi periòdic per revisar que les intervencions aplicades tinguin l'impacte esperat és important tant per comprovar que el model està funcionant com toca, sobretot a l'inici. També servirà com a baseline de comparació entre escoles, per veure si les intervencions s'apliquen de forma correcta.

IMPLEMENTACIÓ

1. BOLCAT HISTÒRIC DE DADES




2. DADES SINTÈTIQUES



3. COMPARACIÓ




4. ANÀLISI D'IMPACTE



REPRESENTACIÓ DEL CONEIXEMENT

VARIABLES	PES	TIPUS	RANG / VALORS
Hours_Studied	0.12	Numèrica	0 – 44
Attendance	0.15	Numèrica	0 – 100
Previous_Scores	0.1	Numèrica	0 – 100
Exam_Score	0.13	Numèrica	0 – 100
Sleep_Hours	0.04	Numèrica	4 – 10
Tutoring_Sessions	0.06	Numèrica	0 – 8
Physical_Activity	0.03	Numèrica	0 – 6
Motivation_Level	0.12	Ordinal	Low / Med / High
Access_to_Resources	0.07	Ordinal	Low / Med / High
Parental_Involvement	0.05	Ordinal	Low / Med / High
Family_Income	0.04	Ordinal	Low / Med / High
Teacher_Quality	0.03	Ordinal	Low / Med / High
Peer_Influence	0.03	Ordinal	Neg / Neu / Pos
Learning_Disabilities	0.03	Binària	0 / 1



CÀLCUL DEL RISC D'ABANDONAMENT

Similitud Global:

$$Sim(q, c) = \frac{\sum w_i \cdot sim_i(q_i, c_i)}{\sum w_i}$$

- Compara el nou estudiant amb casos previs
- Variables ponderades segons importància
- Recupera els estudiants més similars

!! Factors amb major impacte:

- Motivation_Level baixa (+30 punts)
- Hours_Studied baixes (+24)
- Attendance baixa (+23)
- Exam_Score baix (+20)
- Previous_Scores baixos (+14)

$RiskScore \in [0, 100]$

- ALT ≥ 65
- MITJÀ ≥ 38
- BAIX < 38

Probabilitat de dropout: $P(dropout) = 0.6 \cdot Veïns + 0.4 \cdot RiskScore$

- 60% → casos similars recuperats
- 40% → perfil individual calculat



Combina experiència prèvia
+ regles educatives

CATÀLEG D'INTERVENCIONS (REGLES DE PRODUCCIÓ)

- **INT-01 Tutoria motivacional** → (Motivation_Level = Low)
- **INT-02 Seguiment d'assistència** → (Attendance < 75%)
- **INT-03 Suport necessitats educatives** → (Learning_Disabilities = 1)
- **INT-04 Pla d'estudi guiat** → (Hours_Studied < 15)
- **INT-05 Reforç acadèmic** → (Exam_Score < 64)
- **INT-06 Suport en recursos educatius** → (Access_to_Resources = Low)
- **INT-07 Sessions tutoria acadèmica** → (Tutoring_Sessions = 0)
- **INT-08 Implicació familiar** → (Parental_Involvement = Low)
- **INT-09 Gestió influència iguals** → (Peer_Influence = Negative)
- **INT-10 Seguiment ordinari** → (seguiment per defecte)

VALIDACIÓ: APLICACIÓ DE L'ENQUESTA



ENQUESTA VIA GOOGLE FORMS

OBJECTIU

Obtenir dades externes per provar l'IDSS fora del dataset original.



Aquesta nova base s'ha obtingut directament a partir de respostes reals

- Validació del sistema en un context més real
- Primera aproximació a l'ús real de l'IDSS
- Integració de dades manuals dins el flux de l'IDSS

COMPARATIVA DE MÈTRIQUES: BASE ORIGINAL VS. BASE DE VALIDACIÓ

MÈTRICA	XGBoost Og.	XGBoost Val.	MLP Val.
ACCURACY	0.9796	0.8333	0.8333
PRECISION	0.9472	1	1
RECALL	0.9508	0.5	0.5
F1 - SCORE	0.949	0.6667	0.6667

CLUSTERING I PROFILING

- Els alumnes amb risc del 100% classificats en perfils de risc coherentment. Alumnes amb risc 0% assignats a perfils amb factors protectors.

MOTOR D'EXPLICABILITAT (SHAP)

- *Motivation_Low* continua sent la variable amb més impacte. *Hours_Studied*, *Attendance* i *Previous_Scores* mantenen pes rellevant.

ÈTICA, IMPACTE I VALIDACIÓ GENERAL


CONSIDERACIONS ÈTIQUES

- **Privacitat:** Compliment normatiu per a dades personals.
 - **Biaix:** Risc de reflectir desigualtats presents en les dades.
 - **Estigmatitzacio:** "Alt risc" = senyal d'alerta, no etiqueta fixa.
- Solucio:** Explicabilitat + supervisió humana.

PERSPECTIVA DE GÈNERE

La variable **Gender** no mostra relació significativa amb dropout:

- Taxes d'abandonament idèntiques entre categories
- No es va considerar variable discriminant
- **Mostra de validacio desigual (més homes)**



VALIDACIÓ GENERAL DEL SISTEMA




COMPONENTS

Cada mòdul validat independentment



INTERACCIONS

Comunicació fluida entre mòduls



INPUTS / OUTPUTS

Dades clares i resultats útils




RENDIMENT GLOBAL

KPIs d'impacte acadèmic

Conclusió: El sistema es considera validat si els components funcionen correctament, la comunicació entre mòduls és fluida, els inputs i outputs són clars, les prediccions són coherents i els usuaris confien en els resultats. L'IDSS pot actuar com una eina de suport per identificar preventivament estudiants amb risc d'abandonament escolar.

AVALUACIÓ GENERAL DEL IDSS



3 NIVELLS DE VALIDACIÓ


- **Components individuals:** cada part funciona correctament per separat.
- **Interaccions entre components:** comunicació fluida sense errors.
- **Rendiment global:** el sistema aporta valor als stakeholders.

COMPONENT	METODOLOGIA DE VALIDACIÓ	ESTAT
Data / Preprocessament	Revisió de valors nuls, formats, duplicats, coherència	✓ Validat
Models data-driven	Accuracy, precision, recall, F1-score, ROC-AUC, matriu de confusió	✓ Validat
Clustering / Perfils	Qualitat dels grups, interpretació, coherència amb variables	✓ Validat
Knowledge Sources	Revisió manual de regles i coherència amb domini educatiu	✓ Validat
Motor de raonament	Proves amb casos d'estudiants de diferents nivells de risc	✓ Validat
Mòdul explicabilitat	Revisió de si les explicacions indiquen correctament els factors de risc	✓ Validat
Dashboard / Interfície	Proves d'usabilitat amb diferents tipus d'usuaris	✓ Validat

RESULTATS PRINCIPALS DE VALIDACIÓ: KPIs

IMPACTE EN EL RENDIMENT -10~15% Estudiants amb baix rendiment	MILLORA TAXA APROVACIÓ +5~10% Després de les intervencions	RECALL DEL MODEL 0.951 Detecció d'estudiants en risc	ROC-AUC 0.998 Capacitat discriminativa	REENTRENAMENT 6 mesos Cicle de millora contínua
---	--	--	--	---

DASHBOARD



CONCLUSIONS, MILLORES I PROPER PASSOS

CONCLUSIONS

- IDSS viable per detectar risc d'abandonament escolar
- Motivació = predictor dominant ($V = 0.43$)
- XGBoost: F1-score 0.95, AUC 0.998
- 4 perfils d'estudiants identificats
- Dashboard funcional amb prediccions i explicabilitat

POSSIBLES MILLORES

- Clustering revisat: de 3 a 4 perfils
- Enquesta de validació amb dades externes
- Sistema CBR (Retrieve, Reuse, Revise, Retain)
- Dashboard interactiu amb simulador
- Motor SHAP d'explicabilitat integrat

PROPER PASSOS

- Desplegar en un centre educatiu real
- Dades en temps real (ERP / LMS)
- Base de dades centralitzada
- Monitorització longitudinal del risc
- Avaluar efectivitat d'intervencions
- Reentrenament periòdic del model

IMPACTE EN L'EDUCACIÓ

TECNOLOGIA AL SERVEI DELS ESTUDIANTS

DECISIONS BASADES EN DADES

SISTEMA INTEL·LIGENT DE SUPORT A LA DECISIÓ (IDSS)

DETECCIÓ D'ESTUDIANTS EN RISC D'ABANDONAMENT ESCOLAR



Albert Campos, Adrià Hernandez, Oriol Martí, Júlia Pedrol, Albert Roca, i Jana Roman