

SISTEMA INTEL·LIGENT DE SUPORT A LA DECISIÓ (IDSS)

DETECCIÓ D'ESTUDIANTS EN RISC D'ABANDONAMENT ESCOLAR



Albert Campos, Adrià Hernandez, Oriol Martí, Júlia Pedrol, Albert Roca, i Jana Roman

INTRODUCCIÓ I DADES UTILITZADES



El Problema: Rendiment Acadèmic i Abandonament Escolar



SITUACIÓ ACTUAL

L'anàlisi del rendiment acadèmic permet detectar estudiants amb risc de fracàs o abandonament, però molts centres es basen en la intuïció i no en dades.

OBJECTIUS DEL SISTEMA

- Detectar patrons d'abandonament a partir de dades acadèmiques i socioeducatives
- Classificar els estudiants segons nivell de risc (alt risc / baix risc)
- Donar suport a docents i centres en la presa de decisions informada

IMPACTE ESPERAT

Millora en la taxa de retenció i rendiment acadèmic mitjançant intervencions personalitzades i basades en evidència




BENEFICIS CLAU



Identificació precoç: detectar alumnes que necessiten suport abans que empitjori.



Detecció de factors: analitzar variables que influeixen en el rendiment.



Presa de decisions: facilitar intervencions (reforç, tutories).

6670

ESTUDIANTS ANALITZATS

21

VARIABLES ESTUDIADES

1%


MISSINGS

7 VARIABLES NUMÈRIQUES

5 VARIABLES BINÀRIES

9 VARIABLES QUALITATIVES

DADES UTILITZADES: STUDENT PERFORMANCE



LA TASCA I LA DECISIÓ

El projecte té com a objectiu segmentar els estudiants mitjançant tècniques de clustering per identificar perfils acadèmics. Posteriorment, s'aplica un model supervisat per predir el risc de baix rendiment o abandonament dins de cada perfil. La decisió que es vol prendre és determinar quin tipus d'intervenció educativa aplicar segons el perfil de l'estudiant i el seu nivell de risc. Això permet decidir si cal suport acadèmic, seguiment personalitzat o cap intervenció.

PROPOSTA DE VALOR

La IA permet detectar patrons en el rendiment acadèmic i identificar estudiants amb risc de baixes notes, facilitant decisions educatives més eficients i basades en dades.

JUDICI

- Prioritat: evitar falsos negatius.
- S'accepten alguns falsos positius.
- Classificació: Alt risc / Baix risc.
- Revisió final a càrrec del professorat.

DESPLEGAMENT

Preparació de dades
Modelatge
Validació
Pilot
Integració
Posada en producció
Seguiment i millora

DADES

El dataset inclou dades demogràfiques i educatives (gènere, nivell dels pares, alimentació, curs preparatori) i les notes finals.

RESULTAT

Objectius: reduir en un 15% el nombre d'estudiants amb resultats baixos, augmentar en un 10% la taxa d'aprovat després de les intervencions i incrementar el nombre d'estudiants que milloren la seva nota després del reforç.

LA TASCA I LA DECISIÓ


- **Biaixos en les dades:** possibles desigualtats socioeconòmiques o demogràfiques que el model podria aprendre i amplificar.
- **Sobreajustament (overfitting):** que el model funcioni bé amb les dades d'entrenament però no amb dades reals.
- **Mala interpretació dels resultats:** ús incorrecte de les prediccions per part del professorat.
- **Riscos ètics:** estigmatització d'estudiants en classificar-los com a "alt risc".

BARRERES

Les principals barreres poden ser la resistència al canvi per part del professorat i de l'equip directiu, la manca de cultura de dades, les limitacions tècniques dels centres educatius i possibles problemes relacionats amb la protecció i privacitat de les dades dels estudiants.

ARQUITECTURA DE L'IDSS


ARQUITECTURA GLOBAL DEL SISTEMA



1. DADES



2. PREPROCESSAMENT



3. MODELS



4. RESULTATS




5. USUARIS





6. INTERVENCIÓ



7. REENTRENAMENT










**MÒDUL DE
PREPROCESSAMENT**

**SORTIDES DEL
SISTEMA**



MODEL DE DECISIÓ

1.PREDIR NIVELL DE RISC

- **Tipus:** Operativa (automatitzada)
- **Responsable de la decisió:** Sistema analític predictiu
- **Input:** Notes, GPA, assistència, crèdits, variables socioeconòmiques
- **Output:** Classificació de risc per a cada estudiant

4.MONITORITZAR I ACTUALITZAR

- **Tipus:** Operativa
- **Responsable de la decisió:** Sistema analític
- **Input:** Dades actualitzades, assistència, evolució
- **Output:** Actualització de probabilitat i grup de risc

2.ORDENAR ELS ESTUDIANTS SEGONS INTERVENCIÓ

- **Tipus:** Tàctica
- **Responsable de la decisió:** Coordinador acadèmic / Servei d'orientació
- **Input:** Classificació de risc, evolució recent, indicadors de desconnexió
- **Output:** Llista prioritzada d'estudiants en risc imminent

5.AVALUAR TENDÈNCIES GLOBALS

- **Tipus:** Estratègica
- **Responsable de la decisió:** Direcció acadèmica
- **Input:** Distribució de riscos, taxes, efectivitat
- **Output:** Informe institucional i recomanacions

3.ASSIGNAR TIPUS D'INTERVENCIÓ SEGONS EL RISC

- **Tipus:** Operativa
- **Responsable de la decisió:** Tutor acadèmic / Coordinador
- **Input:** Nivell de risc, historial, situació econòmica, recursos
- **Output:** Pla personalitzat (tutoria, suport econòmic, reforç)

RESULTAT PRINCIPAL

- CLASSIFICACIÓ BINÀRIA

EN RISC

SENSE RISC


TIPUS D'USUARIS DE L'IDSS



USUARIS OPERATIUS

INTERVENCIÓ DIRECTA

- **Perfils:** Tutors, professorat, orientadors
- **Necessitats:**
 - Identificar ràpidament nivell de risc
 - Entendre factors contribuents
 - Rebre recomanacions clares
 - Fer seguiment de l'evolució
- **Valor:** Detecció precoç i actuació immediata



USUARIS ESTRATÈGICS

POLÍTIQUES I PLANIFICACIÓ

- **Perfils:** Equips directius, direcció acadèmica, qualitat
- **Necessitats:**
 - Indicadors agregats (taxa de risc, evolució temporal)
 - Informes per definir polítiques i planificar programes
 - Comparar resultats entre cohorts o progres
 - Ajustar recursos a nivell institucional
- **Valor:** Orientació d'estratègies a mitjà i llarg termini



USUARIS TÀCTICS

PRIORITZACIÓ I COORDINACIÓ

- **Perfils:** Coordinadors, cap d'estudis, orientació
- **Necessitats:**
 - Llistes ordenades per risc i urgència
 - Visió agregada per grups/cursos
 - Assignació de recursos (tutories, reforç)
 - Garantir atenció als casos més crítics
- **Valor:** Priorització i optimització de recursos



USUARIS TÈCNICS

MANTENIMENT DEL SISTEMA

- **Perfils:** Analistes de dades, equips IT, data scientists
- **Necessitats:**
 - **Monitoritzar qualitat de dades**
 - **Reentrenar models periòdicament**
 - **Detectar canvis en patrons**
 - **Gestionar** manteniment tècnic i APIs
- **Valor:** Fiabilitat i sostenibilitat del sistema en producció

PREPROCESSAMENT DE DADES

TRACTAMENT DE MISSINGS

- Parental_Education_Level 1,36%
- Teacher_Quality 1,18%
- Distance_from_Home 1,01%

IMPUTACIÓ AMB MODA

OUTLIERS

ANÀLISI AMB PCA


BINARITZACIÓ

RECODIFICACIÓ DE VARIABLES



MANTENIR INTERPRETABILITAT

CASOS POC FREQUENTS
PERÒ PLAUSIBLES

PCA - Outliers detectados (exploratorio)




ANÀLISIS DEL CONJUNT DE DADES (EDA)






Principals aspectes a comentar

- Fort desbalanceig de la variable objectiu
- Els estudiants que abandonen tenen ~10.7 punts menys d'assistència
- Notes prèvies ~7 punts inferiors en el grup dropout.

Violin plots: Variables numèriques vs. dropout



ANÀLISIS DEL CONJUNT DE DADES (EDA)



CONCLUSIONS FINALS

- Les intervencions de l'IDSS haurien de prioritzar la motivació sobre l'assistència i atenció.
- Factors socio-econòmics i demogràfics no discriminen.
- Les variables de estil de vida no aporten informació.



Principal predictor: Motivation_Level

- Un estudiant amb motivació baixa té un risc 32 vegades major d'abandonar que un amb motivació alta.
- Les correlacions entre variables numèriques son prou baixes (només Dropout i Exam_Score s'associen)

MODELS DEL SISTEMA: CLUSTERING JERARQUIC



OBJECTIU

Segmentar els estudiants en grups homogenis segons les seves característiques acadèmiques, socioeconòmiques i contextuals, sense necessitat d'etiquetes prèvies.



APLICACIÓ


Detectar perfils comuns de comportament i patrons compartits entre estudiants amb característiques similars, facilitant la comprensió de la composició de la població estudiantil.



METEDOLOGIA

Detectar perfils comuns de comportament i patrons compartits entre estudiants amb característiques similars, facilitant la comprensió de la composició de la població estudiantil.

Dendrograma - Clustering Jeràrquic



3

CLUSTERS

6670

ESTUDIANTS

Ward

MÈTODE

RESULTATS CLUSTERING JERARQUIC

CLUSTER 1 5054 ESTUDIANTS



76.5% DEL TOTAL
GRUP PREDOMINANT - PERFIL HETEROGENI

CLUSTER 2 1058 ESTUDIANTS




16.0% DEL TOTAL
GRUP DE RISC - PERFIL DESFAVORABLE

CLUSTER 3 495 ESTUDIANTS



7.5% DEL TOTAL
GRUP FAVORABLE - PERFIL EXCEL·LENT

Clusters (PCA)



QUALITAT DEL CLUSTERING

0.57 COEFICIENT DE CORRELACIÓ COFONÈTICA
Indica qualitat moderada en la representació de les distàncies originals



QUALITAT DEL CLUSTERING

Separació moderada entre clusters amb certa superposició entre grups. Els límits entre grups no són completament definits, indicant una estructura interna realista.

MODELS DEL SISTEMEA: PROFILING

CLUSTER 1

PERFIL HETEROGENI I INTERMIG

- **Predomini de groc:** valors intermedis en la majoria de variables
- **Alta variabilitat:** intensitat baixa al aTLP, comportaments heterogenis
- **Risc moderat:** poden coexistir situacions diferents, incloent casos amb risc

No és un perfil clarament definit, conjunt divers

CLUSTER 2

PERFIL DE RISC CONSISTENT

- **Concentració de vermell:** valors desfavorables en diverses variables clau
- **Alta homogeneïtat:** colors intensos al aTLP, comportaments - consistents
- **Major risc:** indicadors desfavorables consistents entre membres

Grup que requereix intervenció prioritària

CLUSTER 3

PERFIL FAVORABLE I HOMOGENI

- **Predomini de verd:** valors favorables en variables rellevants
- **Gran coherència:** colors intensos al aTLP, resultats positius consistents
- **Millor situació:** menor risc d'abandonament


Grup amb millor rendiment acadèmic global

SISTEMA DE COLOR DEL TRAFIC LIGHT PANEL



VERD

Situació favorable




GROC

Situació intermèdia




VERMELL

Situació desfavorable



MODEL DE CLASSIFICACIÓ SUPERVISADA

	F1-Score	Accuracy	Recall	ROC-AUC
MLP	0.9488	0.9795	0.9470	0.9976
XGBoost	0.9509	0.9804	0.954	0.9980
Logistic Regression	0.9429	0.9772	1.000	0.9995



MODEL D'EXPLICABILITAT




OBJECTIU

- Explicar les prediccions del model de classificació
- Identificar quines variables influeixen més
- Comportament global i cassos específics





PROCEDIMENT



- Model XGBoost (millor rendiment)
- Aplicació de SHAP per explicar el model
- Anàlisi:
 - Global → variables més importants
 - Local → explicació de casos concrets
- Interpretació de l'impacte de cada variable en la predicció





CAS D'ALT RISC



CAS LÍMIT



CAS DE BAIX RISC



CONCLUSIÓ

El model mostra que factors com la motivació, les hores d'estudi i l'assistència tenen més impacte real en el risc d'abandonament que la nota d'examen, indicant que aquest risc no depèn només del rendiment acadèmic sinó també de factors de comportament i implicació de l'alumne.

INTERVENTION BASED LEARNING



OBJECTIU

- Entendre accions funcionen per a cada perfil d'alumne.



APLICACIÓ


- Incorporar l'històric d'intervencions (tutories, reforç) en l'aprenentatge del model.



VALORS

- Millor interpretació del risc.
- Recomanacions d'intervenció personalitzades.
- Millora contínua del model.

Cas d'alt risc



Informació rellevant per al model

1. Predicció inicial (t0)
Model detecta el risc i variables clau

2. Captura d'accions
Registrar les intervencions aplicades

3. Noves dades (t1)
Es registra l'actualització periòdica de l'alumnat

4. Càlcul de delta
Comparació del model entre t0 i t1

5. Etiquetatge de cas
Val

6. Reentrenament
Ajust dels pesos del model

ESTAT ACTUAL D4

- Trajectoria futura
- Manca actualització de dades

ROADMAP CAP A D5

- Maneres de fer l'update
- Executar primer **cicle** complet de **delta**
- Construir primer dataset **acció-resultat**

CONCLUSIONS I PROXIMS PASSOS

L'IDSS desenvolupat ofereix una **solució integral** per a la detecció precoç del risc d'abandonament escolar, **combinant tècniques avançades de machine learning** amb una arquitectura orientada a la presa de decisions educatives.

ASSOLIMENTS CLAU



- Sistema complet d'anàlisi i predicció del risc d'abandonament
- Identificació de factors clau (attendance, hours studied, exam score)
- Segmentació d'estudiants en perfils de risc diferenciats
- Models amb alt rendiment predictiu ($F1 > 0.94$)
- Integració de models dins una arquitectura de presa de decisions

PROXERS PASSOS



1. Millorar i ajustar el model
2. Integrar tots els components del sistema
3. Validar el sistema amb noves dades
4. Implementació de mecanismes de feedback
5. Monitorització i millora contínua

IMPACTE EN L'EDUCACIÓ

TECNOLOGIA AL SERVEI DELS ESTUDIANTS

DECISIONS BASADES EN DADES